
Herramienta de análisis de imágenes biomédicas
Biomedical image analysis tool



Trabajo de Fin de Grado
Curso 2025–2026

Autores

Beatriz Bueno Almagro
Leonardo Sáez Biffi

Directores

María Guijarro Mata-García
David Castejón Ferrer

Grado en Ingeniería del Software
Grado en Ingeniería de Computadores
Facultad de Informática
Universidad Complutense de Madrid

Herramienta de análisis de imágenes
biomédicas
Biomedical image analysis tool

Trabajo de Fin de Grado en Ingeniería del Software e
Ingeniería de Computadores

Autores

Beatriz Bueno Almagro
Leonardo Sáez Biffi

Directores

María Guijarro Mata-García
David Castejón Ferrer

Convocatoria: *Junio 2026*

Grado en Ingeniería del Software
Grado en Ingeniería de Computadores
Facultad de Informática
Universidad Complutense de Madrid

25 de Mayo de 2026

Dedicatoria

*A todas las personas que nos han apoyado,
dentro y fuera de la universidad, durante esta
etapa.*

Agradecimientos

Queremos expresar nuestro agradecimiento a nuestros tutores, María y David, por su orientación, su disponibilidad y el seguimiento realizado a lo largo del desarrollo de este Trabajo de Fin de Grado. Sus indicaciones y sugerencias han sido fundamentales tanto en la parte técnica como en la elaboración de esta memoria.

También nos gustaría agradecer a ICTS BioImagen Complutense por la oportunidad de desarrollar este trabajo en un contexto aplicado y por el conocimiento compartido durante el proyecto. En especial, agradecemos la ayuda recibida para comprender mejor el problema biomédico abordado, así como las necesidades reales del caso de uso planteado.

Asimismo, queremos agradecer a la Unidad de Investigación Neurovascular, liderada por los doctores María Ángeles Moro e Ignacio Lizasoain, la cesión de las imágenes correspondientes al modelo de ictus isquémico empleadas en el desarrollo y validación de este trabajo.

También agradecemos a todas las personas que, de una forma u otra, han contribuido al desarrollo del proyecto, ya fuera mediante apoyo técnico, revisión de resultados o acompañamiento durante el proceso.

Por último, queremos agradecer a nuestras familias y a las personas cercanas que nos han acompañado durante esta etapa por su apoyo constante, su paciencia y su confianza a lo largo de estos años.

Resumen

Herramienta de análisis de imágenes biomédicas

El presente Trabajo Fin de Grado aborda el diseño y desarrollo de una herramienta basada en visión por computador para la segmentación de imágenes de resonancia magnética (IRM), con el objetivo de obtener medidas volumétricas a partir de regiones anatómicas y patológicas en un marco de investigación preclínico.

En colaboración con ICTS BioImagen Complutense, se ha desarrollado un prototipo funcional orientado a uno de los casos de uso planteados por el centro: la segmentación de lesión isquémica en cerebro de ratón. El sistema emplea dos modelos de segmentación, aplicados de forma secuencial sobre cada uno de los cortes de la resonancia: primero para delimitar el cerebro completo y, posteriormente, para identificar la región dañada. A partir de las máscaras de segmentación obtenidas, se calculan los volúmenes del cerebro completo y del área afectada.

Debido a la escasez de datos anotados, habitual en el ámbito biomédico, la metodología se ha fundamentado en el uso de *transfer learning* sobre una arquitectura U-Net. Asimismo, para facilitar el análisis cualitativo de las predicciones y aumentar la transparencia del prototipo, se han incorporado técnicas de Inteligencia Artificial Explicable (XAI), como Grad-CAM e *Integrated Gradients*.

Palabras clave

Imagen de Resonancia Magnética (IRM), Isquemia cerebral, Segmentación médica, Region of Interest (ROI), Inteligencia Artificial (IA), Redes Neuronales Convolucionales (CNN), U-Net, Inteligencia Artificial Explicable (XAI), Visión por computador.

Abstract

Biomedical image analysis tool

This Bachelor's thesis addresses the design and development of a computer-vision-based tool for the segmentation of magnetic resonance imaging (MRI) images, with the objective of obtaining volumetric measurements from anatomical and pathological regions within a preclinical research framework.

A functional prototype has been developed, in collaboration with ICTS BioImagen Complutense, focused on one of the use cases proposed by the centre: the segmentation of ischaemic lesions in mouse brain. The system uses two segmentation models, applied sequentially to each MRI slice: first, to delineate the whole brain and, subsequently, to identify the damaged region. The volumes of the whole brain and the affected area are calculated from the obtained segmentation masks.

Due to the scarcity of annotated data, which is a common challenge in biomedical imaging, the proposed methodology relies on *transfer learning* within a U-Net architecture. In addition, Explainable Artificial Intelligence (XAI) techniques, such as Grad-CAM and *Integrated Gradients*, have been incorporated to facilitate the qualitative analysis of the predictions and increase the transparency of the prototype.

Keywords

Magnetic Resonance Imaging (MRI), Cerebral ischaemia, Medical segmentation, Region of Interest (ROI), Artificial Intelligence (AI), Convolutional Neural Networks (CNN), U-Net, Explainable Artificial Intelligence (XAI), Computer vision.

Índice

1. Introducción	1
1.1. Contexto, antecedentes y motivación	1
1.2. Objetivos	2
1.2.1. Objetivo general	3
1.2.2. Objetivos específicos	3
1.3. Plan de trabajo	4
1.3.1. Seguimiento del proyecto y reuniones con los tutores	4
1.3.2. Fases de desarrollo	5
1.4. Estructura de la memoria	6
2. Estado de la Cuestión	9
2.1. Conceptos biomédicos: IRM preclínica y lesiones cerebrales	9
2.2. Visión por computador en imagen biomédica	10
2.3. Arquitecturas de segmentación: U-Net	13
2.4. Aprendizaje por transferencia (Transfer Learning)	15
2.5. Explicabilidad en Inteligencia Artificial (XAI)	16
3. Metodología y Desarrollo	19
3.1. Descripción del conjunto de datos (<i>Dataset</i>)	19
3.1.1. Estructura del dataset	19
3.1.2. Tamaño de dataset	20
3.2. Preprocesamiento de imágenes	21
3.2.1. Conversión de datos RAW a formato NIfTI	22
3.2.2. Segmentación manual mediante ROI	22
3.2.3. Generación de máscaras binarias	23
3.2.4. Normalización y adaptación de las imágenes	25
3.2.5. Estrategia de particionado y control de fuga de datos	26
3.3. Arquitectura de los modelos y <i>Transfer Learning</i>	27
3.3.1. Arquitectura U-Net y decisiones de implementación	27
3.3.2. Justificación de la arquitectura y uso de <i>Transfer Learning</i>	28
3.3.3. Estrategia de entrenamiento y ajuste de la salida	30
3.4. Cuantificación y métricas biomédicas (volumen)	31

3.5.	Integración de explicabilidad	33
3.5.1.	Motivación de la explicabilidad en el sistema	34
3.5.2.	Adaptación de XAI a modelos de segmentación	34
3.5.3.	Procedimiento de integración en el <i>pipeline</i>	35
3.6.	Implementación y reproducibilidad	36
3.6.1.	Requisitos de ejecución	37
3.6.2.	Repositorio y estructura del código entregado	38
4.	Resultados y Discusión	39
4.1.	Configuración experimental	40
4.2.	Resultados en segmentación cerebral	41
4.2.1.	Resultados cuantitativos	41
4.2.2.	Análisis cualitativo	43
4.2.3.	Resultados de explicabilidad en la segmentación cerebral . . .	44
4.3.	Resultados en segmentación de isquemia	47
4.3.1.	Resultados cuantitativos	47
4.3.2.	Naturaleza del problema y subjetividad	48
4.3.3.	Interpretación de métricas	48
4.3.4.	Análisis del umbral de binarización	49
4.3.5.	Análisis cualitativo	50
4.3.6.	Discusión crítica del modelo de isquemia	52
4.3.7.	Resultados de explicabilidad en la segmentación de isquemia .	52
4.4.	Conclusiones del capítulo	55
5.	Conclusiones y Trabajo Futuro	59
5.1.	Conclusiones	59
5.2.	Trabajo Futuro	61
	Introduction	63
	Conclusions and Future Work	69
	Contribuciones personales	73
	Bibliografía	79

Índice de figuras

2.1.	Flujo general de análisis en imagen médica mediante técnicas de visión por computador. Fuente: elaboración propia.	11
2.2.	Ejemplo de arquitectura U-Net para segmentación de imágenes. Fuente: Mehrdad Yazdani, Wikimedia Commons, licencia CC BY-SA 4.0.	14
2.3.	Esquema general del aprendizaje por transferencia. Fuente: elaboración propia.	16
2.4.	Esquema general de aplicación de técnicas de explicabilidad visual. Fuente: elaboración propia.	18
3.1.	Pipeline de procesamiento desde datos RAW hasta el dataset final. Fuente: elaboración propia.	22
3.2.	Ejemplo de slices de IRM. Fuente: elaboración propia.	22
3.3.	Ejemplo de segmentación ROI. Fuente: elaboración propia.	23
3.4.	Ejemplo de máscara binaria. Fuente: elaboración propia.	24
3.5.	Visualización de superposición entre la slice de resonancia magnética y su máscara de segmentación correspondiente. Fuente: elaboración propia.	26
3.6.	Esquema de la arquitectura U-Net 2D empleada en este trabajo. Fuente: elaboración propia.	28
3.7.	Proceso de cálculo del volumen de la lesión a partir de la máscara segmentada. Fuente: elaboración propia.	33
4.1.	Evolución del coeficiente Dice por Caso en el estudio de segmentación del cerebro en modelo control y con ictus isquémico permanente y transitorio. Fuente: elaboración propia.	42
4.2.	Comparación del volumen cerebral estimado por el modelo y el volumen obtenido a partir de la segmentación manual. Fuente: elaboración propia.	42
4.3.	Ejemplos cualitativos de segmentación del cerebro en distintos escenarios. Fuente: elaboración propia.	43
4.4.	Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación cerebral. Fuente: elaboración propia.	45

4.5.	Evolución del coeficiente Dice por Caso en el estudio de segmentación de lesión isquémica en modelo control y con ictus isquémico permanente y transitorio. Fuente: elaboración propia.	47
4.6.	Comparación del volumen de lesión isquémica estimado por el modelo y el volumen obtenido a partir de la segmentación manual. Fuente: elaboración propia.	49
4.7.	Ejemplos cualitativos de segmentación de isquemia en distintos escenarios. Fuente: elaboración propia.	51
4.8.	Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación de isquemia. Fuente: elaboración propia.	53
4.9.	Gráfico de Bland-Altman para analizar la concordancia entre el volumen calculado manualmente y el volumen estimado por el modelo. Fuente: elaboración propia.	56
4.10.	Distribución de las principales métricas de evaluación obtenidas en los casos analizados. Fuente: elaboración propia.	56
4.11.	Comparación del coeficiente Dice medio obtenido para cada paciente evaluado. Fuente: elaboración propia.	57

Índice de tablas

3.1. Resumen del dataset utilizado	21
3.2. Particionado del conjunto de datos a nivel de caso. Todos los cortes de una misma resonancia se asignan a un único subconjunto para evitar fuga de información entre entrenamiento y prueba.	26
3.3. Configuración general del entrenamiento de los modelos de segmentación.	31
3.4. Requisitos principales para la ejecución y reproducción del código entregado.	38
4.1. Resumen de métricas del modelo de segmentación cerebral	41
4.2. Rendimiento medio del modelo de segmentación cerebral en los cortes analizados para explicabilidad.	44
4.3. Resumen cuantitativo de las métricas de fidelidad para los métodos de explicabilidad aplicados al modelo de segmentación cerebral. . . .	46
4.4. Resumen de métricas del modelo de segmentación de isquemia	47
4.5. Comparación del rendimiento medio del modelo de isquemia para distintos umbrales de binarización.	50
4.6. Resultados cuantitativos de explicabilidad para los cortes de isquemia correctamente detectados.	54

Introducción

1.1. Contexto, antecedentes y motivación

En el ámbito de la investigación biomédica, el análisis de imágenes de resonancia magnética, o Imagen por Resonancia Magnética (IRM), constituye una herramienta fundamental para el estudio de estructuras anatómicas y el análisis de su evolución. En particular, en estudios preclínicos sobre modelos animales, como el cerebro de ratón, la resonancia magnética permite observar la evolución de distintas patologías, proporcionando información relevante para la investigación en neurociencia y el análisis de tratamientos. (Universidad Complutense de Madrid, 2024; Saito y Ueda, 2024)

El procesamiento de este tipo de imágenes, conocido como **segmentación**, consiste en delimitar la región anatómica o patológica de interés, denominada **ROI** por sus siglas en inglés **Region of Interest**, con el objetivo de cuantificar las características del órgano o de la lesión, así como estimar su volumen. Estas tareas resultan esenciales para garantizar la reproducibilidad de los experimentos y la comparabilidad de los resultados entre distintos estudios y sujetos, especialmente en aquellos casos en los que se analiza la evolución temporal de una patología o se está evaluando un posible tratamiento. (Universidad Complutense de Madrid, 2024)

Tradicionalmente, estas tareas se han realizado de forma manual: el flujo de trabajo habitual consiste en analizar cada uno de los cortes de la resonancia, identificar las regiones de interés y delimitarlas manualmente mediante herramientas de selección específicas, a partir de las cuales se procede posteriormente al cálculo de magnitudes de interés. Aunque este procedimiento permite obtener resultados experimentales válidos, presenta diversas limitaciones. Se trata de un proceso laborioso que consume una gran cantidad de tiempo, especialmente en estudios con un elevado número de sujetos. Esta carga de trabajo supone una inversión significativa de tiempo por parte de los investigadores, lo que puede repercutir en los tiempos de desarrollo de la investigación. Por otro lado, la delimitación manual de ciertas regiones, como las lesiones isquémicas, presenta un grado de ambigüedad, ya que sus fronteras no siempre están claramente definidas. Esto puede introducir variabilidad en los resultados en función del criterio del profesional. A estas limitaciones se suma la necesidad de analizar conjuntos de imágenes cada vez más extensos y de

obtener medidas cuantitativas de forma consistente, así como la demanda de análisis detallados y precisos, lo que dificulta la escalabilidad de los procesos manuales. (Universidad Complutense de Madrid, 2024; Veiga-Canuto et al., 2022; Liu et al., 2022)

En este contexto, surge la necesidad de desarrollar herramientas que permitan agilizar y automatizar de manera supervisada estas tareas, mejorando la eficiencia del proceso y aumentando la consistencia y reproducibilidad de los resultados.

El avance reciente de las técnicas de inteligencia artificial aplicadas a imagen médica ha demostrado su capacidad para identificar patrones complejos en datos visuales, abriendo la puerta a su aplicación en tareas biomédicas como la clasificación, detección y segmentación de estructuras anatómicas y lesiones. No obstante, la integración de este tipo de soluciones en contextos reales de trabajo requiere no solo obtener resultados precisos, sino también garantizar que dichos resultados sean interpretables y coherentes desde el punto de vista del dominio de aplicación. (Akkus et al., 2017; Litjens et al., 2017)

Este Trabajo de Fin de Grado, en colaboración con el centro ICTS BioImagen Complutense, pretende dar respuesta a una necesidad real observada en el entorno de investigación. A partir del conocimiento adquirido, el análisis del estado del arte y la revisión de la bibliografía, se plantea el desarrollo de una herramienta basada en modelos supervisados que permita contribuir a la mejora del proceso de análisis de imágenes de resonancia magnética en investigación preclínica, proponiendo una solución que reduzca la carga de trabajo manual y pueda contribuir a la mejora de la consistencia de los resultados.

La motivación de este trabajo no se limita únicamente a la implementación de un modelo automático, sino que se centra en el desarrollo de una herramienta que pueda integrarse dentro del flujo de trabajo existente, aportando valor como sistema de apoyo al análisis biomédico. Para ello, se combina la automatización con la supervisión por parte del experto, de forma que el usuario mantiene el control sobre los resultados finales y puede interpretar tanto las segmentaciones generadas como las medidas cuantitativas asociadas.

1.2. Objetivos

El objetivo del Trabajo de Fin de Grado es desarrollar una herramienta informática de apoyo al análisis de imágenes biomédicas preclínicas obtenidas mediante IRM. El trabajo desarrollado se centra en dos tareas de segmentación: la delimitación automática del cerebro y la segmentación de regiones correspondientes a isquemia cerebral.

La herramienta no pretende sustituir el criterio del investigador experto, sino reducir la carga asociada a la segmentación manual y proporcionar resultados reproducibles que puedan ser revisados, interpretados y utilizados como apoyo dentro del flujo de trabajo habitual del centro ICTS BioImagen Complutense.

1.2.1. Objetivo general

Desarrollar y evaluar un prototipo basado en técnicas de visión por computador e inteligencia artificial capaz de segmentar automáticamente, en imágenes de resonancia magnética preclínica, el área correspondiente al cerebro y las regiones afectadas por isquemia cerebral, proporcionando además información cuantitativa asociada a dichas segmentaciones e incorporando mecanismos de explicabilidad que faciliten la interpretación de los resultados obtenidos.

1.2.2. Objetivos específicos

Para alcanzar el objetivo general se han definido los siguientes objetivos específicos:

- O1.** Analizar el contexto biomédico del problema y el flujo de trabajo seguido en ICTS BioImagen Complutense para el análisis de imágenes de IRM preclínica asociadas a estudios de isquemia cerebral.
- O2.** Estudiar el proceso manual de segmentación del cerebro y de las regiones isquémicas, identificando sus principales limitaciones en términos de tiempo, reproducibilidad y dependencia del criterio del investigador.
- O3.** Investigar modelos y enfoques de inteligencia artificial aplicados a imagen médica, valorando tanto modelos existentes como la posibilidad de desarrollar un modelo propio adaptado al dominio de resonancia magnética preclínica en ratón.
- O4.** Organizar y preparar un conjunto de datos formado por imágenes reales de resonancia magnética, regiones de interés y máscaras binarias correspondientes a cerebro e isquemia cerebral.
- O5.** Diseñar un proceso de preprocesamiento que permita adaptar las imágenes originales al entrenamiento de modelos supervisados, incluyendo tareas de conversión de formatos, normalización, filtrado de cortes no informativos y ajuste dimensional.
- O6.** Estudiar y aplicar técnicas de aprendizaje por transferencia, utilizando pesos preentrenados en imagen médica, con el objetivo de mejorar el entrenamiento en un contexto de datos anotados limitados.
- O7.** Diseñar, entrenar y evaluar un primer modelo de segmentación basado en una arquitectura U-Net para delimitar automáticamente el área del cerebro en las imágenes de entrada.
- O8.** Diseñar, entrenar y evaluar un segundo modelo de segmentación basado en una arquitectura U-Net para identificar las regiones de isquemia cerebral presentes en las imágenes.

- O9.** Utilizar la segmentación del cerebro como información auxiliar para restringir el análisis de isquemia a la región anatómica relevante y reducir detecciones fuera del área cerebral.
- O10.** Implementar mecanismos de cuantificación que permitan calcular medidas derivadas de las segmentaciones obtenidas, especialmente el volumen del cerebro y el volumen de la región isquémica.
- O11.** Incorporar técnicas de inteligencia artificial explicable que permitan analizar visualmente qué regiones de la imagen influyen en las predicciones de los modelos y valorar si estas son coherentes con las zonas anatómicas o patológicas esperadas.
- O12.** Evaluar el rendimiento de ambos modelos mediante métricas cuantitativas de segmentación, análisis volumétrico y revisión visual de las predicciones generadas.
- O13.** Desarrollar un prototipo reproducible y accesible, organizado en notebooks, que pueda ser ejecutado y revisado por terceros sin requerir una infraestructura compleja.
- O14.** Valorar posibles líneas de ampliación futura, ofreciendo un primer desarrollo de un software que permita adaptar el entrenamiento a otros órganos y patologías.

1.3. Plan de trabajo

El desarrollo de este Trabajo de Fin de Grado se ha organizado de forma progresiva, partiendo de una fase inicial de comprensión del problema biomédico hasta la implementación y evaluación del sistema propuesto. Dado que el proyecto combina aspectos de ingeniería del software, procesamiento de imagen médica, aprendizaje automático y validación experimental, resultó necesario estructurar el trabajo en distintas fases claramente diferenciadas.

Además, al tratarse de un proyecto desarrollado en colaboración con el centro ICTS BioImagen Complutense, el plan de trabajo estuvo condicionado por las necesidades detectadas durante las reuniones de seguimiento y las visitas realizadas al centro. Estas sesiones permitieron orientar las decisiones técnicas hacia un caso de uso real, definir los requisitos funcionales de la herramienta y adaptar el desarrollo a las características del conjunto de datos disponible.

En los siguientes apartados se describe, en primer lugar, el proceso de seguimiento llevado a cabo mediante actas de reunión y, posteriormente, las principales fases de desarrollo seguidas hasta la obtención del prototipo final.

1.3.1. Seguimiento del proyecto y reuniones con los tutores

A lo largo del desarrollo del proyecto se mantuvo un proceso de seguimiento continuado mediante reuniones periódicas con los tutores, tanto de manera presencial como telemática. Con el objetivo de registrar la evolución del desarrollo y las decisiones tomadas, se realizaron actas de reunión después de cada encuentro.

Estas actas tuvieron un papel especialmente importante durante las primeras fases del proyecto, ya que permitieron documentar la definición inicial del problema, el contexto de la aplicación y las necesidades del usuario final. En particular, las reuniones con nuestro tutor David Castejón, como representante del entorno de uso real en ICTS BioImagen Complutense, permitieron establecer una comunicación continua entre la parte técnica del proyecto y la interpretación biomédica de los resultados. Esta interacción resultó clave para comprender qué salidas eran realmente útiles para los investigadores, cómo debían presentarse las segmentaciones y qué medidas cuantitativas aportaban valor dentro del flujo de trabajo habitual.

Durante las visitas al centro ICTS BioImagen Complutense, las actas permitieron recoger información esencial sobre el flujo de trabajo seguido por los investigadores. Se analizaron ejemplos reales de imágenes y se estudiaron diversas aplicaciones de las IRM tratadas en el centro. Además, se adquirieron nociones básicas sobre el funcionamiento físico de los equipos de resonancia magnética, aprendiendo a diferenciar zonas de hiperintensidad e hipointensidad, claves para la elaboración posterior del dataset y para la interpretación de las lesiones.

Las reuniones también permitieron revisar de forma continua las decisiones de diseño e implementación. En las primeras etapas se valoró el uso de modelos ya existentes para segmentación médica o segmentación general de imágenes. Sin embargo, tras analizar sus limitaciones en el contexto de imágenes de resonancia magnética preclínica de ratón, se decidió orientar el trabajo hacia el desarrollo y entrenamiento de modelos propios, adaptados al conjunto de datos disponible y a las necesidades concretas del caso de uso.

A medida que avanzó el desarrollo, se tomaron decisiones relacionadas con la estructura del conjunto de datos, la eliminación de cortes poco informativos, la preparación de los notebooks de entrenamiento y la mejora del modelo de segmentación de isquemia. En particular, se decidió utilizar la segmentación cerebral como paso previo para restringir el área de análisis del modelo de isquemia al tejido cerebral, con el objetivo de reducir falsos positivos y mejorar la coherencia anatómica de las predicciones.

El feedback proporcionado durante estas reuniones también influyó en aspectos prácticos del prototipo, como la necesidad de mostrar las segmentaciones de forma visual, calcular volúmenes en unidades interpretables, documentar los pasos de uso y facilitar la ejecución del sistema mediante notebooks en *Google Colab*. De este modo, el seguimiento del proyecto no se limitó a una supervisión académica, sino que permitió adaptar progresivamente la herramienta a las necesidades del usuario final.

1.3.2. Fases de desarrollo

El desarrollo del trabajo se ha organizado en varias fases. En primer lugar, se realizó una fase de comprensión del problema biomédico y definición funcional de la herramienta. Esta fase incluyó reuniones con los directores del trabajo y visitas al centro ICTS BioImagen Complutense, donde se estudió el proceso de adquisición de IRM, la generación de regiones de interés y la forma en la que los investigadores obtienen actualmente medidas cuantitativas a partir de las segmentaciones

manuales.

Posteriormente, se abordó una fase de investigación y análisis de alternativas. En esta etapa se revisaron modelos existentes de segmentación médica y segmentación general de imágenes, valorando su posible aplicación al caso de uso planteado. Sin embargo, las diferencias entre las imágenes médicas humanas empleadas habitualmente en muchos modelos preentrenados y las imágenes de resonancia magnética preclínica de ratón limitaron su aplicabilidad directa. Esta conclusión motivó el cambio de enfoque desde el uso de un modelo existente hacia el diseño y entrenamiento de modelos propios, manteniendo el apoyo del aprendizaje por transferencia como estrategia para aprovechar conocimiento visual previamente aprendido en imagen médica.

La siguiente fase consistió en la preparación del conjunto de datos. Se seleccionó como caso de estudio la segmentación de lesiones de isquemia cerebral, debido tanto a la disponibilidad de datos proporcionados por el ICTS BioImagen Complutense como a su relevancia dentro de las líneas de investigación actuales del centro. En esta etapa se llevó a cabo la organización de las imágenes, la adaptación de las máscaras, la conversión de formatos y el preprocesamiento necesario para que los datos pudieran ser utilizados en el entrenamiento de los modelos.

A continuación, se diseñó e implementó el pipeline de segmentación automática, compuesto por dos modelos: uno orientado a la segmentación del cerebro y otro a la segmentación de la lesión isquémica. El diseño del sistema se planteó de forma secuencial, de manera que la segmentación cerebral pudiera utilizarse como paso previo para restringir el análisis posterior de la lesión a la región anatómica relevante. Esta decisión responde tanto a criterios técnicos, al reducir posibles detecciones fuera del cerebro, como a criterios biomédicos, al hacer más coherente la salida del sistema.

De forma paralela al desarrollo de los modelos, se incorporó una fase de estudio e implementación de técnicas de explicabilidad. Esta fase tuvo como objetivo analizar si las regiones destacadas por los métodos de explicación coincidían con zonas relevantes para la predicción del modelo, especialmente en el caso de la isquemia. Con ello se buscó complementar la evaluación cuantitativa con una interpretación visual del comportamiento interno de los modelos.

Finalmente, se realizó la evaluación de los resultados obtenidos mediante métricas de segmentación, cuantificación volumétrica y análisis visual de las predicciones generadas. Esta evaluación permitió valorar tanto la precisión de las máscaras obtenidas como la utilidad práctica de la herramienta dentro del flujo de trabajo planteado por ICTS BioImagen Complutense.

1.4. Estructura de la memoria

La memoria se organiza de la siguiente forma. En el Capítulo 2 se presenta el estado de la cuestión, incluyendo los conceptos biomédicos necesarios, la visión por computador aplicada a imagen médica, las arquitecturas de segmentación, el aprendizaje por transferencia y la inteligencia artificial explicable. En el Capítulo 3 se describe la metodología seguida, desde la construcción del dataset y el preprocesamiento de imágenes hasta la arquitectura de los modelos, la cuantificación

volumétrica y la integración de explicabilidad. En el Capítulo 4 se presentan y discuten los resultados obtenidos para la segmentación cerebral y la segmentación de la región isquémica. Finalmente, el Capítulo 5 recoge las conclusiones del trabajo y las principales líneas de trabajo futuro.

Estado de la Cuestión

En este capítulo se presenta el contexto científico y tecnológico sobre el que se apoya el desarrollo de herramientas automáticas para el análisis de imágenes biomédicas. En primer lugar, se introducen los conceptos básicos necesarios para comprender la imagen por resonancia magnética en estudios preclínicos y el análisis de lesiones cerebrales. A continuación, se revisa el papel de la visión por computador en imagen médica, con especial atención a la segmentación como tarea orientada a delimitar regiones anatómicas o patológicas.

Posteriormente, se describen las arquitecturas de segmentación basadas en aprendizaje profundo, con énfasis en U-Net por su relevancia histórica y práctica en imagen biomédica. También se introduce el aprendizaje por transferencia como estrategia habitual cuando se dispone de conjuntos de datos anotados reducidos. Finalmente, se revisa el concepto de inteligencia artificial explicable, especialmente en modelos de imagen médica, donde no solo interesa obtener una predicción, sino también analizar si esta se apoya en regiones visualmente coherentes.

2.1. Conceptos biomédicos: IRM preclínica y lesiones cerebrales

La resonancia magnética es una técnica de adquisición de imagen ampliamente utilizada en investigación biomédica, ya que permite estudiar tejidos internos de forma no invasiva y con un alto contraste entre estructuras. En el ámbito preclínico, su uso es habitual en modelos animales, como ratones o ratas, con fines principalmente investigadores. A diferencia del contexto clínico, donde la imagen se orienta al diagnóstico o seguimiento de pacientes, en investigación preclínica las imágenes se utilizan para estudiar mecanismos biológicos, evaluar la evolución de una patología o analizar el efecto de tratamientos experimentales (Saito y Ueda, 2024; Universidad Complutense de Madrid, 2024).

En estudios cerebrales, la imagen por resonancia magnética permite observar cambios anatómicos y alteraciones tisulares asociadas a distintas patologías. Una de ellas es la isquemia cerebral, que se produce cuando una región del cerebro recibe un aporte insuficiente de sangre. Esta reducción del flujo sanguíneo puede causar daño

en el tejido afectado y desencadenar procesos de edema, es decir, acumulación de líquido, que modifican la señal observada en la imagen de resonancia. En secuencias ponderadas en T2, estas alteraciones suelen visualizarse como regiones hiperintensas, aunque sus límites pueden ser difusos debido a la transición gradual entre tejido sano y tejido dañado. Estas zonas se denominan habitualmente zonas de hiperintensidad y aparecen como áreas más blancas o brillantes en la imagen. (An et al., 2023; Čivrný et al., 2024; Veiga-Canuto et al., 2022)

Las imágenes de resonancia magnética suelen organizarse como una secuencia de cortes bidimensionales que, en conjunto, representan un volumen tridimensional del órgano estudiado. Cada píxel de un corte, o vóxel cuando se considera el volumen completo, contiene un valor de intensidad asociado a la señal registrada. La interpretación de estos valores depende de la modalidad de adquisición, del protocolo empleado y de las propiedades del tejido observado (Universidad Complutense de Madrid, 2024).

Para analizar estas imágenes es habitual delimitar regiones de interés, conocidas como ROI (Regions of Interest). Una ROI representa una zona concreta de la imagen que se desea estudiar, como puede ser el cerebro completo o una región lesionada. A partir de estas regiones es posible generar máscaras de segmentación, es decir, imágenes binarias en las que se separa la estructura de interés del fondo. Este proceso permite cuantificar de forma objetiva propiedades como el área o el volumen de una región anatómica o patológica.

La delimitación de estas regiones permite transformar una observación visual en información cuantitativa. A partir de una máscara es posible calcular medidas como el área ocupada por una lesión en un corte o el volumen total de una región cuando se consideran todos los cortes de la resonancia. Por ello, la segmentación de estructuras anatómicas y patológicas constituye una tarea clave en el análisis de imagen biomédica, especialmente cuando se busca comparar resultados entre diferentes modelos experimentales o la evolución temporal del daño en estudios longitudinales. (Litjens et al., 2017; Hesamian et al., 2019).

2.2. Visión por computador en imagen biomédica

La visión por computador es un campo de la inteligencia artificial orientada al desarrollo de métodos capaces de extraer información útil a partir de imágenes. Su objetivo es transformar datos visuales en información interpretable por un sistema informático. En el ámbito biomédico, esta transformación resulta especialmente relevante porque permite pasar de una imagen obtenida mediante una técnica de adquisición, como la resonancia magnética, a una representación que pueda apoyar tareas de análisis, cuantificación o seguimiento experimental (Litjens et al., 2017; Shen et al., 2017).

En una imagen digital, cada píxel contiene un valor numérico que representa una intensidad o una combinación de intensidades. En imágenes de resonancia magnética, estos valores no corresponden a colores reales, sino a la señal registrada por el equipo en función del tejido y de la secuencia de adquisición. Por ello, el análisis automático de IRM no consiste simplemente en detectar formas visibles, sino en interpretar

patrones de intensidad, contraste, textura y localización espacial que pueden tener significado biomédico (Litjens et al., 2017; Yamashita et al., 2018).

Las técnicas de visión por computador pueden emplearse en distintas etapas del análisis de imagen médica. Algunas se orientan al preprocesamiento, como la reducción de ruido, la normalización de intensidades o el realce de estructuras. Otras se centran en extraer información de mayor nivel, como la localización de una región anatómica, la detección de una alteración o la delimitación precisa de una zona de interés. Estas tareas requieren tener en cuenta que las imágenes biomédicas presentan características específicas: alta variabilidad entre adquisiciones, dependencia del protocolo empleado, bajo número de muestras disponibles y necesidad de interpretación por parte de expertos (Litjens et al., 2017; Hesamian et al., 2019).

Dentro del análisis automático de imágenes médicas pueden distinguirse varias tareas. La clasificación asigna una etiqueta global a una imagen o a un estudio completo. La detección localiza la presencia de una estructura o alteración mediante una región aproximada, como una caja delimitadora. La segmentación, en cambio, busca una delimitación más precisa, identificando los píxeles o vóxeles que pertenecen a una región concreta. En la Figura 2.1 se resume este flujo general, desde la imagen de entrada hasta la obtención de resultados visuales o cuantitativos.




Figura 2.1: Flujo general de análisis en imagen médica mediante técnicas de visión por computador. Fuente: elaboración propia.

Tradicionalmente, muchas técnicas de análisis de imagen se basaban en reglas definidas manualmente. Por ejemplo, se podían emplear umbrales de intensidad, filtros, detección de bordes u operaciones morfológicas para separar una estructura

del fondo o de otra región anatómica. Estos métodos pueden ser útiles cuando existe una diferencia clara entre la región de interés y el resto de la imagen. Sin embargo, en imágenes biomédicas esta separación no siempre es evidente, ya que las lesiones pueden presentar bordes difusos, cambios graduales de intensidad o una apariencia variable entre sujetos y protocolos (Litjens et al., 2017; Shen et al., 2017).

El aprendizaje automático introduce un cambio importante respecto a estos métodos clásicos. En lugar de definir manualmente todas las reglas de decisión, se entrena un modelo a partir de ejemplos. El sistema recibe datos de entrada y etiquetas o referencias asociadas, y ajusta sus parámetros para aprender una relación entre ambos. En tareas de imagen médica, estas referencias suelen proceder de anotaciones realizadas por expertos, como máscaras de segmentación o etiquetas diagnósticas (Goodfellow et al., 2016; Litjens et al., 2017).

Dentro del aprendizaje automático, las redes neuronales son modelos formados por capas de unidades computacionales conectadas entre sí. Cada unidad combina numéricamente sus entradas, aplica una transformación no lineal y transmite el resultado a la siguiente capa. Durante el entrenamiento, los pesos de estas conexiones se ajustan para reducir el error entre la salida del modelo y la referencia disponible. Esta estructura permite aprender relaciones complejas entre los datos de entrada y la salida esperada (Goodfellow et al., 2016; LeCun et al., 2015).

El aprendizaje profundo, o *deep learning*, se basa en redes neuronales con múltiples capas. La profundidad del modelo permite aprender representaciones jerárquicas: las primeras capas capturan patrones simples, mientras que las capas intermedias y profundas combinan esos patrones para representar estructuras más complejas. Esta idea ha sido especialmente importante en visión por computador, donde el aprendizaje profundo ha mejorado de forma notable el rendimiento en tareas como clasificación de imágenes, detección de objetos y segmentación (LeCun et al., 2015; Krizhevsky et al., 2012).

En imagen médica, las redes neuronales convolucionales, o CNN, han adquirido un papel central. Este tipo de red está diseñado para procesar datos con estructura espacial, como imágenes. Las convoluciones aplican filtros aprendibles sobre regiones locales de la imagen, lo que permite detectar patrones como bordes, texturas o cambios de intensidad. Además, al compartir los mismos filtros a lo largo de la imagen, las CNN reducen el número de parámetros respecto a una red completamente conectada y aprovechan mejor la organización espacial de los datos (Yamashita et al., 2018; Shen et al., 2017).

Esta capacidad resulta especialmente útil en resonancia magnética, donde la información relevante no depende solo del valor de intensidad de un píxel aislado, sino también de su relación con los píxeles vecinos y con la estructura anatómica en la que se encuentra. Por ejemplo, una zona hiperintensa puede interpretarse de forma distinta según su localización, su forma, su continuidad espacial o su relación con el tejido circundante. Las CNN permiten aprender este tipo de patrones espaciales directamente a partir de los datos (Litjens et al., 2017; Yamashita et al., 2018).

No obstante, el uso de redes profundas en imagen biomédica también presenta limitaciones. Estos modelos requieren datos anotados de calidad, pueden sobreajustarse cuando el conjunto de entrenamiento es reducido y no siempre resulta evidente qué información de la imagen están utilizando para generar una predicción. Estas

dificultades son especialmente relevantes en segmentación, donde la anotación no se limita a asignar una etiqueta global a la imagen, sino que exige delimitar con precisión la región de interés (Hesamian et al., 2019; Tajbakhsh et al., 2016).

Por este motivo, el desarrollo de herramientas de visión por computador en imagen médica no puede valorarse únicamente por la precisión de sus resultados. También es necesario analizar la coherencia de las predicciones, la estabilidad del modelo ante nuevos casos, la calidad de las anotaciones de referencia y la utilidad real de las salidas generadas para el usuario experto (Litjens et al., 2017; Zhang et al., 2023).

2.3. Arquitecturas de segmentación: U-Net

La arquitectura U-Net, propuesta originalmente por Ronneberger et al. en 2015, es una de las arquitecturas más influyentes en segmentación de imágenes biomédicas. Su importancia se debe a que fue diseñada específicamente para problemas donde es necesario obtener una predicción densa, es decir, una salida con una etiqueta para cada píxel de la imagen de entrada (Ronneberger et al., 2015).

U-Net presenta una estructura simétrica en forma de “U”, compuesta por un camino contractivo o *encoder* y un camino expansivo o *decoder*. Esta organización permite combinar dos tipos de información necesarios para segmentar correctamente: el contexto semántico, que ayuda a reconocer qué estructura aparece en la imagen, y la precisión espacial, necesaria para localizar sus bordes con detalle (Ronneberger et al., 2015; Shen et al., 2017).

El camino contractivo actúa como extractor jerárquico de características. En la formulación original de U-Net, este bloque aplica de forma repetida dos convoluciones de tamaño 3×3 , seguidas de funciones de activación ReLU, y una operación de reducción espacial mediante *max pooling* de tamaño 2×2 . A medida que disminuye la resolución espacial de los mapas de características, aumenta progresivamente el número de canales. Por ejemplo, una representación puede reducir su tamaño espacial de 128×128 píxeles a 64×64 píxeles, mientras que el número de canales puede aumentar de 32 a 64, después a 128 y posteriormente a 256 o 512. Este diseño amplía el campo receptivo de la red y favorece el aprendizaje de representaciones cada vez más abstractas (Ronneberger et al., 2015).

En las capas iniciales, la red captura detalles locales de alta frecuencia, como bordes, texturas y gradientes de intensidad. Estas características son relevantes en resonancia magnética, ya que ayudan a definir los límites inmediatos de una región de interés. Conforme aumenta la profundidad de la red, la resolución espacial disminuye y el campo receptivo efectivo aumenta, lo que permite representar patrones de mayor nivel. En esta etapa, el cuello de botella concentra la información semántica de la imagen, aunque esta representación se obtiene a costa de perder parte de la precisión espacial necesaria para localizar las estructuras con exactitud (Ronneberger et al., 2015; Shen et al., 2017).

El camino expansivo tiene como objetivo recuperar progresivamente la resolución espacial para reconstruir el mapa de segmentación final. Para ello, aumenta la resolución de los mapas de características hasta alcanzar el tamaño necesario para generar la máscara de salida. Sin embargo, el simple sobremuestreo de las caracterís-

ticas profundas puede producir contornos imprecisos, ya que parte de la información espacial fina se pierde durante las operaciones de reducción del *encoder*. Esta limitación se aborda mediante uno de los elementos más característicos de U-Net: las conexiones de salto o *skip connections* (Ronneberger et al., 2015).

Las *skip connections*, implementadas habitualmente mediante concatenación, permiten fusionar los mapas de características del *encoder* con los mapas sobremuestreados del *decoder* en niveles de resolución equivalentes. De esta forma, el *decoder* recibe simultáneamente información semántica procedente de capas profundas e información espacial de mayor resolución procedente de capas iniciales (Ronneberger et al., 2015).

De manera simplificada, si x_l representa la salida del nivel l del *encoder* e y_{l+1} representa la salida del nivel más profundo del *decoder*, la entrada del nivel correspondiente del *decoder* puede expresarse como:

$$\text{Input}_{\text{decoder},l} = \text{Concat}(\text{Up}(y_{l+1}), x_l)$$

donde $\text{Up}(\cdot)$ representa la operación de sobremuestreo y $\text{Concat}(\cdot)$ la concatenación de características. Esta combinación permite recuperar detalle espacial sin renunciar al contexto global aprendido por la red.

Como se muestra en la Figura 2.2, U-Net sigue una estructura encoder-decoder en la que las conexiones de salto permiten combinar información profunda con detalles espaciales de mayor resolución.




Figura 2.2: Ejemplo de arquitectura U-Net para segmentación de imágenes. Fuente: Mehrdad Yazdani, Wikimedia Commons, licencia CC BY-SA 4.0.

A partir de U-Net se han propuesto múltiples variantes, como U-Net++ o Attention U-Net, orientadas a mejorar la reutilización de características, introducir mecanismos de atención o incorporar bloques residuales (Zhou et al., 2018; Oktay et al., 2018). No obstante, la U-Net original sigue siendo una arquitectura de referencia en segmentación biomédica por su equilibrio entre rendimiento, claridad estructural y coste computacional.

2.4. Aprendizaje por transferencia (Transfer Learning)

El aprendizaje por transferencia consiste en reutilizar conocimiento aprendido por un modelo en una tarea o dominio de origen para mejorar el aprendizaje en una tarea o dominio de destino. En lugar de entrenar una red neuronal desde una inicialización aleatoria, se parte de pesos previamente aprendidos y se adaptan al nuevo problema (Pan y Yang, 2010; Yosinski et al., 2014).

Esta estrategia es especialmente útil cuando el conjunto de datos disponible para la tarea final es limitado. En aprendizaje profundo, los modelos con muchas capas y parámetros suelen necesitar grandes cantidades de datos para generalizar correctamente. Si se entrenan desde cero con pocos ejemplos, pueden ajustarse demasiado al conjunto de entrenamiento y reducir su rendimiento ante imágenes nuevas. Este fenómeno, conocido como sobreajuste, es una limitación frecuente en imagen biomédica, donde la obtención de datos anotados suele ser costosa y depende de expertos (Tajbakhsh et al., 2016; Hesamian et al., 2019).

El aprendizaje por transferencia puede aplicarse de distintas formas. Una opción consiste en utilizar el modelo preentrenado como extractor fijo de características, congelando sus capas y entrenando únicamente las capas finales adaptadas a la nueva tarea. Otra posibilidad es realizar un ajuste fino o *fine-tuning*, en el que parte de las capas preentrenadas se descongelan y se actualizan durante el entrenamiento con el nuevo conjunto de datos. La elección entre ambas estrategias depende del tamaño del dataset, la similitud entre el dominio de origen y el dominio de destino, y la complejidad de la tarea (Yosinski et al., 2014; Tajbakhsh et al., 2016).

En aplicaciones generales de visión por computador, muchos modelos se preentrenan sobre grandes conjuntos de imágenes naturales. Sin embargo, las imágenes naturales y las imágenes biomédicas presentan diferencias importantes. Las primeras suelen contener objetos cotidianos, escenas y texturas con colores y estructuras muy variadas, mientras que las imágenes biomédicas dependen de modalidades de adquisición específicas, presentan patrones de intensidad propios y requieren interpretar estructuras anatómicas o patológicas. Por ello, cuando es posible, resulta conveniente partir de modelos preentrenados en un dominio más próximo al biomédico (Tajbakhsh et al., 2016; Mei et al., 2022).

RadImageNet es un ejemplo de recurso orientado a este propósito, ya que proporciona pesos obtenidos a partir de imágenes médicas de distintas modalidades, como resonancia magnética, tomografía computarizada y ecografía (Mei et al., 2022). El uso de pesos preentrenados en imagen médica puede aportar una inicialización más adecuada que la obtenida exclusivamente a partir de imágenes naturales, especialmente cuando la tarea final también pertenece al dominio radiológico.

En arquitecturas encoder-decoder, como U-Net, el aprendizaje por transferencia suele aplicarse sustituyendo el *encoder* por una red preentrenada. En este esquema, el *encoder* actúa como extractor de características visuales y el *decoder* aprende a reconstruir la máscara de segmentación correspondiente. Esta combinación permite aprovechar representaciones previamente aprendidas y adaptarlas posteriormente a una tarea concreta de segmentación (Ronneberger et al., 2015; Tajbakhsh et al.,

2016; Mei et al., 2022).




Figura 2.3: Esquema general del aprendizaje por transferencia. Fuente: elaboración propia.

La Figura 2.3 resume este proceso. Un modelo previamente entrenado se reutiliza como punto de partida para una nueva tarea, aprovechando representaciones ya aprendidas y ajustándolas posteriormente al problema específico.

2.5. Explicabilidad en Inteligencia Artificial (XAI)

La Inteligencia Artificial Explicable, o XAI, agrupa métodos orientados a hacer más comprensible el comportamiento de los modelos de inteligencia artificial. Su objetivo no es únicamente mostrar el resultado de un modelo, sino aportar información sobre los factores que han influido en una predicción concreta. Esta cuestión es especialmente relevante en redes neuronales profundas, cuyo funcionamiento interno puede ser difícil de interpretar directamente debido al elevado número de parámetros y transformaciones no lineales que intervienen en el proceso (Barredo Arrieta et al., 2020; Samek et al., 2017b).

En imagen médica, la explicabilidad adquiere una importancia particular. Un modelo puede obtener buenas métricas globales y, aun así, basar algunas de sus predicciones en regiones irrelevantes, artefactos de adquisición o patrones espurios del conjunto de entrenamiento. Por ello, además de evaluar la precisión del modelo, resulta conveniente analizar si la información utilizada para producir la salida es coherente con el conocimiento del dominio (Samek et al., 2017b; Litjens et al., 2017).

Los métodos de XAI pueden clasificarse de distintas formas. Una distinción habitual diferencia entre explicaciones globales y explicaciones locales. Las explicaciones globales buscan describir el comportamiento general del modelo, mientras que las

locales se centran en justificar una predicción concreta. En análisis de imagen médica suelen emplearse explicaciones locales visuales, ya que permiten estudiar qué regiones de una imagen han influido más en una salida determinada (Barredo Arrieta et al., 2020).

Una forma habitual de generar estas explicaciones visuales es mediante mapas de relevancia o mapas de calor. Estos mapas asignan un valor de importancia a distintas zonas de la imagen, indicando qué regiones han contribuido en mayor medida a la predicción. En un contexto biomédico, esto permite comprobar si el modelo se apoya en zonas anatómica o patológicamente plausibles. Por ejemplo, ante la segmentación de una lesión, sería esperable que las regiones más relevantes se encuentren próximas a la zona lesionada y no en el fondo de la imagen o en elementos externos al tejido analizado (Samek et al., 2017b; Selvaraju et al., 2019).

Entre los métodos más utilizados en modelos de imagen se encuentran los mapas de saliencia, Integrated Gradients, Grad-CAM y Grad-CAM++. Los mapas de saliencia analizan la sensibilidad de la salida del modelo respecto a cambios en los píxeles de entrada. Integrated Gradients compara la imagen con una referencia o línea base y acumula la contribución de cada píxel a lo largo de una trayectoria entre ambas imágenes (Sundararajan et al., 2017). Grad-CAM, por su parte, utiliza los gradientes de una salida objetivo respecto a los mapas de características de una capa convolucional para generar una representación espacial de las regiones relevantes. Grad-CAM++ extiende esta idea mediante una ponderación más detallada de los gradientes, lo que puede mejorar la localización en determinados casos (Selvaraju et al., 2019; Chattopadhyay et al., 2018).

La explicabilidad no sustituye a métricas de evaluación como Dice o IoU. Estas métricas siguen siendo necesarias para medir el solapamiento entre la máscara predicha y la máscara de referencia. Sin embargo, no informan sobre los motivos por los que el modelo ha generado una predicción determinada. Los métodos de XAI aportan una perspectiva complementaria, centrada en analizar la coherencia visual del comportamiento del modelo y en detectar posibles fallos que no siempre son evidentes mediante métricas agregadas (Hesamian et al., 2019; Barredo Arrieta et al., 2020; Samek et al., 2017b).

La Figura 2.4 muestra el flujo general de aplicación de una técnica de explicabilidad visual. A partir de la imagen de entrada y de la salida del modelo, el método de XAI genera un mapa de relevancia que permite analizar qué regiones han influido más en la predicción.




Figura 2.4: Esquema general de aplicación de técnicas de explicabilidad visual. Fuente: elaboración propia.

Metodología y Desarrollo

3.1. Descripción del conjunto de datos (*Dataset*)

El conjunto de datos empleado está compuesto por imágenes de resonancia magnética nuclear (IRM) preclínicas de cerebros de ratón, obtenidas en el contexto de colaboración con el centro *ICTS BioImagen Complutense*. Estas imágenes constituyen la base para el entrenamiento y evaluación de los modelos de segmentación automática de la estructura cerebral y las lesiones asociadas, en este caso, la lesión por isquemia cerebral.

Tal y como se establece en los objetivos del proyecto, el dataset ha sido diseñado para permitir tanto la delimitación anatómica del cerebro como la identificación de regiones patológicas, lo que implica la coexistencia de dos tipos de anotaciones: segmentación de órgano sano y segmentación de lesión.

3.1.1. Estructura del dataset

El dataset presenta una estructura jerárquica, en la que cada caso de estudio se presenta en una carpeta individual con la denominación "*CASE n*". Para cada caso, se dispone de los siguientes elementos:

3.1.1.1. Volúmenes en formato NIfTI (.nii)

El formato **NIfTI** (*Neuroimaging Informatics Technology Initiative*) es el estándar en neuroimagen por su capacidad de almacenar datos volumétricos junto a metadatos asociados, como se describe en la documentación oficial estándar (Neuroimaging Informatics Technology Initiative, 2003) .

Además, se ha decidido usar NIfTI frente a otros formatos debido a que es uno de los estándares más utilizados en el ecosistema de procesamiento de imágenes médicas en Python, debido a su compatibilidad con librerías ampliamente empleadas como *nibabel*, que permiten la carga, manipulación y análisis de volúmenes de neuroimagen de forma eficiente (Neuroimaging Informatics Technology Initiative, 2003; NiBabel Developers, 2026a).

Su estructura interna está constituida por una matriz de datos tridimensionales,

en la cual cada voxel representa una medida de intensidad, la señal IRM. Además, en su cabecera se almacenan metadatos críticos para el estudio de cada sujeto, entre los cuales la resolución espacial (tamaño del voxel), necesario para calcular los volúmenes de una región de la imagen, orientación, el tipo de dato (en nuestro caso `\int16`) y el identificador del sujeto y de estudio.

Cada uno de estos archivos, facilitados por el centro *ICTS BioImagen Complutense*, contienen 28 *slices*.¹

3.1.1.2. Region of Interest (.ROI)

Las **ROI** (Region Of Interest) son una herramienta estándar en análisis de imagen médica para delimitar estructuras anatómicas o patológicas relevantes (Neuroimaging Informatics Technology Initiative, 2003). Se tratan de anotaciones geométricas representadas como contornos que aíslan la región de estudio, delimitando su extensión espacial. Estas selecciones se realizan para cada una de las slices o cortes anatómicos de la IRM, definiendo así la estructura anatómica de la característica de estudio. Para cada caso de estudio, se cuenta con dos conjuntos de datos ROI, el conjunto de selección del cerebro y el conjunto de selección de la isquemia cerebral. Cabe destacar que, especialmente en el caso de la isquemia, las ROI presentan bordes difusos, regiones de transición (gradientes de intensidad) y variabilidad interobservador de la medida.

3.1.1.3. Máscaras de segmentación (.png)

Las máscaras son la representación final utilizada en el entrenamiento supervisado. Estas máscaras consisten en imágenes 2D binarias en las que se representan con los valores 0 (color negro) el fondo y 255 (color blanco) la región de selección. Estas máscaras son producidas a partir de las selecciones ROI, respetando su tamaño y alineación, y constituyen el *ground truth* del entrenamiento. Se opta por trabajar con slices bidimensionales en lugar de volúmenes tridimensionales completos debido a la reducción del coste computacional y a la disponibilidad de arquitecturas preentrenadas en 2D.

3.1.2. Tamaño de dataset

El conjunto de datos utilizado está compuesto por un total de 30 casos de estudio. Estos incluyen imágenes de resonancia magnética correspondientes a lesiones cerebrales de tipo isquémico, tanto transitorias como permanentes, adquiridas en dos instantes temporales distintos: 4 horas y 24 horas tras la inducción de la lesión. Esta configuración permite analizar la evolución temporal del daño cerebral, abarcando desde fases tempranas hasta estados más avanzados, así como distintos grados de reversibilidad del tejido afectado. (Pradillo et al., 2022)

¹Las *slice* son cortes bidimensionales que muestran una sección anatómica del cerebro, los cuales son utilizados para analizar el órgano y la lesión, así como para calcular posteriormente su volumen en base al tamaño de Voxel definido.

Adicionalmente, se han incorporado casos de control sin presencia de lesión, con el objetivo de mejorar la capacidad del modelo para discriminar entre tejido sano y patológico, contribuyendo así a una mayor robustez en la clasificación y segmentación.

Pese a que cada uno de estos 30 casos cuenta con un total de 28 slices, se han descartado los 2 primeros y el último corte de cada resonancia. Esto se debe a la baja calidad de la señal en estos cortes, donde la presencia de ruido y artefactos compromete la fiabilidad de las anotaciones y puede introducir sesgos en el entrenamiento del modelo. Tras la depuración de los datos iniciales, se cuenta con un total de 750 imágenes bidimensionales utilizadas como entrada del modelo.

Para cada una de estas slices, se dispone de anotaciones manuales en forma de máscaras binarias correspondientes a dos tareas de segmentación: cerebro e isquemia. En el caso de la segmentación cerebral, esto supone un total de **750 máscaras de *ground truth***.² Para la segmentación de la zona isquémica, el número de máscaras efectivas es menor ya que únicamente están presentes en aquellos casos donde existe lesión. Como media, se cuenta con 9 máscaras de selección del daño isquémico por sujeto.

En conjunto, considerando ambas tareas, el dataset incluye más de 1.000 anotaciones de *ground truth*, lo que proporciona un volumen significativo de datos etiquetados a nivel de píxel para el entrenamiento supervisado del modelo.

Número de casos	30
Cortes por caso	28 (25 utilizados)
Imágenes totales	750
Máscaras cerebro	750
Máscaras isquemia (media)	~270
Resolución	120 × 120 píxeles

Tabla 3.1: Resumen del dataset utilizado

La resolución indicada corresponde al número de píxeles en los que se divide el campo de visión, o *Field of View* (FOV), de cada imagen.

3.2. Preprocesamiento de imágenes

El preprocesamiento de imágenes constituye una etapa crítica en el pipeline de entrenamiento, ya que garantiza la homogeneidad de los datos de entrada y mejora la estabilidad del modelo. Para obtener los datos necesarios para formar el dataset, el procesamiento ha sido realizado por los alumnos bajo las directrices y supervisión de los profesionales del *ICTS BioImagen Complutense*.

El procesamiento de las imágenes, desde la IRM en formato RAW (**.bruker**³)

²En este contexto, el término *ground truth* hace referencia a las máscaras obtenidas a partir de anotaciones manuales, utilizadas como referencia para entrenar y evaluar los modelos de segmentación.

³Formato de datos generado por equipos de resonancia magnética de la compañía Bruker, utilizado para almacenar los datos originales adquiridos durante el estudio.

hasta el dataset final usado para el entrenamiento, se describe con el siguiente pipeline:



Figura 3.1: Pipeline de procesamiento desde datos RAW hasta el dataset final. Fuente: elaboración propia.

3.2.1. Conversión de datos RAW a formato NIfTI

Las imágenes originales son adquiridas en formato propietario del fabricante del escáner utilizado (`.bruker`), el cual contiene tanto la señal de resonancia magnética como información específica del dispositivo. Sin embargo, este formato no es directamente compatible con las herramientas estándar de procesamiento de imagen médica ni con los frameworks de aprendizaje profundo.

Por este motivo, se realiza una conversión a formato NIfTI, el cual permite trabajar con los datos de manera más flexible, amplia y estándar.

Durante este proceso, se preserva la información tridimensional original, así como los parámetros necesarios para el análisis cuantitativo posterior.

Para la realización de este proceso, así como de las etapas posteriores de segmentación manual, se ha empleado el software *MRI File Manager*⁴, una herramienta de código abierto para la gestión y conversión de datos de resonancia magnética. Asimismo, para la correcta utilización del software y la comprensión del flujo de procesado de imágenes, se ha estudiado el manual proporcionado por la Universidad Complutense de Madrid sobre el tratamiento de imágenes de resonancia magnética mediante *ImageJ*. (Universidad Complutense de Madrid, 2024).




Figura 3.2: Ejemplo de slices de IRM. Fuente: elaboración propia.

3.2.2. Segmentación manual mediante ROI

Una vez transformado el Dataset al formato NIfTI, se procede a la segmentación manual de las estructuras de interés mediante la definición de regiones de interés (ROI). Este proceso ha sido realizado utilizando las herramientas *MRIFileManager*

⁴Software disponible en: https://populse.github.io/mri_conv/Home/index.html

junto con la librería *ImageJ*, siguiendo el manual de uso y bajo la supervisión de expertos del centro ICTS BioImagen Complutense.

Las ROI se definen como contornos sobre cada *slice*, delimitando tanto el cerebro completo como las regiones afectadas por la isquemia. Este proceso requiere una interpretación visual experta, especialmente en el caso de las lesiones isquémicas, donde los bordes no están claramente definidos y existen gradientes de intensidad. Como consecuencia, las segmentaciones presentan un cierto grado de subjetividad, lo cual constituye una limitación inherente al problema abordado.




Figura 3.3: Ejemplo de segmentación ROI. Fuente: elaboración propia.

3.2.3. Generación de máscaras binarias

A partir de las anotaciones ROI, se generan máscaras binarias que representan la información de segmentación en un formato adecuado para el entrenamiento supervisado.

Este proceso ha sido implementado mediante un script específico desarrollado en Python, que permite transformar las regiones definidas por contornos en imágenes discretas binarias alineadas con las slices originales. En estas máscaras, cada píxel se etiqueta como fondo (valor 0) o región de interés (valor 255), garantizando la correspondencia espacial con la imagen de entrada.

Con el objetivo de mejorar la reproducibilidad del proceso, la lógica general del script se resume en el Algoritmo 1. El procedimiento parte de los archivos ROI exportados desde ImageJ, almacenados en archivos comprimidos independientes para cada tipo de segmentación. Para cada ROI, se extraen las coordenadas del contorno y se reescalan al tamaño de entrada utilizado por el modelo, fijado en 120×120 píxeles. A continuación, se genera una imagen vacía en escala de grises y se rasteriza el polígono correspondiente, asignando valor 255 a los píxeles incluidos dentro de la región de interés y valor 0 al fondo.




Figura 3.4: Ejemplo de máscara binaria. Fuente: elaboración propia.

Una decisión relevante en este proceso es que el ajuste de escala se aplica sobre las coordenadas del contorno antes de generar la máscara, en lugar de redimensionar directamente una máscara binaria ya rasterizada. De este modo, se evita introducir valores intermedios en los bordes de la lesión, algo que podría ocurrir si se aplicasen interpolaciones continuas sobre una imagen binaria. Esta estrategia permite conservar la naturaleza discreta de la segmentación y mantener una correspondencia espacial coherente entre la imagen de entrada y su máscara asociada.

Algorithm 1 Generación de máscaras binarias a partir de anotaciones ROI

Require: Carpeta del caso, archivos `cerebro.zip` e `isquemia.zip`, tamaño de salida $W = H = 120$

Ensure: Máscaras binarias en formato PNG alineadas con las slices originales

- 1: **for** cada archivo ZIP de anotaciones **do**
- 2: Crear carpeta de salida asociada al tipo de segmentación
- 3: Extraer temporalmente los ficheros `.roi`
- 4: **for** cada fichero ROI **do**
- 5: Leer el ROI y obtener las coordenadas del contorno
- 6: Reescalar cada punto del contorno al tamaño 120×120 :

$$x' = x \cdot \frac{W}{W_{ROI}}, \quad y' = y \cdot \frac{H}{H_{ROI}}$$

- 7: Crear una máscara vacía de tamaño 120×120 con valor 0
 - 8: Dibujar y rellenar el polígono reescalado con valor 255
 - 9: Guardar la máscara resultante en formato PNG
 - 10: **end for**
 - 11: **end for**
-

Este paso es crítico para asegurar la coherencia dimensional del dataset y su compatibilidad con la arquitectura de la red neuronal empleada. Todas las imágenes y máscaras utilizadas durante el entrenamiento se normalizan a una resolución uniforme de 120×120 píxeles, lo que permite trabajar con tensores de entrada homogéneos y simplifica el procesamiento posterior dentro del pipeline de entrenamiento.

El desarrollo de esta herramienta ha permitido automatizar el proceso de generación de *ground truth*, asegurando la consistencia del dataset y reduciendo posibles errores derivados de la intervención manual. Asimismo, facilita la reutilización del pipeline por parte de usuarios con menor experiencia técnica, permitiendo la generación de nuevos conjuntos de entrenamiento y el reentrenamiento de los modelos de forma más accesible.

3.2.4. Normalización y adaptación de las imágenes

Con el objetivo de garantizar la homogeneidad de los datos de entrada, las imágenes y sus máscaras son sometidas a un proceso de adaptación previo al entrenamiento.

En primer lugar, todas las imágenes son redimensionadas a una resolución de 120×120 píxeles, correspondiente al tamaño de entrada definido para la arquitectura de la red neuronal empleada. Esta decisión permite trabajar con tensores de tamaño uniforme y reduce el coste computacional del entrenamiento, aunque también implica una pérdida potencial de detalle espacial en estructuras pequeñas.

Durante este proceso se aplica interpolación sobre las imágenes de resonancia, lo que puede introducir suavizado en los bordes y pérdida de detalle en regiones de pequeño tamaño (Lehmann et al., 1999). En el caso de las máscaras binarias, se evita aplicar interpolación continua, empleando una estrategia de vecino más cercano para preservar la naturaleza discreta de las etiquetas y evitar la aparición de valores intermedios entre fondo y región de interés.

Asimismo, las intensidades de las imágenes, originalmente almacenadas en formato entero (`int16`), se convierten a formato de coma flotante (`float32`) y se normalizan al rango $[0, 1]$. En este trabajo se ha aplicado una normalización *Min-Max* por volumen, es decir, cada resonancia se normaliza de forma independiente utilizando sus propios valores mínimo y máximo de intensidad:

$$I_{\text{norm}} = \frac{I - I_{\text{mín}}}{I_{\text{máx}} - I_{\text{mín}} + \epsilon}$$

donde I representa la intensidad original, $I_{\text{mín}}$ e $I_{\text{máx}}$ son los valores mínimo y máximo del volumen correspondiente, y ϵ es un término pequeño añadido para evitar divisiones por cero. Esta estrategia permite reducir la variabilidad de escala entre adquisiciones y facilita la estabilidad numérica durante el entrenamiento.

No obstante, esta normalización no elimina por completo las diferencias asociadas a distintas secuencias o protocolos de adquisición de IRM, ya que las intensidades en resonancia magnética no están estandarizadas de forma absoluta. Por ello, el entrenamiento y la evaluación del modelo deben interpretarse dentro del contexto de las imágenes disponibles y de su modalidad concreta. Técnicas alternativas, como la normalización global del conjunto de datos o la normalización Z-score por paciente, podrían explorarse en trabajos futuros si se amplía el dataset o se incorporan secuencias de IRM más heterogéneas.

Por último, tanto las máscaras de entrenamiento como las slices de la IRM se orientan y se visualizan mediante una superposición para comprobar que existe una alineación correcta entre la imagen anatómica y la región segmentada. Esta

comprobación visual permite detectar posibles errores de correspondencia espacial antes del entrenamiento del modelo.




Figura 3.5: Visualización de superposición entre la slice de resonancia magnética y su máscara de segmentación correspondiente. Fuente: elaboración propia.

3.2.5. Estrategia de particionado y control de fuga de datos

Dado que cada resonancia magnética está formada por una secuencia de cortes bidimensionales pertenecientes al mismo sujeto, la unidad de independencia considerada en este trabajo no es el corte individual, sino el caso completo. Esta decisión es especialmente relevante en imagen médica, ya que los cortes consecutivos de una misma adquisición presentan una alta dependencia espacial y anatómica. Por tanto, si distintos cortes de un mismo caso apareciesen simultáneamente en entrenamiento, validación y prueba, se produciría una fuga de información entre subconjuntos que podría sobreestimar el rendimiento real del modelo.

Para evitar este problema, el particionado del conjunto de datos se realizó a nivel de caso. Es decir, todos los cortes y sus correspondientes máscaras asociados a una misma resonancia se asignaron exclusivamente a uno de los subconjuntos: entrenamiento, validación o prueba. El conjunto de entrenamiento se empleó para ajustar los pesos de los modelos y el conjunto de prueba se reservó para monitorizar el aprendizaje y seleccionar decisiones de configuración, como el umbral de binarización de la salida, y para la evaluación final.

En particular, el conjunto de prueba estuvo formado por tres casos completos que no fueron utilizados durante el entrenamiento ni durante la validación. Esta separación permite evaluar el comportamiento del sistema sobre sujetos no vistos previamente, proporcionando una estimación más realista de su capacidad de generalización. No obstante, debido al reducido número de casos disponibles, los resultados deben interpretarse como una evaluación preliminar del prototipo y no como una validación estadística exhaustiva.

Subconjunto	Nº de casos	Uso principal
Entrenamiento	27	Ajuste de pesos del modelo
Prueba	3	Evaluación final sobre casos no vistos

Tabla 3.2: Particionado del conjunto de datos a nivel de caso. Todos los cortes de una misma resonancia se asignan a un único subconjunto para evitar fuga de información entre entrenamiento y prueba.

3.3. Arquitectura de los modelos y *Transfer Learning*

Tras realizar un preprocesamiento de las imágenes para su uso en el entrenamiento, procedemos a definir la arquitectura a alto nivel de la aplicación de segmentación automática. En el caso de estudio que nos presenta ICTS BioImagen Complutense, se requiere la automatización de la medición de volúmenes de la lesión isquémica en el cerebro, además de la afectación en este órgano; por lo que es necesaria la segmentación automática por separado del órgano y de la lesión.

Para esta tarea, se utiliza la arquitectura U-Net para crear dos modelos, entrenados con las mismas imágenes pero con distintas máscaras binarias. Aunque existen múltiples variantes de U-Net, como U-Net++, Attention U-Net o ResUNet, se decide usar U-Net como estructura básica, teniendo en cuenta ventajas e inconvenientes relacionados con la complejidad técnica, la capacidad del modelo y el coste computacional, que se expondrán más adelante en esta sección.

Debido al bajo número de datos disponibles, habitual en el ámbito biomédico, se aplica además *Transfer Learning*, una técnica de *Deep Learning* que permite reutilizar pesos previamente aprendidos por otros modelos para adaptarlos a una tarea más concreta. Para ello, se emplean pesos de *RadImageNet*, un modelo preentrenado con IRM, TAC y ecografía. (Pan y Yang, 2010; Mei et al., 2022).

Tras los primeros entrenamientos, se observó una tendencia a la sobresegmentación en el modelo de isquemia. Para mitigar este problema, se probaron varias estrategias, como el cambio de la función de pérdida para penalizar los falsos positivos. Finalmente, se optó por ajustar el umbral de binarización de la salida probabilística del modelo. La comparación cuantitativa de los distintos umbrales se presenta en el capítulo de resultados.

Además, se contempla la aplicación de técnicas de Inteligencia Artificial Explicable para proporcionar robustez al análisis, verificar que el modelo basa sus predicciones en regiones anatómica y patológicamente relevantes, y mejorar la confianza en los resultados obtenidos.

3.3.1. Arquitectura U-Net y decisiones de implementación

La arquitectura principal empleada en este trabajo para la segmentación automática se basa en una U-Net 2D, la cual se repite en los dos modelos desarrollados (cerebro e isquemia). En nuestro caso, esta arquitectura se adaptó para trabajar con cortes bidimensionales de resonancia magnética preclínica, de manera que cada muestra de entrada se representa como una imagen en escala de grises redimensionada a 120×120 píxeles. Además, dado que el encoder seleccionado requiere tres canales de entrada, cada imagen monocanal se replicó tres veces antes de ser introducida en la red.

A nivel estructural, la red mantiene el esquema clásico encoder-decoder característico de U-Net. En la rama contractiva, el encoder **ResNet50** actúa como extractor jerárquico de características, generando representaciones cada vez más abstractas de la imagen de entrada conforme aumenta la profundidad de la red. A su vez, a

partir del encoder se obtienen varios mapas de características intermedios que posteriormente se reutilizan en el decoder a través de conexiones de salto, preservando así información espacial de alta resolución, necesaria para obtener una segmentación precisa (Ronneberger et al., 2015). En la rama expansiva, la máscara de salida se reconstruye mediante varias etapas sucesivas de sobremuestreo y concatenación con estos mapas intermedios.

En la implementación del decoder se optó por una estrategia de sobremuestreo mediante **UpSampling2D** seguida de convoluciones convencionales, en lugar de utilizar convoluciones transpuestas. Esta decisión permite separar el aumento de resolución del refinamiento de características y ayuda a reducir la aparición de artefactos tipo *checkerboard*⁵, asociados a ciertas configuraciones de deconvolución (Odena et al., 2016).

En cuanto a la salida del modelo, esta se obtiene mediante una convolución 1×1 con activación sigmoideal, lo que permite generar una máscara binaria de probabilidad por píxel para la clase objetivo. Esta formulación es coherente con el problema planteado, ya que tanto la segmentación del cerebro como la de la lesión se modelan como tareas de segmentación binaria, donde cada píxel debe clasificarse como perteneciente o no a la región de interés.

Como se muestra en la Figura 3.6, ambos modelos comparten la misma arquitectura base, diferenciándose únicamente en la máscara objetivo empleada durante el entrenamiento: uno orientado a la segmentación del cerebro y el otro hacia la segmentación de la lesión isquémica. La figura muestra la entrada de tamaño $120 \times 120 \times 3$, el encoder **ResNet50** preentrenado sobre *RadImageNet*, las conexiones de salto, el decoder basado en **UpSampling2D** y convoluciones, y la generación de la máscara binaria de salida. Esta misma arquitectura base se utiliza tanto para el modelo de segmentación de cerebro como para el de segmentación de isquemia, diferenciándose únicamente en la máscara objetivo empleada durante el entrenamiento.




Figura 3.6: Esquema de la arquitectura U-Net 2D empleada en este trabajo. Fuente: elaboración propia.

3.3.2. Justificación de la arquitectura y uso de *Transfer Learning*

Aunque existen variantes más complejas de esta arquitectura, como U-Net++ (Zhou et al., 2018) o Attention U-Net (Oktay et al., 2018), se decide utilizar U-Net como estructura base del sistema. Esta elección se toma teniendo en cuenta

⁵Los artefactos *checkerboard* son patrones visuales no deseados con apariencia de cuadrícula o tablero de ajedrez, que pueden aparecer en imágenes generadas o reconstruidas mediante ciertas operaciones de convolución transpuesta.

que, aunque estas variantes introducen mejoras interesantes a nivel arquitectónico, también aumentan la complejidad del modelo y el número de elementos a ajustar durante el entrenamiento. En este caso, al trabajar con un conjunto de datos reducido y dentro del alcance de un TFG, resulta más razonable partir de una arquitectura ya consolidada en segmentación biomédica, suficientemente robusta y más sencilla de controlar experimentalmente (Ronneberger et al., 2015). De este modo, en lugar de añadir complejidad desde la propia arquitectura, se opta por mantener una U-Net base y reforzarla mediante *Transfer Learning*, buscando así un equilibrio entre capacidad de segmentación, coste computacional y facilidad de implementación.

De esta manera se opta por aplicar *Transfer Learning*: una técnica de *Deep Learning* especialmente útil cuando no se dispone de un conjunto de entrenamiento lo suficientemente grande como para entrenar un modelo profundo desde cero. Para ello, se incorporó un encoder **ResNet50** preentrenado con pesos de *RadImageNet*, con el objetivo de partir de una base de conocimiento visual ya aprendida en imagen médica, en lugar de comenzar con una inicialización aleatoria de los pesos.

La elección de **ResNet50** responde a un compromiso entre capacidad de representación, coste computacional y estabilidad del entrenamiento. Frente a backbones más ligeros, como *MobileNet*, **ResNet50** ofrece una mayor capacidad para extraer características jerárquicas complejas, algo relevante en tareas de segmentación biomédica donde las diferencias de intensidad y textura pueden ser sutiles. Por otro lado, se evitó recurrir a arquitecturas más profundas o más complejas, ya que el tamaño reducido del conjunto de datos y la resolución de entrada empleada, de 120×120 píxeles, podían aumentar el riesgo de sobreajuste y el coste de entrenamiento sin garantizar una mejora proporcional en el rendimiento.

Además, **ResNet50** cuenta con una arquitectura residual consolidada, que facilita el entrenamiento de redes profundas mediante conexiones de salto (He et al., 2016). En este trabajo, su uso resulta especialmente adecuado porque existen pesos preentrenados en *RadImageNet*, un conjunto de datos radiológico que permite transferir representaciones visuales más cercanas al dominio biomédico que las aprendidas exclusivamente sobre imágenes naturales. Esta decisión está respaldada por el trabajo de (Mei et al., 2022), donde se muestra que los modelos preentrenados en *RadImageNet* pueden servir como un punto de partida eficaz para tareas posteriores de imagen biomédica. De este modo, la U-Net implementada no parte de un encoder entrenado desde cero, sino de un backbone previamente adaptado al dominio radiológico, lo que refuerza la justificación de esta elección.

En este contexto, se consideró el uso de técnicas de aumento de datos (*data augmentation*) como estrategia para mejorar la capacidad de generalización de los modelos. Entre las transformaciones más relevantes para este tipo de imágenes se encuentran pequeñas rotaciones, desplazamientos espaciales, variaciones moderadas de contraste o intensidad y ligeras transformaciones geométricas que no alteren la coherencia anatómica de la imagen ni la correspondencia con las máscaras de segmentación.

No obstante, en este trabajo se priorizó una estrategia basada en *transfer learning*, manteniendo el aumento de datos como una línea de mejora futura. Esta decisión se tomó para evitar introducir transformaciones que pudieran modificar de forma no controlada la apariencia de estructuras anatómicas pequeñas o de bor-

des difusos, especialmente en el caso de la lesión isquémica. Por tanto, aunque el *data augmentation* no forma parte de la configuración final, se considera una extensión natural del sistema para futuros entrenamientos con el objetivo de mejorar la robustez del modelo ante variaciones de orientación, intensidad y adquisición.

En conjunto, estas decisiones responden a una misma necesidad: disponer de un modelo con suficiente capacidad de representación para segmentar estructuras biomédicas complejas, pero que al mismo tiempo pueda entrenarse de forma estable en un contexto de datos limitados, por lo que el uso de *Transfer Learning* resulta una estrategia adecuada para alcanzar este objetivo.

3.3.3. Estrategia de entrenamiento y ajuste de la salida

Para el proceso de entrenamiento, se siguió una estrategia en dos fases: en una primera etapa, el encoder preentrenado permaneció congelado y únicamente se entrenó la parte decodificadora de la red, de forma que el modelo pudiera adaptarse a la tarea concreta sin modificar las representaciones aprendidas previamente. En una segunda etapa, se descongelaron las últimas capas del encoder para realizar un ajuste fino controlado del modelo completo. Con ello se buscó mantener el conocimiento transferido desde el preentrenamiento, permitiendo al mismo tiempo cierta especialización del extractor de características al dominio concreto de la imagen de IRM.

La función de pérdida seleccionada fue una combinación de entropía cruzada binaria y pérdida Dice (`BCE + Dice loss`). Esta elección se tomó debido a que permite optimizar simultáneamente dos aspectos importantes de la segmentación: por un lado, la clasificación correcta de cada píxel de forma individual y, por otro lado, el grado de solapamiento global entre la máscara predicha y la máscara de referencia.

Mientras que la componente BCE penaliza errores locales de clasificación, la componente Dice resulta especialmente útil en segmentación médica cuando existe un claro desbalance entre fondo y región objetivo, como ocurre con frecuencia en la delimitación de lesiones pequeñas (Milletari et al., 2016). Como métrica principal de seguimiento durante el entrenamiento se utilizó el coeficiente Dice, por ofrecer una medida directa del grado de coincidencia entre la segmentación automática y la segmentación manual.

A nivel de configuración, el entrenamiento se realizó con el optimizador Adam y un tamaño de lote de 4. En la primera fase se utilizó una tasa de aprendizaje de 10^{-4} , que posteriormente se redujo a 10^{-5} durante la fase de ajuste fino del encoder. En total, el entrenamiento quedó estructurado en 25 épocas con el encoder congelado y 10 épocas adicionales de *fine-tuning*, incorporando además una partición de validación para monitorizar la evolución del modelo y seleccionar configuraciones estables.

Tras los primeros experimentos con el modelo de isquemia, se observó que el umbral de binarización influía de forma directa tanto en la calidad espacial de la segmentación como en la precisión de la cuantificación volumétrica. Por ello, durante la fase de validación se evaluaron distintos valores de umbral, con el objetivo de seleccionar una configuración adecuada para la inferencia final.

Tabla 3.3: Configuración general del entrenamiento de los modelos de segmentación.

Parámetro	Valor
Arquitectura base	U-Net 2D con encoder ResNet50
Tamaño de entrada	$120 \times 120 \times 3$
Optimizador	Adam
Tamaño de lote	4
Función de pérdida	BCE + Dice Loss
Métrica principal	Coficiente Dice
Tasa de aprendizaje (fase 1)	10^{-4}
Tasa de aprendizaje (fase 2)	10^{-5}
Épocas con encoder congelado	25
Épocas de <i>fine-tuning</i>	10
Salida del modelo	Máscara probabilística con activación sigmoideal

Este ajuste se consideró especialmente relevante en el modelo de isquemia, ya que la lesión ocupa una región reducida respecto al fondo y el modelo puede generar falsos positivos en zonas de baja probabilidad. En cambio, en el modelo de segmentación cerebral no se introdujo un ajuste específico del umbral, al tratarse de una estructura anatómica de mayor tamaño y con una segmentación más estable.

Finalmente, para el modelo de isquemia se adoptó un umbral de binarización de 0,80 en la fase de inferencia. La comparación cuantitativa de los umbrales evaluados, así como la justificación experimental del valor finalmente seleccionado, se presentan en el capítulo de resultados.

3.4. Cuantificación y métricas biomédicas (volumen)

La segmentación automática proporciona una delimitación espacial del cerebro y de la lesión isquémica. Sin embargo, para que esta salida sea útil en un contexto de investigación biomédica, es necesario transformarla en magnitudes cuantitativas que permitan comparar casos y evaluar diferencias entre segmentaciones manuales y automáticas.

En este trabajo, la métrica cuantitativa principal es el volumen de las regiones segmentadas. Esta magnitud permite estimar la extensión del órgano y de la lesión, facilitando el análisis posterior de los casos estudiados. En el ámbito de la imagen cerebral, y en particular en estudios de ictus, el volumen lesional se utiliza habitualmente como una medida relevante para caracterizar la afectación observada en resonancia magnética (Harston et al., 2015; Ospel et al., 2024).

Para realizar esta cuantificación, se toma como entrada la salida del *pipeline* de segmentación. Dicha salida consiste en una máscara binaria asociada a cada corte de la resonancia magnética, donde los píxeles con valor positivo representan la región segmentada y el resto corresponde al fondo o a zonas no incluidas en la segmentación.

Dado que las imágenes médicas se almacenan en formato NIfTI, el volumen no se calcula únicamente a partir del número de píxeles segmentados, sino teniendo en cuenta la información espacial de la imagen. En este formato, el campo `pixdim`

codifica el espaciado físico de la rejilla en cada dimensión, mientras que la información *affine* (*sform/qform*) permite representar la geometría espacial asociada a la imagen (Neuroimaging Informatics Technology Initiative, 2005; NiBabel Developers, 2026b). De este modo, si N representa el número total de vóxeles segmentados, y s_x , s_y y s_z representan el tamaño físico del vóxel en cada una de las tres dimensiones espaciales, el volumen total puede expresarse como:

$$V = N \cdot s_x \cdot s_y \cdot s_z \quad (3.1)$$

donde:

- V es el volumen total de la región segmentada,
- N es el número total de vóxeles clasificados como pertenecientes al órgano o a la lesión,
- s_x y s_y corresponden a la resolución espacial en el plano de la imagen,
- s_z corresponde al espesor del corte, expresado en unidades físicas.

En la práctica, como la segmentación se obtiene corte a corte, el cálculo también puede formularse como la suma del volumen parcial aportado por cada corte. Si A_i representa el área segmentada en el corte i , el volumen total se obtiene como:

$$V = \sum_{i=1}^n A_i \cdot s_z \quad (3.2)$$

siendo n el número total de cortes segmentados. A su vez, el área segmentada en cada corte puede calcularse como:

$$A_i = N_i \cdot s_x \cdot s_y \quad (3.3)$$

donde N_i es el número de píxeles segmentados en el corte i .

La Figura 3.7 resume este procedimiento. Para cada corte, se contabilizan los píxeles pertenecientes a la región de interés y se transforman en un área física utilizando la resolución espacial de la imagen en el plano (s_x, s_y). Posteriormente, la suma de las áreas segmentadas se combina con el espaciado entre cortes (s_z) para estimar el volumen total.

Este procedimiento permite transformar la salida binaria del modelo en una medida físicamente interpretable, expresada en milímetros cúbicos (mm^3). El uso de unidades físicas, en lugar de recuentos de píxeles sin escala, resulta esencial para que las medidas obtenidas sean comparables entre diferentes resonancias, sujetos y estudios experimentales.

Desde el punto de vista metodológico, la cuantificación volumétrica amplía la utilidad del sistema desarrollado, ya que la herramienta no solo proporciona una segmentación visual de la región de interés, sino también una medida numérica objetiva. Esta salida resulta coherente con el flujo de trabajo que se busca automatizar en ICTS BioImagen Complutense, donde la segmentación manual de las regiones de interés se utiliza posteriormente para estimar volúmenes y analizar la afectación




Figura 3.7: Proceso de cálculo del volumen de la lesión a partir de la máscara segmentada. Fuente: elaboración propia.

observada. Además, este enfoque coincide con otros trabajos de segmentación biomédica orientados a la medición automática de carga lesional en resonancia magnética (de Oliveira et al., 2022; Akkus et al., 2017).

3.5. Integración de explicabilidad

Desde el inicio de este Trabajo de Fin de Grado, uno de los objetivos del proyecto no solo implicaba el desarrollo del *pipeline* de segmentación y cálculo de volúmenes, sino también el análisis de la robustez y la interpretabilidad de los modelos. La aplicación de modelos de *deep learning* a una tarea realizada habitualmente por expertos introduce el riesgo de incorporar un proceso de caja negra en un contexto, como el biomédico, donde la transparencia resulta especialmente relevante para generar confianza en los resultados y facilitar su análisis crítico (Samek et al., 2017b; Doshi-Velez y Kim, 2017).

En este apartado se expone la metodología seguida para integrar técnicas de Inteligencia Artificial Explicable (XAI) en los dos modelos que forman parte del *pipeline* de segmentación automática. Dado que los fundamentos de los métodos empleados ya se han descrito en el estado de la cuestión, esta sección se centra en su adaptación práctica al problema de segmentación y en cómo se incorporan al flujo de análisis desarrollado.

3.5.1. Motivación de la explicabilidad en el sistema

Aunque los resultados de segmentación pueden evaluarse mediante métricas cuantitativas, estas no son suficientes para comprender cómo se generan las predicciones del modelo. Una segmentación puede obtener buenos valores de solapamiento y, aun así, apoyarse en patrones no deseados, artefactos de adquisición o regiones anatómicas no relacionadas con la estructura de interés.

Este aspecto resulta especialmente relevante en imagen biomédica, donde el objetivo no es únicamente obtener una máscara precisa, sino también comprobar que el comportamiento del modelo sea coherente con el dominio de aplicación. Además, el uso de un conjunto de datos reducido incrementa la probabilidad de que la red aprenda relaciones poco generalizables, por lo que la explicabilidad se incorpora como una herramienta complementaria para analizar el comportamiento interno del sistema.

En este trabajo, la explicabilidad se utiliza con dos objetivos principales. En primer lugar, permite generar mapas de relevancia que indican qué zonas de la imagen contribuyen en mayor medida a la salida del modelo. En segundo lugar, facilita el análisis crítico de las segmentaciones obtenidas, al permitir estudiar si la red se apoya en regiones anatómicamente coherentes o si aparecen dependencias no deseadas en zonas externas a la región de interés.

3.5.2. Adaptación de XAI a modelos de segmentación

Una de las principales dificultades al aplicar técnicas de explicabilidad en este trabajo es que muchos métodos de XAI fueron diseñados originalmente para tareas de clasificación. En estos problemas, la salida del modelo suele ser un valor escalar asociado a una clase concreta. Sin embargo, en segmentación, la salida del modelo es una máscara densa, donde cada píxel tiene asociada una probabilidad de pertenencia a la clase objetivo.

Por este motivo, no es posible aplicar directamente estos métodos sin realizar una adaptación previa. Para ello, se define una función de *score* escalar a partir de la salida del modelo. Esta función resume la predicción densa en un único valor, sobre el que pueden calcularse gradientes o perturbaciones de forma compatible con las técnicas de explicabilidad utilizadas.

En este trabajo, el *score* se define a partir de la activación del modelo en la región segmentada por la propia red. De este modo, la explicación no se calcula sobre una clase global de imagen, sino sobre la región que el modelo ha identificado como perteneciente a la estructura objetivo. Esta decisión permite adaptar métodos originalmente propuestos para clasificación al contexto de segmentación biomédica.

El cálculo se realiza sobre la predicción del modelo y no sobre la máscara de referencia. Esta decisión es importante, ya que el objetivo de la explicabilidad no es medir directamente la coincidencia con la anotación manual, sino analizar qué información utiliza la red para generar su propia salida.

3.5.3. Procedimiento de integración en el *pipeline*

La explicabilidad se integra como una fase posterior a la inferencia de los modelos de segmentación. Una vez obtenidas las máscaras predichas, se generan mapas de relevancia asociados a la salida de cada modelo. Para ello, se han implementado notebooks específicos que cargan los modelos entrenados, procesan los volúmenes de resonancia magnética corte a corte y reproducen el mismo flujo seguido durante la inferencia.

En el caso del modelo de isquemia, el procedimiento mantiene la estructura secuencial del *pipeline*: primero se obtiene la máscara cerebral, después se utiliza dicha máscara para restringir la entrada al tejido cerebral y, finalmente, se genera la predicción de lesión. A partir de esta salida se calculan los mapas de relevancia asociados a la región segmentada como isquemia.

En el caso del modelo de segmentación cerebral, el procedimiento se aplica directamente sobre la predicción de cerebro generada por el modelo. La explicación se calcula sobre la región que la red identifica como tejido cerebral, con el objetivo de estudiar si la predicción depende de zonas coherentes con la estructura anatómica segmentada.

Aunque cada modelo tiene una región objetivo distinta, el marco de explicabilidad empleado es común. En ambos casos se parte de la salida probabilística del modelo, se define un *score* escalar sobre la región predicha y se calculan los mapas de relevancia correspondientes. Posteriormente, estos mapas se normalizan y se redimensionan al tamaño de la imagen de entrada para facilitar su visualización junto con el corte original, la máscara de referencia y la máscara predicha.

Para los métodos basados en Grad-CAM, se selecciona la última capa convolucional del decoder, previa a la convolución final 1×1 , al tratarse de una capa cercana a la generación de la máscara de salida y que todavía conserva información espacial relevante. Esta elección permite obtener mapas de activación relacionados con la decisión final del modelo sin perder completamente la estructura espacial de la imagen.

Además de los mapas visuales, se incorporan métricas basadas en perturbación de la entrada, como *Deletion*, *Insertion* y AOPC. Estas métricas se emplean para estudiar si las regiones identificadas como relevantes tienen influencia real sobre la salida del modelo, complementando así la interpretación visual de los mapas de relevancia (Samek et al., 2017a; Petsiuk et al., 2018).

Cabe destacar que los mapas de relevancia no deben interpretarse como segmentaciones adicionales ni como una validación clínica directa. Su función es proporcionar una aproximación al comportamiento interno del modelo, permitiendo analizar qué regiones de la imagen influyen en la predicción. Por tanto, la explicabilidad se plantea como una herramienta complementaria a las métricas de segmentación y a la evaluación volumétrica.

Los resultados visuales y cuantitativos derivados de esta integración se presentan posteriormente en el capítulo de resultados, donde se analizan ejemplos representativos para ambos modelos y se discute la coherencia de las explicaciones obtenidas.

3.6. Implementación, reproducibilidad y código entregado

El desarrollo práctico del programa se ha organizado en una serie de notebooks de *Python*, que constituyen el código entregado junto con esta memoria. Esta decisión se corresponde con el carácter experimental del proyecto y con la necesidad de documentar de forma clara cada fase del flujo de trabajo: entrenamiento, inferencia, cálculo de métricas y explicabilidad.

El uso de notebooks resulta adecuado en este contexto por varios motivos. En primer lugar, permite combinar código, explicaciones intermedias, visualizaciones y resultados en un mismo entorno, facilitando la revisión del proceso seguido. En segundo lugar, favorece la reproducibilidad, ya que cada notebook puede ejecutarse de forma secuencial y permite comprobar de manera directa las entradas, salidas y transformaciones aplicadas en cada etapa. Además, durante el desarrollo del TFG se acordó mantener el sistema en formato notebook, sin interfaz gráfica independiente, siempre que estos incluyeran de forma clara el procedimiento de entrenamiento, uso y evaluación de los modelos.

Esta organización también facilita el uso del sistema por parte de usuarios no especializados en desarrollo software, especialmente en entornos como Google Colab o Jupyter Notebook. De este modo, el usuario puede ejecutar el flujo de trabajo por bloques, modificar parámetros concretos y visualizar los resultados sin necesidad de desplegar una aplicación completa. Por tanto, los notebooks no se plantean únicamente como scripts de desarrollo, sino como una forma documentada y ejecutable de entregar el prototipo.

Por lo tanto, se entregan cinco notebooks principales, cada uno de ellos con responsabilidades diferenciadas. En primer lugar, el notebook de entrenamiento, `UNET_RadImageNet_unificado.ipynb`, contiene la definición de la arquitectura U-Net empleada, la carga del conjunto de datos, el preprocesamiento de las imágenes y máscaras, la configuración de entrenamiento y el guardado final de los modelos. Este notebook permite reproducir el proceso de entrenamiento, pudiéndose entrenar un único modelo para una tarea concreta o dos modelos, uno de órgano y otro de lesión. En este último caso, se aplica la máscara de *Ground Truth* del órgano sobre la imagen original, de forma que el modelo de lesión se entrena únicamente sobre la región anatómica correspondiente.

Se adjunta además un notebook de testeo, `Tester_Pipeline.ipynb`, que permite cargar los modelos entrenados y ejecutar el *pipeline* completo. En primer lugar, se cargan los modelos y el caso de estudio a analizar. A continuación, se obtiene la máscara del órgano, se restringe la imagen original a dicha región y se aplica el modelo de lesión. Finalmente, las máscaras resultantes se utilizan para calcular los volúmenes de órgano y lesión. Este notebook permite reproducir el proceso de inferencia, obteniendo tanto las máscaras segmentadas como los volúmenes cuantificados a partir de la imagen de entrada.

El notebook `GraphTester.ipynb` contiene el código utilizado para generar las métricas de los modelos, expuestas posteriormente en el capítulo de resultados. En este notebook se implementan las funciones necesarias para calcular el coeficiente

Dice, el error absoluto de volumen y el error relativo porcentual, tanto a nivel de corte como a nivel volumétrico. Además, se incluyen funciones para generar gráficos comparativos entre la segmentación automática y la manual, facilitando la visualización de los resultados obtenidos.

Los notebooks de XAI para el cerebro y la lesión isquémica implementan el análisis de explicabilidad de los modelos entrenados. Ambos siguen una estructura común: carga del modelo, selección de la capa objetivo, generación de mapas de relevancia, cálculo de métricas de fidelidad y exportación de resultados. En ellos se aplican técnicas como Grad-CAM, Grad-CAM++, *Integrated Gradients* y oclusión. Además, se generan curvas de perturbación como *Deletion*, *Insertion*, MoRF y LeRF, junto con métricas derivadas como AOPC. Estos resultados se exportan en formato CSV y como figuras, facilitando su incorporación al análisis cualitativo y cuantitativo de la memoria.

Además, se incluyen los dos modelos desarrollados, guardados en formato `.h5`, que pueden ser cargados directamente para realizar el proceso de inferencia sobre nuevos casos de estudio. Estos modelos corresponden a la arquitectura U-Net entrenada para segmentar el cerebro y la lesión isquémica, respectivamente.

Por último, también se adjuntan, como parte de la reproducibilidad del proyecto, los archivos resultantes de la ejecución de los notebooks de cálculo de métricas y explicabilidad, con los datos resultantes en formato CSV y las imágenes generadas en formato PNG.

3.6.1. Requisitos de ejecución

Para facilitar la reproducción del trabajo, el código se ha organizado de forma que pueda ejecutarse en un entorno estándar de *Python*, preferiblemente mediante Jupyter Notebook o Google Colab. No se requiere una infraestructura específica ni software propietario para ejecutar la inferencia o el cálculo de métricas, aunque el entrenamiento de los modelos puede beneficiarse del uso de GPU para reducir el tiempo de ejecución.

Los requisitos principales del entorno son los siguientes:

- Un entorno de ejecución compatible con notebooks, como Jupyter Notebook, JupyterLab o Google Colab.
- Python 3.x, junto con las librerías necesarias para procesamiento de imagen, aprendizaje profundo, lectura de volúmenes médicos y visualización de resultados.
- Acceso a los modelos entrenados en formato `.h5`, en caso de ejecutar únicamente la inferencia.
- Imágenes de entrada en formato NIfTI, organizadas según la estructura de carpetas descrita en la sección del conjunto de datos.
- Máscaras de referencia, en caso de reproducir el entrenamiento o calcular métricas comparativas frente a segmentaciones manuales.

Entre las librerías utilizadas se incluyen TensorFlow/Keras para la definición, entrenamiento y carga de los modelos; NumPy y Pandas para el tratamiento de datos; NiBabel para la lectura de imágenes médicas en formato NIfTI; Pillow y OpenCV para operaciones de preprocesamiento de imagen; Matplotlib y Plotly para la generación de figuras y visualizaciones; y Scikit-learn para funciones auxiliares de evaluación. Las dependencias concretas del proyecto deben recogerse en un fichero `requirements.txt` dentro del repositorio, de forma que el entorno pueda reconstruirse mediante instalación automática.

Requisito	Descripción
Entorno de ejecución	Jupyter Notebook, JupyterLab o Google Colab.
Lenguaje	Python 3.x.
Aprendizaje profundo	TensorFlow/Keras para entrenamiento, carga e inferencia de los modelos.
Procesamiento de datos	NumPy y Pandas para manipulación de matrices, métricas y exportación de resultados.
Imagen médica	NiBabel para lectura de volúmenes NIfTI y acceso a la información espacial de la imagen.
Procesamiento de imagen	Pillow y OpenCV para redimensionado, normalización y manipulación de máscaras.
Visualización	Matplotlib y Plotly para generación de gráficas, máscaras, mapas de calor y figuras exportables.
Archivos necesarios	Modelos .h5, imágenes NIfTI de entrada y, cuando proceda, máscaras manuales de referencia.

Tabla 3.4: Requisitos principales para la ejecución y reproducción del código entregado.

3.6.2. Repositorio y estructura del código entregado

Todo el código desarrollado se encuentra disponible en el repositorio de GitHub del proyecto:

[https://github.com/beabuenodev/
Herramienta-de-Analisis-de-Imagenes-Biomedicas](https://github.com/beabuenodev/Herramienta-de-Analisis-de-Imagenes-Biomedicas)

Resultados y Discusión

En este capítulo se presentan y discuten los resultados obtenidos por los modelos de segmentación cerebral y de segmentación de isquemia cerebral desarrollados en este trabajo. La evaluación se ha realizado sobre un subconjunto de test compuesto por tres casos representativos, empleados exclusivamente para el estudio experimental presentado en este capítulo y no incluidos en el conjunto de datos utilizado durante el entrenamiento ni durante la validación de los modelos. Este subconjunto incluye un sujeto de control sin presencia de lesión y dos sujetos con lesión isquémica, correspondientes a los escenarios de isquemia transitoria e isquemia permanente.

Cada caso dispone de 28 cortes axiales para la evaluación de la segmentación cerebral. En los casos patológicos se dispone, además, de 9 cortes con anotación específica de la región isquémica, lo que da lugar a un total de 84 cortes empleados en la evaluación cerebral y 18 cortes adicionales de lesión para la evaluación específica de isquemia. En conjunto, el análisis considera 102 imágenes de test.

Es importante precisar que la unidad principal de análisis en este capítulo es el caso completo, no el corte individual. Por este motivo, las gráficas comparativas por paciente muestran valores agregados, calculados como la media de los resultados obtenidos en todos los cortes correspondientes a cada caso. Esta decisión evita interpretar cada slice como una muestra independiente, ya que los cortes de un mismo volumen pertenecen al mismo sujeto y están anatómicamente correlacionados. No obstante, cuando resulta relevante para estudiar la variabilidad interna de cada volumen, el análisis se complementa con métricas calculadas a nivel de corte, especialmente en los apartados de explicabilidad y en la discusión de los cortes extremos.

En el caso del modelo de segmentación de isquemia, se ha aplicado un umbral de binarización de 0.8 sobre la salida probabilística del modelo. Este valor fue seleccionado previamente por ofrecer el mejor compromiso entre precisión espacial, estabilidad volumétrica y reducción de falsos positivos, tal como se observa en la Tabla 4.5. Aunque umbrales inferiores obtienen valores de Dice ligeramente superiores, el umbral 0.8 presenta el menor error absoluto y relativo de volumen, con un error absoluto de 0.0001 ml y un error relativo del 0.86 %. Por este motivo, se priorizó este valor como punto de equilibrio entre solapamiento espacial y precisión volumétrica.

La evaluación debe interpretarse como un estudio exploratorio del comporta-

miento del sistema ante casos representativos, y no como una validación clínica definitiva sobre una grupo amplio. Esta limitación se debe al número reducido de casos disponibles para test y a la propia naturaleza del problema, especialmente en la segmentación de isquemia, donde las regiones lesionadas presentan bordes difusos y una delimitación manual parcialmente subjetiva.

4.1. Configuración experimental

La evaluación experimental se ha diseñado con el objetivo de analizar el comportamiento de los modelos desarrollados en condiciones representativas del uso previsto de la herramienta. Para ello, se han considerado dos tareas principales: la segmentación del cerebro completo y la segmentación de regiones de isquemia cerebral. Aunque ambas tareas se abordan mediante arquitecturas basadas en U-Net, presentan niveles de dificultad distintos. La segmentación cerebral corresponde a una estructura anatómica amplia y relativamente bien delimitada, mientras que la segmentación de isquemia implica regiones más pequeñas, de borde difuso y con mayor variabilidad visual.

El conjunto de test está formado por tres casos completos. El primero corresponde a un caso de control, sin presencia de lesión, y permite evaluar la capacidad del sistema para no generar detecciones patológicas incorrectas. Los otros dos casos corresponden a sujetos con lesión isquémica, incluyendo un escenario de isquemia transitoria y otro de isquemia permanente. Esta selección permite cubrir tres situaciones relevantes para el análisis: ausencia de lesión, lesión de menor definición e intensidad, y lesión más estable y claramente visible.

Para cada caso se han evaluado las máscaras generadas por el modelo frente a las segmentaciones manuales disponibles. En la tarea de segmentación cerebral se han utilizado los 28 cortes de cada volumen, dando lugar a 84 cortes evaluados. En la tarea de segmentación de isquemia se han analizado los cortes anotados con información específica de lesión, correspondientes a los casos patológicos. Además, el caso de control se ha incluido en la evaluación de isquemia para comprobar que el modelo mantiene un comportamiento conservador en ausencia de patología.

Las métricas cuantitativas empleadas han sido el coeficiente Dice, la intersección sobre la unión o IoU, el error absoluto de volumen, el error relativo y el porcentaje de acierto volumétrico. Dice e IoU permiten medir el solapamiento espacial entre la máscara predicha y la máscara de referencia, mientras que las métricas volumétricas permiten valorar si la herramienta estima de forma adecuada la magnitud de la estructura segmentada. Esta segunda dimensión resulta especialmente relevante para el objetivo del proyecto, ya que la herramienta no solo busca generar máscaras visuales, sino también cuantificar automáticamente regiones anatómicas o patológicas.

Las gráficas por paciente representan la media de los valores obtenidos en los slices de cada sujeto. Esta forma de presentación permite comparar de manera clara el comportamiento del modelo entre casos.

Además del análisis cuantitativo, se ha realizado una evaluación cualitativa de las segmentaciones generadas. Este análisis visual resulta necesario en el contexto

de la imagen biomédica, ya que las métricas de solapamiento pueden penalizar de forma intensa pequeñas diferencias en los bordes, especialmente cuando las regiones segmentadas son pequeñas o presentan límites ambiguos. Por este motivo, la interpretación de los resultados combina métricas numéricas, comparación visual de máscaras y análisis de coherencia espacial mediante técnicas de explicabilidad.

Finalmente, para el modelo de isquemia se ha estudiado el impacto del umbral de binarización aplicado sobre la salida probabilística. En este capítulo se presentan los resultados correspondientes al umbral 0.8, seleccionado por ofrecer un equilibrio adecuado entre detección de lesión y reducción de falsos positivos. Esta decisión es especialmente importante en la segmentación de isquemia, donde valores de umbral más bajos pueden aumentar la sensibilidad, pero también producir sobresegmentaciones en regiones de intensidad intermedia.

4.2. Resultados en segmentación cerebral

La primera tarea evaluada corresponde a la segmentación del cerebro completo. Esta tarea constituye una etapa fundamental dentro del flujo de análisis, ya que permite aislar la región anatómica de interés y proporciona una base sobre la que posteriormente pueden calcularse medidas volumétricas o aplicarse procedimientos específicos de análisis de lesión.

4.2.1. Resultados cuantitativos

La Tabla 4.1 resume las métricas obtenidas por el modelo de segmentación cerebral sobre los casos de test. Los resultados muestran un rendimiento elevado y estable, con un coeficiente Dice 3D medio de $0,973 \pm 0,001$ y una IoU 3D media de $0,947 \pm 0,002$. Estos valores indican un alto grado de solapamiento entre las máscaras predichas y las segmentaciones de referencia.

Tabla 4.1: Resumen de métricas del modelo de segmentación cerebral

Métrica	Valor
Error absoluto medio (ml)	$0,007 \pm 0,004$
Error relativo medio (%)	$1,56 \pm 0,90$
Acierto medio (%)	98,44
Coeficiente Dice 3D	$0,973 \pm 0,001$
IoU 3D	$0,947 \pm 0,002$

Desde el punto de vista volumétrico, el modelo obtiene un error absoluto medio de 0,007 ml y un error relativo medio del 1,56 %. Estos valores muestran que la segmentación automática no solo reproduce adecuadamente la forma espacial del cerebro, sino que también conserva de manera precisa su volumen total. Este aspecto resulta relevante para la herramienta desarrollada, ya que una estimación volumétrica estable es necesaria para que los resultados puedan ser utilizados posteriormente en tareas de cuantificación biomédica.

En la Figura 4.1 se representan los valores medios del coeficiente Dice obtenidos para cada caso. Cada punto corresponde a la media de los valores calculados sobre los cortes del volumen correspondiente. Como se observa, el rendimiento se mantiene estable entre los tres casos evaluados, sin caídas relevantes asociadas a la presencia o ausencia de lesión isquémica. Este comportamiento sugiere que el modelo de cerebro aprende una representación anatómica robusta y no depende de forma significativa del estado patológico del sujeto.




Figura 4.1: Evolución del coeficiente Dice por Caso en el estudio de segmentación del cerebro en modelo control y con ictus isquémico permanente y transitorio. Fuente: elaboración propia.

La Figura 4.2 compara el volumen cerebral estimado por el modelo con el volumen obtenido a partir de la segmentación manual. La proximidad entre ambos valores confirma que las diferencias observadas son reducidas y que el modelo mantiene una estimación volumétrica coherente en los tres casos. Esta estabilidad es especialmente importante porque pequeñas desviaciones sistemáticas en la segmentación del cerebro podrían propagarse a etapas posteriores del análisis.




Figura 4.2: Comparación del volumen cerebral estimado por el modelo y el volumen obtenido a partir de la segmentación manual. Fuente: elaboración propia.

En conjunto, los resultados cuantitativos muestran que el modelo de segmentación cerebral alcanza un comportamiento preciso, estable y adecuado para su inte-

gración en la herramienta desarrollada. La baja variabilidad entre casos indica que el modelo generaliza correctamente dentro del subconjunto de evaluación utilizado, al menos para los escenarios representativos considerados en este trabajo.

4.2.2. Análisis cualitativo

Con el objetivo de complementar la evaluación cuantitativa, se ha realizado un análisis visual de las máscaras generadas por el modelo. La Figura 4.3 muestra ejemplos representativos de la segmentación cerebral obtenida en los distintos casos evaluados. En cada ejemplo se compara la imagen original, la máscara de referencia y la máscara predicha por el modelo.




Figura 4.3: Ejemplos cualitativos de segmentación del cerebro en distintos escenarios. Fuente: elaboración propia.

A nivel visual, las máscaras generadas presentan una delimitación coherente del contorno cerebral. El modelo conserva la forma de la estructura y no presenta artefactos fuera del área esperada. Este comportamiento es consistente con los valores elevados de Dice e IoU observados en el análisis cuantitativo.

Las principales discrepancias se concentran en los cortes extremos de los casos, donde las slices contienen ruido y son menos definidas. Estos cortes no se han tenido en cuenta, ya que en un entorno de investigación son descartados por su baja calidad e interés, ya que no forman parte de la anatomía cerebral relevante para el análisis de la isquemia cerebral.

En los cortes centrales, la segmentación es precisa y la estructura está bien definida, presentando bordes incluso más ajustados que la segmentación manual. Esto indica que el modelo es capaz de identificar de manera estable la región cerebral principal, incluso en presencia de variaciones de intensidad propias de la resonancia magnética.

4.2.3. Resultados de explicabilidad en la segmentación cerebral

Además de evaluar la calidad de las máscaras generadas, se aplicaron técnicas de explicabilidad para analizar la coherencia espacial de las regiones utilizadas por el modelo durante la predicción. Este análisis se realizó sobre 84 cortes pertenecientes a tres casos distintos.

Durante la revisión de los resultados se observó que los cortes extremos del volumen presentaban un comportamiento diferente al de los cortes centrales. En estas zonas, la presencia de tejido cerebral es reducida o incluso inexistente en la máscara de referencia, lo que afecta negativamente a métricas como Dice e IoU. Por este motivo, los resultados se analizaron diferenciando entre el conjunto completo de cortes, los cortes interiores y los cortes extremos.

Tabla 4.2: Rendimiento medio del modelo de segmentación cerebral en los cortes analizados para explicabilidad.

Conjunto de cortes	N	Dice medio	IoU medio
Todos los cortes	84	0,802	0,774
Cortes interiores	66	0,969	0,940
Cortes extremos	18	0,189	0,174

Como se observa en la Tabla 4.2, el rendimiento global se ve condicionado por los cortes extremos. Al considerar únicamente los cortes interiores, más representativos de la tarea principal de segmentación cerebral, el modelo alcanza un Dice medio de 0,969 y un IoU medio de 0,940. Esta diferencia indica que la disminución del rendimiento en el conjunto completo se debe principalmente a los cortes de borde, donde la región anatómica objetivo es pequeña o ambigua.

La Figura 4.4 muestra un ejemplo representativo de un corte interior con buena segmentación cerebral. En ella se presenta la imagen original, la máscara de referencia, la máscara predicha, los mapas de relevancia generados mediante Grad-CAM, Grad-CAM++ e Integrated Gradients, y la curva de eliminación normalizada asociada.

En los cortes interiores, la máscara predicha presenta un alto grado de solapamiento con la segmentación manual. Los mapas generados por Grad-CAM y Grad-




Figura 4.4: Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación cerebral. Fuente: elaboración propia.

CAM++ muestran activaciones amplias y continuas sobre la región cerebral, lo que facilita su interpretación visual en una tarea de segmentación anatómica. Integrated Gradients, en cambio, produce mapas más localizados y dispersos, resaltando zonas concretas de la imagen, como bordes o regiones de mayor variación de intensidad.

Desde un punto de vista anatómico, este comportamiento resulta especialmente relevante en la segmentación cerebral. A diferencia de la isquemia, que constituye una región patológica de menor tamaño y límites menos definidos, el cerebro presenta una delimitación anatómica más amplia y relativamente continua frente a los tejidos circundantes. Por ello, las atribuciones generadas por Integrated Gradients pueden interpretarse como una señal de que el modelo está utilizando información localizada en el contorno cerebral y en las transiciones de intensidad entre el tejido cerebral y el fondo o estructuras adyacentes.

Esta observación es coherente con la propia naturaleza de la tarea: para segmentar correctamente el cerebro, el modelo no solo debe identificar la presencia global de tejido cerebral, sino también localizar sus límites espaciales. En este sentido, mientras que Grad-CAM y Grad-CAM++ ofrecen una visión más global de la región

anatómica segmentada, Integrated Gradients aporta una explicación más fina sobre qué zonas concretas de la imagen influyen en la delimitación de la máscara. No obstante, esta interpretación debe entenderse como un análisis de coherencia espacial del modelo, y no como una validación anatómica independiente del límite cerebral.

Esta diferencia entre métodos también se refleja en las métricas de fidelidad. La Tabla 4.3 resume los valores medios obtenidos para Grad-CAM, Grad-CAM++ e Integrated Gradients. La sensibilidad por oclusión se empleó como análisis complementario, pero no se incluye en esta tabla al no generar las mismas métricas agregadas que los métodos basados en mapas de relevancia.

Tabla 4.3: Resumen cuantitativo de las métricas de fidelidad para los métodos de explicabilidad aplicados al modelo de segmentación cerebral.

Método	Deletion AUC ↓	Insertion AUC ↑	LeRF AUC ↑	AOPC ↑	AOPC norm. ↑
Grad-CAM	0,264	0,712	0,755	0,753	0,761
Grad-CAM++	0,304	0,795	0,807	0,714	0,721
Integrated Gradients	0,102	0,755	0,721	0,914	0,923

Integrated Gradients obtuvo el mejor comportamiento en las métricas basadas en eliminación, con un *Deletion AUC* medio de 0,102 y un *AOPC* normalizado de 0,923. Esto indica que las regiones identificadas como relevantes por este método tienen una influencia directa sobre la predicción, ya que su eliminación provoca una caída más rápida de la puntuación del modelo.

Por otro lado, Grad-CAM++ presentó los mejores valores en las métricas de inserción y LeRF, con un *Insertion AUC* medio de 0,795 y un *LeRF AUC* medio de 0,807. Este resultado sugiere que las regiones resaltadas por Grad-CAM++ contienen información suficiente para reconstruir progresivamente la predicción, y que las zonas consideradas menos relevantes afectan en menor medida a la salida cuando se eliminan en primer lugar.

El comportamiento observado en las curvas de perturbación refuerza esta interpretación. Al eliminar el 25 % de los píxeles considerados más relevantes, la puntuación media del modelo descendió hasta 0,097 con Integrated Gradients, frente a 0,663 con Grad-CAM y 0,750 con Grad-CAM++. Esto sugiere que Integrated Gradients produce mapas más focalizados en regiones críticas para la predicción, mientras que Grad-CAM y Grad-CAM++ generan explicaciones más distribuidas espacialmente.

En los cortes extremos, la interpretación de las explicaciones fue menos estable. Esto se debe a que la máscara manual puede contener una región cerebral muy reducida o incluso vacía, mientras que la imagen todavía puede mostrar estructuras anatómicas residuales. En consecuencia, estos cortes deben entenderse como casos límite del volumen, útiles para estudiar el comportamiento del modelo en zonas de transición, pero no como ejemplos representativos de la segmentación cerebral principal.

En conjunto, los resultados muestran que las explicaciones generadas son coherentes con el comportamiento cuantitativo del modelo en los cortes interiores. Grad-CAM y Grad-CAM++ ofrecen visualizaciones más suaves y anatómicamente interpretables, al activar de forma amplia la región cerebral segmentada. Integrated Gradients, por su parte, identifica regiones más concretas y con mayor impacto

en las métricas de perturbación, especialmente en zonas compatibles con bordes anatómicos y transiciones de intensidad relevantes para delimitar el cerebro. Por tanto, la combinación de estos métodos permite analizar la segmentación cerebral desde perspectivas complementarias: una visión global de la región segmentada y una atribución más localizada de los píxeles que influyen en la predicción.

4.3. Resultados en segmentación de isquemia

A continuación, se presentan los resultados obtenidos en la tarea de segmentación de las regiones de lesión por isquemia cerebral, la cual, por razones que se describirán en la siguiente sección, supone un problema más complejo que la segmentación del órgano sano. Para ello, al igual que en el modelo de cerebro, se han evaluado varias configuraciones de arquitecturas *U-Net*, utilizando las métricas descritas anteriormente.

4.3.1. Resultados cuantitativos

Tabla 4.4: Resumen de métricas del modelo de segmentación de isquemia

Métrica	Valor
Error absoluto medio (ml)	$0,001 \pm 0,001$
Error relativo medio (%)	$7,41 \pm 2,64$
Acierto medio (%)	92,59
Coefficiente Dice 3D	$0,820 \pm 0,157$
IoU 3D	$0,717 \pm 0,246$

En la Figura 4.5 se representan los valores del coeficiente Dice obtenidos para cada uno de los casos evaluados en la tarea de segmentación de isquemia.




Figura 4.5: Evolución del coeficiente Dice por Caso en el estudio de segmentación de lesión isquémica en modelo control y con ictus isquémico permanente y transitorio. Fuente: elaboración propia.

En el caso de control, donde no existe presencia de lesión, el modelo obtiene un valor de Dice igual a 1, lo que indica una coincidencia perfecta entre la predicción

y la máscara de referencia al no detectar regiones patológicas. En los casos con presencia de isquemia, los valores de Dice se sitúan en torno a 0.8, lo que refleja un alto grado de solapamiento entre la segmentación automática y la manual, aunque con discrepancias en las zonas de transición y en la delimitación de los bordes.

De manera general, los resultados obtenidos muestran un valor de *coeficiente Dice* inferiores y con mayor variabilidad frente al modelo de cerebro. El error relativo también presenta una ligera degradación respecto al caso base.

Estas diferencias son notables a lo largo de todas las configuraciones y casos analizados, lo que sugiere que la limitación no reside únicamente en el modelo, sino en la naturaleza del problema abordado.

4.3.2. Naturaleza del problema y subjetividad

A diferencia de la segmentación del cerebro, el cual está claramente delimitado por el cráneo y el espacio subcranoideo, debido a las características anatómicas propias de las lesiones de isquemia cerebral, el proceso de segmentación constituye un problema complejo y altamente subjetivo, cuya interpretación puede variar significativamente entre distintos profesionales, tal y como respalda el *ICTS BioImagen Complutense*.

Concretamente, las lesiones presentan las siguientes características visibles en cada corte de la IRM afectado:

- Borde difuminado.
- Gradientes de intensidad entre tejido sano y afectado.
- Zonas intermedias en las que la clasificación no es clara.
- Ruido y artefactos propios de la resonancia magnética nuclear.

Como consecuencia, la delimitación manual de estas regiones depende del criterio del experto que realiza la medición, lo que introduce una alta variabilidad en los datos recogidos entre observadores y estudios. La anotación manual está afectada por incertidumbre en la frontera de la lesión, y penaliza las métricas de solapamiento, por lo que el *ground truth* utilizado durante el entrenamiento y la evaluación del modelo debe analizarse con concordancia a una referencia experta operativa.

4.3.3. Interpretación de métricas

Teniendo en cuenta esta problemática, los valores obtenidos en las métricas deben interpretarse con cautela. Por este motivo, ha sido necesaria una validación adicional por parte de profesionales del *ICTS BioImagen Complutense*, con el fin de obtener un veredicto más fiable y ajustado a la realidad clínica. Un *valor Dice* inferior en comparación al modelo de segmentación cerebral no implica necesariamente un menor rendimiento del modelo, sino que refleja la variabilidad técnica del proceso.

Pequeñas variaciones en la delimitación de la zona afectada, producen cambios significativos en el *valor Dice*, por lo que el modelo puede estar generando segmentaciones coherentes desde el punto de vista clínico aún cuando la métrica no alcance los valores óptimos.

En este punto, resulta especialmente relevante considerar el criterio aportado por los profesionales del *ICTS BioImagen Complutense*, quienes señalan que la validez de las segmentaciones no dependen únicamente de precisión absoluta sino de la robustez en el comportamiento del modelo. Es decir, una ligera sobreestimación o subestimación sistemática en los volúmenes segmentados puede considerarse válida siempre que la desviación sea consistente entre casos y no introduzca artefactos incoherentes, como cortes intermedios vacíos o la detección de regiones incompatibles con la morfología de la isquemia.

Tal y como se observa en la Figura 4.6, las diferencias en los volúmenes estimados se mantienen en rangos consistentes respecto al *ground truth*. Este comportamiento sugiere que el modelo presenta una desviación sistemática controlada, alineada con los criterios de robustez definidos por el centro de Bioimagen.




Figura 4.6: Comparación del volumen de lesión isquémica estimado por el modelo y el volumen obtenido a partir de la segmentación manual. Fuente: elaboración propia.

4.3.4. Análisis del umbral de binarización

Durante la evaluación del modelo de segmentación de isquemia se observó que el umbral de binarización aplicado sobre la salida probabilística influía de forma directa en la máscara final obtenida. Este efecto resulta especialmente relevante en la segmentación de lesiones pequeñas, donde pequeñas variaciones en la probabilidad asignada a los píxeles pueden traducirse en falsos positivos o en cambios apreciables en el volumen estimado.

Por este motivo, se evaluaron distintos valores de umbral entre 0,50 y 0,95. Para cada configuración se calcularon el coeficiente Dice medio, el error absoluto de volumen y el error relativo porcentual, con el objetivo de analizar el equilibrio entre el solapamiento espacial de la segmentación y la precisión de la cuantificación volumétrica.

Como se observa en la Tabla 4.5, el mayor valor de Dice medio se obtiene con un umbral de 0,50. Sin embargo, al aumentar el umbral se reduce progresivamente el error volumétrico hasta alcanzar su valor mínimo en 0,80, donde se obtiene el menor error absoluto y relativo. A partir de este punto, incrementos adicionales del umbral

Tabla 4.5: Comparación del rendimiento medio del modelo de isquemia para distintos umbrales de binarización.

Umbral	Dice medio	Error absoluto (ml)	Error relativo (%)	Casos procesados
0.50	0.8323	0.0009	6.65	3
0.55	0.8310	0.0008	5.89	3
0.60	0.8308	0.0007	4.95	3
0.65	0.8314	0.0005	3.85	3
0.70	0.8301	0.0004	2.59	3
0.75	0.8301	0.0003	1.73	3
0.80	0.8290	0.0001	0.86	3
0.85	0.8281	0.0002	1.33	3
0.90	0.8256	0.0004	3.02	3
0.95	0.8220	0.0007	5.65	3

reducen ligeramente el Dice y vuelven a aumentar el error volumétrico.

Estos resultados muestran que el umbral óptimo depende del criterio priorizado. Un umbral de 0,50 maximiza ligeramente el solapamiento espacial, mientras que un umbral de 0,80 ofrece una estimación volumétrica más precisa. Dado que uno de los objetivos principales de la herramienta es cuantificar el volumen de la lesión, se adoptó finalmente un umbral de 0,80 para la fase de inferencia del modelo de isquemia.

Debe tenerse en cuenta que este análisis se realizó sobre un número reducido de casos, por lo que el umbral seleccionado debe interpretarse como una decisión experimental adecuada para este conjunto de validación, y no como un valor universal generalizable a cualquier adquisición de resonancia magnética.

4.3.5. Análisis cualitativo

Con el objetivo de complementar el análisis cuantitativo presentado anteriormente, se ha realizado una evaluación cualitativa de las segmentaciones obtenidas en los casos de isquemia cerebral, prestando especial atención al comportamiento del modelo en regiones de alta ambigüedad.

La Figura 4.7 muestra ejemplos representativos de segmentación correspondientes a los tres casos estudiados. En cada uno de ellos se comparan la máscara manual (GT), y la predicción generada por el modelo.

En el caso de control, el modelo presenta un comportamiento óptimo, con una correspondencia exacta entre la predicción y la ausencia de lesión. Este resultado confirma la capacidad del modelo para no generar falsos positivos en ausencia de patología.

En el caso de isquemia permanente, se obtiene un coeficiente Dice de 0.86 y un IoU de 0.755. A nivel visual, la predicción del modelo muestra una delimitación más homogénea y consistente de la región afectada en comparación con la máscara manual, la cual presenta bordes más irregulares. Este comportamiento sugiere que el modelo no solo reproduce la anotación, sino que puede aportar una segmentación más regular en regiones donde el ground truth es ambiguo.




Figura 4.7: Ejemplos cualitativos de segmentación de isquemia en distintos escenarios. Fuente: elaboración propia.

Por último, en el caso de isquemia transitoria, se obtienen valores inferiores (Dice de 0.751 e IoU de 0.601), lo cual es coherente con la menor definición de la lesión. En este tipo de casos, la baja intensidad de la zona hiperintensa de la isquemia hacen que su selección manual sea compleja, intruduciendo un valor de subjetividad elevado. Sin embargo, el modelo consigue destacar exitosamente la zona más afectada pese a que el caso puede parecerse mucho a un caso de control.

En conjunto, estos resultados cualitativos refuerzan la interpretación de las métricas cuantitativas, evidenciando que las diferencias observadas en los valores de Dice no responden únicamente al rendimiento del modelo, sino también a la complejidad intrínseca de cada caso y a la variabilidad presente en las anotaciones de referencia.

Se ha observado que, debido a la mayor sensibilidad del modelo, en ocasiones se ha conseguido identificar regiones desapercibidas a criterio manual, así como de segmentar de forma más homogénea ciertas zonas de transición. Estos resultados sugieren que el modelo no solo reproduce el comportamiento humano, sino que, en

determinados escenarios, puede ser una herramienta útil para mejorar la consistencia del proceso.

En segundo lugar, en las zonas de transición entre tejido sano y tejido afectado, el modelo muestra una mayor estabilidad en la delimitación de los bordes, proporcionando segmentaciones más suaves y menos fragmentadas. Este aspecto resulta especialmente relevante en el contexto de la isquemia, donde los gradientes de intensidad dificultan la definición de un límite claro.

Por otro lado, también se han identificado casos en los que el modelo presenta una ligera sobreestimación de las regiones afectadas, especialmente en áreas con intensidades intermedias. No obstante, tal y como se ha discutido previamente, este comportamiento puede considerarse aceptable siempre que se mantenga de forma consistente y no introduzca estructuras incompatibles con la morfología esperada de la lesión.

Finalmente, en los casos más complejos, el modelo muestra limitaciones similares a las de la segmentación manual, lo que refuerza la idea de que la dificultad reside en la propia naturaleza de la imagen y no exclusivamente en el enfoque empleado.

En conjunto, el análisis cualitativo respalda los resultados cuantitativos obtenidos, evidenciando que el modelo produce segmentaciones coherentes y clínicamente plausibles, incluso en aquellos casos donde las métricas numéricas no alcanzan valores elevados.

4.3.6. Discusión crítica del modelo de isquemia

Es importante destacar que el sistema desarrollado se concibe como una herramienta supervisada en la que el especialista mantiene el control de los datos finales. La herramienta permite la edición de cada una de las máscaras generada así como los valores volumétricos en cada corte de la resonancia analizada. Este enfoque garantiza que cualquier desviación pueda ser corregida de manera sencilla por el experto, integrando la automatización dentro de un **flujo de trabajo asistido y no sustitutivo**.

4.3.7. Resultados de explicabilidad en la segmentación de isquemia

Una vez evaluado el rendimiento del modelo de segmentación de isquemia, se analizó la coherencia espacial de sus predicciones mediante técnicas de explicabilidad visual. El análisis se realizó sobre un subconjunto de 84 cortes pertenecientes a tres casos de prueba, de los cuales 22 presentaban lesión en la segmentación manual y 62 no contenían lesión.

A nivel de presencia o ausencia de lesión por corte, el modelo obtuvo 21 verdaderos positivos, 60 verdaderos negativos, 2 falsos positivos y 1 falso negativo. Esto supone una sensibilidad del 95,45 %, una especificidad del 96,77 % y una puntuación F1 del 93,33 %. En los cortes con lesión correctamente detectada, el Dice medio fue de 0,784 y la IoU media de 0,672.

Para la interpretación visual se aplicaron Grad-CAM, Grad-CAM++ e Integra-

ted Gradients utilizando como objetivo la máscara predicha por el propio modelo. De este modo, las explicaciones analizan las regiones que contribuyen a la predicción generada por la red, independientemente de su coincidencia exacta con la segmentación manual.

La Figura 4.8 muestra un ejemplo representativo de explicabilidad aplicado a un corte con lesión. En los casos correctamente segmentados, Grad-CAM y Grad-CAM++ presentan activaciones localizadas en la región predicha como isquemia, con una correspondencia visual clara con la zona de lesión en los cortes de mayor solapamiento. Integrated Gradients también resalta la región de interés, aunque con un patrón más disperso y fragmentado.




Figura 4.8: Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación de isquemia. Fuente: elaboración propia.

Esta diferencia entre métodos es coherente con lo observado en la segmentación cerebral: Grad-CAM y Grad-CAM++ generan mapas más compactos y visualmente interpretables, mientras que Integrated Gradients proporciona una atribución más

fin, pero menos localizada espacialmente.

La evaluación cuantitativa mediante perturbación se resume en la Tabla 4.6. En los cortes con lesión correctamente detectada, los valores medios de *Deletion AUC* fueron muy bajos para los tres métodos, con valores de 0,025 para Grad-CAM y Grad-CAM++, y 0,026 para Integrated Gradients. Esto indica que, al eliminar en primer lugar las regiones consideradas más relevantes, el score asociado a la predicción cae de forma abrupta.

Tabla 4.6: Resultados cuantitativos de explicabilidad para los cortes de isquemia correctamente detectados.

Método	Deletion AUC	Insertion AUC	LeRF AUC	AOPC normalizado
Grad-CAM	0,025	0,627	0,867	1,000
Grad-CAM++	0,025	0,840	0,840	1,000
Integrated Gradients	0,026	0,879	0,882	0,999

Las curvas de *Insertion* muestran que, al reconstruir la imagen comenzando por las regiones más relevantes, el modelo recupera progresivamente su activación. Este comportamiento es especialmente claro en Grad-CAM++ e Integrated Gradients, con valores medios de 0,840 y 0,879, respectivamente. Por su parte, los valores elevados de *LeRF AUC* indican que la eliminación inicial de las regiones menos relevantes mantiene la predicción durante una parte importante del proceso de perturbación.

El *AOPC* normalizado se sitúa en valores cercanos a 1 para los tres métodos, lo que refuerza la influencia de las regiones destacadas sobre la salida del modelo. En conjunto, estos resultados indican que los mapas de relevancia no solo son visualmente coherentes, sino que además identifican regiones con impacto directo sobre la predicción.

El análisis también permite observar el comportamiento del modelo en casos erróneos. En los falsos positivos, las explicaciones muestran activaciones localizadas en las regiones que han originado la predicción incorrecta. Esto evidencia que la explicabilidad no garantiza que la segmentación sea correcta, sino que permite identificar qué información ha utilizado el modelo para producirla. Por tanto, estos casos resultan útiles para estudiar patrones de error y posibles regiones ambiguas de la imagen.

Desde un punto de vista biomédico, estas regiones de alta relevancia deben interpretarse con cautela. En la isquemia cerebral, suele distinguirse entre el núcleo de la lesión, asociado a tejido con daño más establecido, y la penumbra isquémica, entendida como una región periférica funcionalmente alterada pero potencialmente recuperable. Sin embargo, en este trabajo no se dispone de una anotación independiente que diferencie explícitamente entre núcleo y penumbra, ni de una validación experta específica de dichas subregiones. Por tanto, los mapas de Integrated Gradients no permiten afirmar de forma concluyente que el modelo esté separando ambos componentes fisiopatológicos. (Astrup et al., 1981)

Aun así, el patrón observado resulta informativo. Mientras que Grad-CAM y Grad-CAM++ tienden a generar activaciones más compactas sobre la región seg-

mentada como lesión, Integrated Gradients produce atribuciones más finas y fragmentadas, incluyendo zonas internas de la lesión y áreas de transición en sus bordes. Esta distribución puede ser coherente con la dificultad de delimitar la isquemia en resonancia magnética, donde los límites entre tejido sano y afectado no siempre son nítidos. En consecuencia, las explicaciones sugieren que el modelo no basa su predicción únicamente en una región puntual, sino también en variaciones locales de intensidad próximas a la zona lesionada. No obstante, esta interpretación debe entenderse como un análisis de plausibilidad espacial del modelo, y no como una identificación clínica de núcleo isquémico o penumbra.

En conjunto, la explicabilidad aporta una lectura complementaria de la segmentación de isquemia al mostrar que las regiones más influyentes para el modelo se sitúan en zonas espacialmente compatibles con la lesión y sus bordes. Sin embargo, dado que no se dispone de etiquetas diferenciadas de núcleo isquémico y penumbra, estos mapas no deben interpretarse como una validación fisiopatológica independiente, sino como una herramienta de apoyo para analizar la coherencia espacial de la predicción.

4.4. Conclusiones del capítulo

De forma global, los resultados obtenidos muestran un comportamiento diferenciado entre las dos tareas abordadas. La segmentación cerebral presenta un rendimiento más estable y preciso, con métricas de solapamiento elevadas y errores volumétricos reducidos en todos los casos evaluados. Este resultado era esperable, ya que el cerebro constituye una estructura anatómica de mayor tamaño, con límites más definidos y menor variabilidad relativa entre sujetos.

Por el contrario, la segmentación de isquemia representa una tarea más compleja. Las regiones lesionadas son de menor tamaño, presentan bordes menos definidos y pueden mostrar una intensidad más variable en la imagen de resonancia magnética. Por ello, pequeñas discrepancias espaciales entre la predicción y la referencia manual tienen un impacto mayor sobre métricas como Dice o IoU. Aun así, el modelo permite localizar de forma coherente las zonas patológicas principales y proporciona estimaciones volumétricas útiles para una primera aproximación automatizada.

El análisis conjunto de métricas cuantitativas, resultados visuales y mapas de explicabilidad indica que la herramienta desarrollada cumple el objetivo de ofrecer apoyo al análisis de imágenes biomédicas, especialmente como sistema de asistencia y cuantificación preliminar. No obstante, los resultados también muestran que la segmentación de lesiones requiere una validación más amplia y un refinamiento adicional antes de su uso en contextos de análisis clínico o experimental más exigentes.

Las Figuras 4.9, 4.10 y 4.11 resumen de forma visual esta interpretación global de los resultados. El gráfico de Bland-Altman permite analizar la concordancia entre el volumen de referencia y el volumen estimado por el modelo, mientras que los diagramas de caja muestran la distribución de las métricas principales y ayudan a identificar la variabilidad entre casos. Por último, la comparación del Dice medio por paciente permite observar si el rendimiento se mantiene de forma homogénea o si existen casos concretos con mayor dificultad de segmentación.




Figura 4.9: Gráfico de Bland-Altman para analizar la concordancia entre el volumen calculado manualmente y el volumen estimado por el modelo. Fuente: elaboración propia.




Figura 4.10: Distribución de las principales métricas de evaluación obtenidas en los casos analizados. Fuente: elaboración propia.




Figura 4.11: Comparación del coeficiente Dice medio obtenido para cada paciente evaluado. Fuente: elaboración propia.

Conclusiones y Trabajo Futuro

5.1. Conclusiones

El trabajo desarrollado ha permitido alcanzar el objetivo principal planteado al inicio de la memoria: construir un prototipo funcional de apoyo al análisis de imágenes biomédicas preclínicas mediante técnicas de visión por computador e inteligencia artificial. La herramienta obtenida permite segmentar automáticamente el cerebro y las regiones de isquemia cerebral en imágenes de resonancia magnética de ratón, calcular medidas volumétricas asociadas e incorporar mecanismos de explicabilidad para analizar el comportamiento de los modelos.

A partir de los resultados obtenidos, puede concluirse que la aproximación propuesta es adecuada como primera solución automatizada dentro de un flujo de trabajo supervisado. El sistema no sustituye el criterio del investigador experto, pero sí permite reducir parte de la carga manual asociada a la delimitación de regiones de interés y proporciona una salida cuantitativa que puede ser revisada, corregida y utilizada como apoyo en estudios biomédicos.

El modelo de segmentación cerebral ha mostrado un comportamiento especialmente sólido. Los resultados alcanzados, con un coeficiente Dice 3D medio de 0,973 y una IoU 3D media de 0,947, indican una alta correspondencia entre las máscaras generadas automáticamente y las segmentaciones manuales de referencia. Además, el bajo error volumétrico obtenido confirma que el modelo no solo reproduce adecuadamente la forma del cerebro, sino que también conserva de manera precisa su volumen total. Esta estabilidad convierte la segmentación cerebral en una base fiable para las fases posteriores del pipeline.

La segmentación de isquemia cerebral ha presentado una mayor dificultad, como era esperable por la naturaleza del problema. Las lesiones isquémicas muestran bordes difusos, variaciones de intensidad y zonas de transición cuya delimitación depende en parte del criterio del operador. Aun así, el modelo ha obtenido resultados coherentes, con un Dice 3D medio de 0,820 y una IoU 3D media de 0,717. Estos valores, aunque inferiores a los obtenidos en la segmentación cerebral, resultan razonables para una tarea con mayor ambigüedad anatómica y visual. El modelo permite localizar las regiones patológicas principales y ofrece estimaciones volumétricas útiles como primera aproximación automatizada.

Desde el punto de vista de la cuantificación, el sistema cumple una función relevante, ya que transforma las máscaras generadas en medidas volumétricas interpretables. Esta salida resulta especialmente importante en el contexto del trabajo, puesto que el interés del usuario final no se limita a visualizar una segmentación, sino también a disponer de valores numéricos que permitan comparar casos, estudiar la evolución de una lesión o analizar diferencias entre sujetos.

La incorporación de técnicas de Inteligencia Artificial Explicable ha aportado una capa adicional de análisis. Los mapas generados mediante Grad-CAM, Grad-CAM++ e Integrated Gradients han permitido estudiar qué regiones de la imagen influyen en las predicciones de los modelos. En los casos correctamente segmentados, las explicaciones obtenidas se concentran en zonas coherentes con las estructuras segmentadas, lo que refuerza la interpretación de que los modelos no se apoyan únicamente en artefactos o regiones externas irrelevantes. No obstante, estas técnicas deben entenderse como una herramienta complementaria de inspección, no como una validación clínica independiente.

En conjunto, el trabajo demuestra que el uso de arquitecturas U-Net con aprendizaje por transferencia es una estrategia viable para abordar tareas de segmentación biomédica en un contexto de datos limitados. La decisión de emplear dos modelos diferenciados, uno para cerebro y otro para isquemia, ha permitido estructurar el problema de forma clara y aprovechar la segmentación anatómica como paso previo al análisis de la lesión. Esta organización mejora la coherencia del sistema y facilita su interpretación.

A pesar de estos resultados, el trabajo presenta varias limitaciones. La primera y más importante es el tamaño reducido del conjunto de datos. Aunque esta situación es habitual en proyectos de imagen biomédica, limita la capacidad de generalización de los modelos y obliga a interpretar los resultados como una validación exploratoria. Una evaluación más robusta requeriría incorporar un mayor número de casos, distintos protocolos de adquisición y una mayor variabilidad en la morfología e intensidad de las lesiones.

Otra limitación relevante es la dependencia de las anotaciones manuales utilizadas como referencia. En el caso de la isquemia, las fronteras de la lesión no siempre están claramente definidas, por lo que el ground truth contiene un cierto grado de subjetividad. Esta variabilidad afecta directamente a métricas como Dice e IoU, que penalizan pequeñas diferencias espaciales aunque estas puedan ser aceptables desde el punto de vista experto. Por ello, los resultados deben interpretarse teniendo en cuenta que la segmentación manual representa una referencia operativa, no una verdad absoluta.

También debe considerarse que la validación se ha realizado sobre un número limitado de casos de prueba. Aunque estos casos permiten estudiar situaciones relevantes, como control, isquemia transitoria e isquemia permanente, no son suficientes para afirmar que el sistema generaliza a todos los escenarios posibles. Antes de su uso en estudios experimentales más amplios, sería necesario realizar una validación externa con más sujetos y, preferiblemente, con revisión por parte de varios expertos.

5.2. Trabajo Futuro

Como trabajo futuro, una primera línea de mejora consistiría en ampliar el conjunto de datos disponible. La incorporación de nuevos casos permitiría entrenar modelos más robustos, reducir el riesgo de sobreajuste y evaluar con mayor precisión el comportamiento del sistema ante lesiones de distinta morfología, tamaño e intensidad. También sería recomendable estudiar técnicas de aumento de datos específicas para imagen médica, siempre que las transformaciones aplicadas mantengan la coherencia anatómica de las imágenes.

Una segunda línea de trabajo sería mejorar la evaluación experimental. En futuras versiones deberían utilizarse particiones de entrenamiento, validación y test más amplias, así como validación cruzada y análisis separados por tipo de lesión, tiempo de adquisición y calidad de imagen. Además, sería especialmente útil comparar las predicciones del modelo con anotaciones realizadas por varios expertos, con el fin de cuantificar la variabilidad interobservador y contextualizar mejor el rendimiento del sistema automático.

Desde el punto de vista técnico, podrían explorarse arquitecturas más avanzadas que la U-Net base empleada en este trabajo, como U-Net++, Attention U-Net o modelos con mecanismos de atención. Estas arquitecturas podrían mejorar la detección de lesiones pequeñas o de bordes poco definidos. Sin embargo, su uso debería evaluarse con cautela, ya que un aumento de complejidad no garantiza necesariamente una mejora en contextos con pocos datos anotados.

Otra posible mejora sería estudiar modelos tridimensionales. El enfoque actual trabaja corte a corte con imágenes 2D, lo que reduce el coste computacional y facilita el uso de modelos preentrenados, pero no aprovecha completamente la continuidad espacial entre slices consecutivas. Una arquitectura 3D podría mejorar la coherencia volumétrica de las predicciones, aunque requeriría más datos, mayor capacidad computacional y una estrategia de entrenamiento más compleja.

También sería conveniente desarrollar una interfaz de usuario orientada al investigador biomédico. Aunque los notebooks entregados permiten reproducir el entrenamiento, la inferencia y la evaluación, una aplicación con interfaz gráfica facilitaría la carga de volúmenes, la visualización de cortes, la edición de máscaras, el cálculo de volúmenes y la exportación de resultados. Esta mejora favorecería la integración de la herramienta en un entorno de trabajo real.

Finalmente, la metodología desarrollada podría extenderse a otros órganos, lesiones o modalidades de imagen. Aunque este trabajo se ha centrado en cerebro e isquemia cerebral en ratón, el pipeline propuesto proporciona una base adaptable a otros problemas de segmentación biomédica, siempre que se disponga de datos anotados y se ajusten adecuadamente las fases de preprocesamiento, entrenamiento y validación.

En conclusión, este Trabajo de Fin de Grado ha permitido desarrollar una primera herramienta funcional para el análisis automatizado de imágenes biomédicas preclínicas. Los resultados obtenidos muestran un rendimiento sólido en segmentación cerebral y un comportamiento prometedor en segmentación de isquemia, especialmente teniendo en cuenta la dificultad del problema y la limitación de datos disponibles. Aunque el sistema requiere validación adicional y mejoras antes de su

aplicación en entornos experimentales más amplios, constituye una base técnica válida para avanzar hacia herramientas de apoyo que reduzcan la carga manual, mejoren la reproducibilidad y faciliten la cuantificación de lesiones en investigación biomédica.

Introduction

Context, background and motivation

In the field of biomedical research, the analysis of magnetic resonance images, or Magnetic Resonance Imaging (MRI), constitutes a fundamental tool for the study of anatomical structures and the analysis of their evolution. In particular, in preclinical studies on animal models, such as the mouse brain, magnetic resonance imaging makes it possible to observe the evolution of different pathologies, providing relevant information for neuroscience research and the analysis of treatments. (Universidad Complutense de Madrid, 2024; Saito y Ueda, 2024)

The processing of this type of images, known as **segmentation**, consists of delimiting the anatomical or pathological region of interest, referred to as **ROI**, from the English term **Region of Interest**, with the aim of quantifying the characteristics of the organ or lesion, as well as estimating its volume. These tasks are essential to ensure the reproducibility of experiments and the comparability of results between different studies and subjects, especially in those cases in which the temporal evolution of a pathology is analysed or a possible treatment is being evaluated. (Universidad Complutense de Madrid, 2024)

Traditionally, these tasks have been performed manually: the usual workflow consists of analysing each of the MRI slices, identifying the regions of interest and manually delimiting them using specific selection tools, from which the magnitudes of interest are subsequently calculated. Although this procedure makes it possible to obtain valid experimental results, it presents several limitations. It is a laborious process that consumes a large amount of time, especially in studies with a high number of subjects. This workload entails a significant investment of time by researchers, which may affect the development times of the research. On the other hand, the manual delimitation of certain regions, such as ischaemic lesions, presents a degree of ambiguity, since their boundaries are not always clearly defined. This may introduce variability in the results depending on the professional's criterion. In addition to these limitations, there is the need to analyse increasingly extensive image sets and to obtain quantitative measurements consistently, as well as the demand for detailed and precise analyses, which hinders the scalability of manual processes. (Universidad Complutense de Madrid, 2024; Veiga-Canuto et al., 2022; Liu et al., 2022)

In this context, there is a need to develop tools that make it possible to speed up and automate these tasks in a supervised manner, improving process efficiency and increasing the consistency and reproducibility of the results.

The recent progress of artificial intelligence techniques applied to medical imaging has demonstrated their ability to identify complex patterns in visual data, opening the door to their application in biomedical tasks such as classification, detection and segmentation of anatomical structures and lesions. Nevertheless, the integration of this type of solution into real working contexts requires not only obtaining accurate results, but also ensuring that these results are interpretable and coherent from the point of view of the application domain. (Akkus et al., 2017; Litjens et al., 2017)

This Bachelor's Degree Final Project, in collaboration with the ICTS BioImagen Complutense centre, aims to respond to a real need observed in the research environment. Based on the knowledge acquired, the analysis of the state of the art and the review of the bibliography, the development of a tool based on supervised models is proposed, with the aim of contributing to the improvement of the magnetic resonance image analysis process in preclinical research, proposing a solution that reduces the manual workload and may contribute to improving the consistency of the results.

The motivation of this work is not limited solely to the implementation of an automatic model, but rather focuses on the development of a tool that can be integrated into the existing workflow, providing value as a support system for biomedical analysis. To this end, automation is combined with expert supervision, so that the user retains control over the final results and can interpret both the generated segmentations and the associated quantitative measurements.

Objectives

The objective of this Bachelor's Degree Final Project is to develop a software tool to support the analysis of preclinical biomedical images obtained by means of MRI. The work developed focuses on two segmentation tasks: the automatic delimitation of the brain and the segmentation of regions corresponding to cerebral ischaemia.

The tool is not intended to replace the judgement of the expert researcher, but rather to reduce the workload associated with manual segmentation and provide reproducible results that can be reviewed, interpreted and used as support within the usual workflow of the ICTS BioImagen Complutense centre.

General objective

To develop and evaluate a prototype based on computer vision and artificial intelligence techniques capable of automatically segmenting, in preclinical magnetic resonance images, the area corresponding to the brain and the regions affected by cerebral ischaemia, while also providing quantitative information associated with these segmentations and incorporating explainability mechanisms that facilitate the interpretation of the results obtained.

Specific objectives

To achieve the general objective, the following specific objectives have been defined:

- O1.** To analyse the biomedical context of the problem and the workflow followed at ICTS BioImagen Complutense for the analysis of preclinical MRI images associated with cerebral ischaemia studies.
- O2.** To study the manual segmentation process of the brain and ischaemic regions, identifying its main limitations in terms of time, reproducibility and dependence on the researcher's criterion.
- O3.** To investigate artificial intelligence models and approaches applied to medical imaging, assessing both existing models and the possibility of developing a proprietary model adapted to the domain of preclinical mouse magnetic resonance imaging.
- O4.** To organise and prepare a dataset composed of real magnetic resonance images, regions of interest and binary masks corresponding to the brain and cerebral ischaemia.
- O5.** To design a preprocessing process that makes it possible to adapt the original images for the training of supervised models, including format conversion, normalisation, filtering of non-informative slices and dimensional adjustment tasks.
- O6.** To study and apply transfer learning techniques, using weights pretrained on medical imaging, with the aim of improving training in a context of limited annotated data.
- O7.** To design, train and evaluate a first segmentation model based on a U-Net architecture to automatically delimit the brain area in the input images.
- O8.** To design, train and evaluate a second segmentation model based on a U-Net architecture to identify the regions of cerebral ischaemia present in the images.
- O9.** To use brain segmentation as auxiliary information to restrict ischaemia analysis to the relevant anatomical region and reduce detections outside the brain area.
- O10.** To implement quantification mechanisms that make it possible to calculate measurements derived from the segmentations obtained, especially brain volume and the volume of the ischaemic region.
- O11.** To incorporate explainable artificial intelligence techniques that make it possible to visually analyse which regions of the image influence the models' predictions and assess whether these are coherent with the expected anatomical or pathological areas.

- O12.** To evaluate the performance of both models through quantitative segmentation metrics, volumetric analysis and visual review of the generated predictions.
- O13.** To develop a reproducible and accessible prototype, organised in notebooks, which can be executed and reviewed by third parties without requiring complex infrastructure.
- O14.** To assess possible future extension lines, offering a first development of software that makes it possible to adapt training to other organs and pathologies.

Work plan

The development of this Bachelor's Degree Final Project has been organised progressively, starting from an initial phase of understanding the biomedical problem through to the implementation and evaluation of the proposed system. Given that the project combines aspects of software engineering, medical image processing, machine learning and experimental validation, it was necessary to structure the work into clearly differentiated phases.

Furthermore, as this is a project developed in collaboration with the ICTS BioImagen Complutense centre, the work plan was conditioned by the needs detected during follow-up meetings and visits to the centre. These sessions made it possible to orient technical decisions towards a real use case, define the functional requirements of the tool and adapt the development to the characteristics of the available dataset.

The following sections describe, first, the follow-up process carried out through meeting minutes and, subsequently, the main development phases followed until the final prototype was obtained.

Project follow-up and meetings with the supervisors

Throughout the development of the project, a continuous follow-up process was maintained through periodic meetings with the supervisors, both in person and online. In order to record the evolution of the development and the decisions made, meeting minutes were prepared after each meeting.

These minutes played an especially important role during the early phases of the project, as they made it possible to document the initial definition of the problem, the application context and the needs of the final user. In particular, the meetings with our supervisor David Castejón, as representative of the real use environment at ICTS BioImagen Complutense, made it possible to establish continuous communication between the technical side of the project and the biomedical interpretation of the results. This interaction was key to understanding which outputs were truly useful for researchers, how the segmentations should be presented and which quantitative measurements provided value within the usual workflow.

During the visits to the ICTS BioImagen Complutense centre, the minutes made it possible to collect essential information about the workflow followed by the researchers. Real examples of images were analysed and various applications of the

MRIs processed at the centre were studied. In addition, basic notions about the physical operation of magnetic resonance imaging equipment were acquired, learning to distinguish areas of hyperintensity and hypointensity, which are key for the subsequent construction of the dataset and for the interpretation of lesions.

The meetings also made it possible to continuously review design and implementation decisions. In the initial stages, the use of existing models for medical segmentation or general image segmentation was considered. However, after analysing their limitations in the context of preclinical mouse magnetic resonance images, it was decided to orient the work towards the development and training of proprietary models, adapted to the available dataset and to the specific needs of the use case.

As development progressed, decisions were made regarding the structure of the dataset, the removal of low-informative slices, the preparation of the training notebooks and the improvement of the ischaemia segmentation model. In particular, it was decided to use brain segmentation as a preliminary step to restrict the analysis area of the ischaemia model to brain tissue, with the aim of reducing false positives and improving the anatomical coherence of the predictions.

The feedback provided during these meetings also influenced practical aspects of the prototype, such as the need to display the segmentations visually, calculate volumes in interpretable units, document the usage steps and facilitate the execution of the system through notebooks in *Google Colab*. In this way, the follow-up of the project was not limited to academic supervision, but made it possible to progressively adapt the tool to the needs of the final user.

Development phases

The development of the work has been organised into several phases. First, a phase was carried out to understand the biomedical problem and define the functionality of the tool. This phase included meetings with the project directors and visits to the ICTS BioImagen Complutense centre, where the MRI acquisition process, the generation of regions of interest and the way in which researchers currently obtain quantitative measurements from manual segmentations were studied.

Subsequently, a phase of research and analysis of alternatives was addressed. At this stage, existing models for medical segmentation and general image segmentation were reviewed, assessing their possible application to the proposed use case. However, the differences between the human medical images commonly used in many pretrained models and preclinical mouse magnetic resonance images limited their direct applicability. This conclusion motivated the change in approach from the use of an existing model towards the design and training of proprietary models, while maintaining the support of transfer learning as a strategy to take advantage of visual knowledge previously learned in medical imaging.

The next phase consisted of preparing the dataset. The segmentation of cerebral ischaemia lesions was selected as the case study, due both to the availability of data provided by ICTS BioImagen Complutense and to its relevance within the centre's current research lines. At this stage, the organisation of the images, the adaptation of the masks, the conversion of formats and the preprocessing required for the data to be used in model training were carried out.

Next, the automatic segmentation pipeline was designed and implemented, composed of two models: one oriented towards brain segmentation and the other towards ischaemic lesion segmentation. The design of the system was proposed sequentially, so that brain segmentation could be used as a preliminary step to restrict the subsequent analysis of the lesion to the relevant anatomical region. This decision responds both to technical criteria, by reducing possible detections outside the brain, and to biomedical criteria, by making the system output more coherent.

In parallel with the development of the models, a phase for the study and implementation of explainability techniques was incorporated. This phase aimed to analyse whether the regions highlighted by the explanation methods coincided with regions relevant to the model's prediction, especially in the case of ischaemia. The purpose was to complement quantitative evaluation with a visual interpretation of the internal behaviour of the models.

Finally, the results obtained were evaluated through segmentation metrics, volumetric quantification and visual analysis of the generated predictions. This evaluation made it possible to assess both the accuracy of the masks obtained and the practical usefulness of the tool within the workflow proposed by ICTS BioImagen Complutense.

Structure of the report

The report is organised as follows. Chapter 2 presents the state of the art, including the necessary biomedical concepts, computer vision applied to medical imaging, segmentation architectures, transfer learning and explainable artificial intelligence. Chapter 3 describes the methodology followed, from dataset construction and image preprocessing to the architecture of the models, volumetric quantification and the integration of explainability. Chapter 4 presents and discusses the results obtained for brain segmentation and segmentation of the ischaemic region. Finally, Chapter 5 presents the conclusions of the work and the main lines of future work.

Conclusions and Future Work

Conclusions

The work developed has made it possible to achieve the main objective set out at the beginning of the report: to build a functional prototype to support the analysis of preclinical biomedical images using computer vision and artificial intelligence techniques. The resulting tool makes it possible to automatically segment the brain and cerebral ischaemia regions in mouse magnetic resonance imaging images, calculate associated volumetric measurements, and incorporate explainability mechanisms to analyse the behaviour of the models.

Based on the results obtained, it can be concluded that the proposed approach is suitable as a first automated solution within a supervised workflow. The system does not replace the judgement of the expert researcher, but it does reduce part of the manual workload associated with the delimitation of regions of interest and provides a quantitative output that can be reviewed, corrected, and used as support in biomedical studies.

The brain segmentation model has shown particularly robust behaviour. The results achieved, with a mean 3D Dice coefficient of 0.973 and a mean 3D IoU of 0.947, indicate a high correspondence between the automatically generated masks and the reference manual segmentations. In addition, the low volumetric error obtained confirms that the model not only adequately reproduces the shape of the brain, but also accurately preserves its total volume. This stability makes brain segmentation a reliable basis for the later stages of the pipeline.

Cerebral ischaemia segmentation has presented greater difficulty, as expected given the nature of the problem. Ischaemic lesions show diffuse borders, intensity variations, and transition areas whose delimitation partly depends on the operator's judgement. Even so, the model has obtained coherent results, with a mean 3D Dice of 0.820 and a mean 3D IoU of 0.717. Although these values are lower than those obtained in brain segmentation, they are reasonable for a task with greater anatomical and visual ambiguity. The model makes it possible to locate the main pathological regions and offers useful volumetric estimates as a first automated approximation.

From the point of view of quantification, the system fulfils a relevant function, since it transforms the generated masks into interpretable volumetric measurements. This output is especially important in the context of the work, since the interest

of the end user is not limited to visualising a segmentation, but also to obtaining numerical values that make it possible to compare cases, study the evolution of a lesion, or analyse differences between subjects.

The incorporation of Explainable Artificial Intelligence techniques has provided an additional layer of analysis. The maps generated using Grad-CAM, Grad-CAM++, and Integrated Gradients have made it possible to study which regions of the image influence the predictions of the models. In correctly segmented cases, the explanations obtained are concentrated in areas consistent with the segmented structures, which reinforces the interpretation that the models do not rely solely on artefacts or irrelevant external regions. Nevertheless, these techniques should be understood as a complementary inspection tool, not as an independent clinical validation.

Overall, the work demonstrates that the use of U-Net architectures with transfer learning is a viable strategy for addressing biomedical segmentation tasks in a limited-data context. The decision to use two differentiated models, one for the brain and another for ischaemia, has made it possible to structure the problem clearly and to use anatomical segmentation as a prior step before lesion analysis. This organisation improves the coherence of the system and facilitates its interpretation.

Despite these results, the work presents several limitations. The first and most important is the reduced size of the dataset. Although this situation is common in biomedical imaging projects, it limits the generalisation capacity of the models and requires the results to be interpreted as an exploratory validation. A more robust evaluation would require the incorporation of a larger number of cases, different acquisition protocols, and greater variability in the morphology and intensity of the lesions.

Another relevant limitation is the dependence on the manual annotations used as reference. In the case of ischaemia, the boundaries of the lesion are not always clearly defined, so the ground truth contains a certain degree of subjectivity. This variability directly affects metrics such as Dice and IoU, which penalise small spatial differences even when these may be acceptable from an expert point of view. Therefore, the results should be interpreted taking into account that the manual segmentation represents an operational reference, not an absolute truth.

It should also be considered that the validation has been performed on a limited number of test cases. Although these cases make it possible to study relevant situations, such as control, transient ischaemia, and permanent ischaemia, they are not sufficient to state that the system generalises to all possible scenarios. Before its use in broader experimental studies, it would be necessary to perform an external validation with more subjects and, preferably, with review by several experts.

Future Work

As future work, a first line of improvement would consist of expanding the available dataset. The incorporation of new cases would make it possible to train more robust models, reduce the risk of overfitting, and evaluate more accurately the behaviour of the system when faced with lesions of different morphology, size, and intensity. It would also be advisable to study data augmentation techniques spe-

cific to medical imaging, provided that the transformations applied maintain the anatomical coherence of the images.

A second line of work would be to improve the experimental evaluation. In future versions, larger training, validation, and test partitions should be used, as well as cross-validation and separate analyses by lesion type, acquisition time, and image quality. In addition, it would be especially useful to compare the predictions of the model with annotations made by several experts, in order to quantify interobserver variability and better contextualise the performance of the automatic system.

From a technical point of view, more advanced architectures than the base U-Net used in this work could be explored, such as U-Net++, Attention U-Net, or models with attention mechanisms. These architectures could improve the detection of small lesions or lesions with poorly defined borders. However, their use should be evaluated with caution, since an increase in complexity does not necessarily guarantee an improvement in contexts with few annotated data.

Another possible improvement would be to study three-dimensional models. The current approach works slice by slice with 2D images, which reduces the computational cost and facilitates the use of pretrained models, but does not fully exploit the spatial continuity between consecutive slices. A 3D architecture could improve the volumetric coherence of the predictions, although it would require more data, greater computational capacity, and a more complex training strategy.

It would also be advisable to develop a user interface aimed at the biomedical researcher. Although the delivered notebooks make it possible to reproduce the training, inference, and evaluation, an application with a graphical interface would facilitate the loading of volumes, the visualisation of slices, the editing of masks, the calculation of volumes, and the export of results. This improvement would favour the integration of the tool into a real working environment.

Finally, the methodology developed could be extended to other organs, lesions, or imaging modalities. Although this work has focused on the brain and cerebral ischaemia in mice, the proposed pipeline provides a basis that can be adapted to other biomedical segmentation problems, provided that annotated data are available and that the preprocessing, training, and validation stages are appropriately adjusted.

In conclusion, this Bachelor's Degree Final Project has made it possible to develop a first functional tool for the automated analysis of preclinical biomedical images. The results obtained show robust performance in brain segmentation and promising behaviour in ischaemia segmentation, especially taking into account the difficulty of the problem and the limitation of the available data. Although the system requires additional validation and improvements before its application in broader experimental environments, it constitutes a valid technical basis for moving towards support tools that reduce the manual workload, improve reproducibility, and facilitate the quantification of lesions in biomedical research.

Contribuciones personales

El presente Trabajo de Fin de Grado ha sido desarrollado de forma conjunta por los dos autores. Ambos estudiantes han participado en la definición del problema, en las reuniones de seguimiento con los tutores, en la toma de decisiones técnicas, en la revisión de resultados y en la elaboración de la memoria. No obstante, dentro de este trabajo común, cada integrante ha asumido responsabilidades predominantes en distintas fases del proyecto, que se detallan a continuación.

Beatriz Bueno Almagro

Mi contribución al proyecto se ha centrado principalmente en la definición técnica de los modelos, el análisis de la arquitectura empleada, el ajuste experimental de la salida del sistema, la integración de técnicas de explicabilidad y la redacción y revisión de distintas partes de la memoria. Desde las primeras fases del trabajo participé en la comprensión del problema planteado por la ICTS BioImagen Complutense, especialmente en la traducción de las necesidades del usuario final a requisitos técnicos concretos: segmentar automáticamente el cerebro y la lesión isquémica, calcular volúmenes y generar una salida interpretable dentro de un flujo de trabajo biomédico asistido.

Durante la fase de investigación inicial colaboré en la revisión del estado del arte, prestando especial atención a las técnicas de visión por computador aplicadas a imagen biomédica, a las arquitecturas de segmentación médica, al uso de U-Net y al aprendizaje por transferencia en contextos con conjuntos de datos reducidos. Esta investigación fue necesaria para justificar decisiones metodológicas importantes, como el uso de una arquitectura U-Net con encoder preentrenado frente a alternativas más complejas, y para argumentar la necesidad de incorporar técnicas de Inteligencia Artificial Explicable en un sistema aplicado a imagen médica.

Una parte relevante de mi trabajo consistió en estudiar y documentar la arquitectura de los modelos de segmentación. Participé en la descripción de la U-Net 2D empleada, en la justificación del uso de un encoder ResNet50 preentrenado con RadImageNet y en la explicación de las decisiones de implementación asociadas al decoder, las conexiones de salto, la salida sigmoideal y el planteamiento de la segmentación como problema binario. También contribuí a relacionar estas decisiones con las características del proyecto: tamaño reducido del conjunto de datos, natu-

raleza biomédica de las imágenes, necesidad de segmentación precisa y limitaciones computacionales propias del alcance de un TFG.

Asimismo, trabajé de forma destacada en el ajuste de la salida del modelo, especialmente en el análisis del umbral de binarización aplicado sobre la predicción probabilística. En el caso del modelo de isquemia, este ajuste resultó especialmente importante debido a la tendencia del sistema a sobresegmentar regiones de la imagen y generar falsos positivos. Por ello, participé en la comparación de distintos valores de umbral y en la interpretación de sus efectos sobre las métricas de evaluación y sobre la coherencia visual de las máscaras obtenidas. Esta parte del trabajo permitió justificar por qué no basta con aceptar directamente la salida probabilística del modelo, sino que es necesario adaptar el umbral al comportamiento concreto de la tarea.

Otra de mis principales aportaciones fue la integración y análisis de técnicas de explicabilidad. Trabajé en el estudio de métodos como Grad-CAM, Grad-CAM++ e Integrated Gradients, así como en su adaptación conceptual a un problema de segmentación, donde la salida del modelo no es una única clase sino una máscara espacial. Esta tarea incluyó reflexionar sobre qué significa explicar una predicción en segmentación médica y cómo deben interpretarse los mapas generados. En la memoria se plantea esta explicabilidad no como una validación clínica directa, sino como una herramienta para analizar si el modelo basa sus predicciones en regiones anatómica o patológicamente coherentes.

También me encargué especialmente de la interpretación de los resultados de explicabilidad. Esto incluyó el análisis cualitativo de los mapas obtenidos para los modelos, la comparación entre las regiones activadas por los métodos de XAI y las máscaras de segmentación, y la discusión de las diferencias entre métodos. En particular, participé en la interpretación de por qué Grad-CAM y Grad-CAM++ tienden a producir explicaciones más localizadas y visualmente interpretables, mientras que Integrated Gradients puede mostrar patrones más finos pero también más dispersos. Esta discusión permitió complementar las métricas de segmentación con una lectura más crítica del comportamiento interno del modelo.

En relación con la memoria, participé en la redacción de apartados técnicos vinculados a la arquitectura, el aprendizaje por transferencia, la estrategia de entrenamiento, el ajuste del umbral y la explicabilidad. Además, contribuí a la revisión global del documento, corrigiendo repeticiones, mejorando la cohesión entre capítulos y ajustando el tono académico. Esta revisión fue especialmente importante para que la memoria no quedase como una simple descripción de código, sino como una explicación razonada de las decisiones tomadas durante el desarrollo.

También participé en la revisión de la trazabilidad entre la implementación y la memoria, comprobando que las decisiones descritas en el documento se correspondieran con los notebooks desarrollados y con los resultados obtenidos. Esta revisión incluyó la comprobación de la coherencia entre metodología, figuras, tablas, métricas y discusión, evitando que el texto presentase afirmaciones no respaldadas por la implementación o por los experimentos realizados.

Por último, contribuí a la preparación de la defensa del trabajo en los apartados relacionados con la motivación técnica del sistema, la justificación de la arquitectura, la elección del umbral, la explicabilidad y las limitaciones del modelo. También

participé en la revisión final de figuras, tablas, referencias y formulaciones técnicas, comprobando que las afirmaciones incluidas en la memoria estuvieran alineadas con la implementación real y con los resultados obtenidos.

Leonardo Sáez Biffi

Mi contribución al proyecto se ha centrado principalmente en la implementación técnica del sistema, el procesamiento de los datos, el entrenamiento de los modelos de segmentación, la construcción del flujo de ejecución en notebooks y la redacción de varias partes fundamentales de la memoria. Desde las primeras fases del trabajo participé en el análisis del problema planteado por la ICTS BioImagen Complutense y en la definición de una solución basada en segmentación automática de imágenes de resonancia magnética preclínica.

Una de mis principales aportaciones fue la preparación del conjunto de datos para el entrenamiento de los modelos. Esta tarea incluyó la lectura y organización de los casos de resonancia magnética, la correspondencia entre imágenes y máscaras, la preparación de las segmentaciones de cerebro e isquemia y la adaptación de los datos al formato requerido por la red. También participé en la resolución de problemas derivados de la estructura real del dataset, como la existencia de múltiples máscaras asociadas a un mismo corte o la necesidad de mantener una correspondencia correcta entre las imágenes originales y las regiones de interés anotadas manualmente.

Durante el desarrollo del sistema implementé buena parte del pipeline de preprocesamiento de imágenes. Este proceso incluyó la lectura de volúmenes de resonancia, la extracción de cortes bidimensionales, la normalización de intensidades, el redimensionado de las imágenes al tamaño de entrada del modelo y la generación de tensores adecuados para el entrenamiento. También trabajé en la adaptación de imágenes monocanales a una entrada de tres canales, necesaria para emplear un encoder preentrenado dentro de la arquitectura U-Net. Estas transformaciones fueron fundamentales para asegurar que los datos pudieran introducirse de forma consistente en los modelos de aprendizaje profundo.

Otra aportación central fue la implementación y entrenamiento de los modelos de segmentación. Participé en el desarrollo de los notebooks de entrenamiento tanto para la segmentación del cerebro como para la segmentación de la lesión isquémica, utilizando una arquitectura U-Net con encoder ResNet50 y pesos preentrenados de RadImageNet. En esta fase se trabajó con estrategias de *transfer learning*, congelación inicial del encoder y posterior ajuste fino de capas, así como con funciones de pérdida adecuadas para segmentación binaria, especialmente en un contexto de fuerte desbalance entre fondo y lesión.

Además, desarrollé parte del flujo de inferencia del sistema, integrando los dos modelos dentro de un mismo pipeline. En este flujo, el modelo de cerebro se utiliza primero para delimitar la región anatómica principal y, posteriormente, el modelo de isquemia realiza la segmentación de la lesión sobre la imagen procesada. Esta integración permitió acercar el sistema al uso final previsto: cargar una resonancia, procesar sus cortes, generar máscaras de segmentación y obtener resultados cuantitativos asociados. También participé en la preparación de notebooks de prueba que

permitieran recorrer este proceso de forma secuencial y reproducible.

Otra parte relevante de mi trabajo fue la implementación del cálculo de volúmenes a partir de las máscaras generadas. Para ello se tuvo en cuenta la información espacial de las imágenes originales, de forma que el volumen segmentado pudiera expresarse en unidades físicas y no únicamente como número de píxeles. Esta funcionalidad resulta especialmente importante en el contexto biomédico del proyecto, ya que el objetivo de la herramienta no es solo producir una máscara visual, sino facilitar una cuantificación útil de la estructura cerebral y de la lesión. En este sentido, la implementación del cálculo volumétrico conecta directamente la salida del modelo con una necesidad práctica del usuario final.

También participé en la adaptación de los notebooks para que pudieran ser ejecutados por terceros de forma más sencilla. Esto incluyó la limpieza del código, la organización de las celdas, la incorporación de mensajes explicativos, la gestión básica de errores y la preparación de un flujo de uso más accesible en Google Colab. Esta parte del trabajo fue importante para que el sistema no quedase únicamente como un conjunto de scripts de desarrollo, sino como una herramienta reproducible y evaluable por usuarios externos al proceso de implementación.

En cuanto a la memoria, participé de forma directa en la redacción de la introducción, donde se presenta la motivación del proyecto, el contexto de colaboración con ICTS BioImagen Complutense y la necesidad de automatizar tareas de segmentación y cuantificación en imágenes de resonancia magnética. También redacté el primer apartado de metodología, centrado en la descripción del conjunto de datos y su organización, explicando la estructura de los casos, las imágenes utilizadas, las máscaras disponibles y la relación entre los datos originales y los datos empleados para el entrenamiento.

Además, me encargué de redactar gran parte del capítulo de resultados, incluyendo la presentación de las métricas obtenidas, la comparación entre las segmentaciones automáticas y las máscaras de referencia, y el análisis del comportamiento de los modelos en los distintos casos evaluados. Esta parte del trabajo fue especialmente importante para conectar la implementación con una evaluación objetiva del sistema, mostrando no solo el funcionamiento del pipeline, sino también sus aciertos, errores y limitaciones. También participé en la preparación de tablas, gráficas y ejemplos visuales empleados para apoyar esta discusión.

Asimismo, participé en la redacción de las conclusiones y del trabajo futuro. En este apartado contribuí a sintetizar el grado de cumplimiento de los objetivos planteados, las principales aportaciones del sistema desarrollado y las limitaciones que permanecen abiertas. También colaboré en la identificación de posibles líneas futuras, como la ampliación del conjunto de datos, la mejora del modelo de lesión, la validación con más casos y la evolución del prototipo hacia una herramienta más completa y usable en un entorno biomédico real.

Durante la fase de evaluación, colaboré en la obtención de resultados cuantitativos y cualitativos. Esto incluyó el cálculo de métricas de segmentación, la comparación entre predicciones y máscaras de referencia, y la generación de ejemplos visuales que permitieran analizar el comportamiento de los modelos en cortes concretos. Estos resultados fueron posteriormente utilizados para construir las tablas y figuras incluidas en la memoria, así como para apoyar la discusión sobre los puntos

fuertes y limitaciones del sistema.

Finalmente, participé en la revisión técnica de la memoria, asegurando que la descripción del código, del entrenamiento y del funcionamiento del pipeline coincidiera con la implementación real desarrollada durante el proyecto. También contribuí a la preparación de la defensa en los apartados más relacionados con la estructura del dataset, el preprocesamiento de datos, el flujo de ejecución, el entrenamiento de los modelos, la obtención de resultados y el cálculo de volúmenes.

Bibliografía

Toda tecnología suficientemente avanzada es indistinguible de la magia.

Arthur C. Clarke

- AKKUS, Z., GALIMZIANOVA, A., HOOGI, A., RUBIN, D. L. y ERICKSON, B. J. Deep learning for brain MRI segmentation: State of the art and future directions. *Journal of Digital Imaging*, vol. 30(4), páginas 449–459, 2017.
- AN, J., WENDT, L., WIESE, G., HEROLD, T., RZEPKA, N., MUELLER, S., KOCH, S. P., HOFFMANN, C. J., HARMS, C. y BOEHM-STURM, P. Deep learning-based automated lesion segmentation on mouse stroke magnetic resonance images. *Scientific Reports*, vol. 13, página 13341, 2023.
- ASTRUP, J., SIESJÖ, B. K. y SYMON, L. Thresholds in cerebral ischemia: the ischemic penumbra. *Stroke*, vol. 12(6), páginas 723–725, 1981.
- BARREDO ARRIETA, A., DÍAZ-RODRÍGUEZ, N., DEL SER, J., BENNETOT, A., TABIK, S., BARBADO, A., GARCÍA, S., GIL-LÓPEZ, S., MOLINA, D., BENJAMINS, R., CHATILA, R. y HERRERA, F. Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, vol. 58, páginas 82–115, 2020.
- CHATTOPADHAY, A., SARKAR, A., HOWLADER, P. y BALASUBRAMANIAN, V. N. Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks. En *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, páginas 839–847. IEEE, 2018.
- ČIVRNÝ, J., TOMÁŠ, D. y ČERNÁ, M. MRI of cerebral oedema in ischaemic stroke and its current use in routine clinical practice. *Neuroradiology*, vol. 66(3), páginas 305–315, 2024.
- DOSHI-VELEZ, F. y KIM, B. Towards a rigorous science of interpretable machine learning. 2017.
- GOODFELLOW, I., BENGIO, Y. y COURVILLE, A. *Deep Learning*. MIT Press, 2016. Consultado el 24 de mayo de 2026.

- HARSTON, G. W. J. ET AL. Imaging biomarkers in acute ischemic stroke trials: A systematic review. *Stroke*, vol. 46(4), páginas 1163–1169, 2015.
- HE, K., ZHANG, X., REN, S. y SUN, J. Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, páginas 770–778. 2016.
- HESAMIAN, M. H., JIA, W., HE, X. y KENNEDY, P. Deep learning techniques for medical image segmentation: Achievements and challenges. *Journal of Digital Imaging*, vol. 32(4), páginas 582–596, 2019.
- KRIZHEVSKY, A., SUTSKEVER, I. y HINTON, G. E. ImageNet classification with deep convolutional neural networks. En *Advances in Neural Information Processing Systems*, vol. 25, páginas 1097–1105. Curran Associates, Inc., 2012. Consultado el 24 de mayo de 2026.
- LECUN, Y., BENGIO, Y. y HINTON, G. Deep learning. *Nature*, vol. 521(7553), páginas 436–444, 2015.
- LEHMANN, T. M., GONNER, C. y SPITZER, K. Survey: Interpolation methods in medical image processing. *IEEE Transactions on Medical Imaging*, vol. 18(11), páginas 1049–1075, 1999.
- LITJENS, G., KOOI, T., BEJNORDI, B. E., SETIO, A. A. A., CIOMPI, F., GHAFORIAN, M., VAN DER LAAK, J. A. W. M., VAN GINNEKEN, B. y SÁNCHEZ, C. I. A survey on deep learning in medical image analysis. *Medical Image Analysis*, vol. 42, páginas 60–88, 2017.
- LIU, X., XING, F., MARIN, T., EL FAKHRI, G. y WOO, J. Variational inference for quantifying inter-observer variability in segmentation of anatomical structures. En *Medical Imaging 2022: Image Processing*, vol. 12032 de *Proceedings of SPIE*, página 120321M. 2022.
- MEI, X., LIU, Z., ROBSON, P. M., MARINELLI, B., HUANG, M., DOSHI, A., JACOBI, A., CAO, C., LINK, K. E., YANG, B. ET AL. RadImageNet: An open radiologic deep learning research dataset for effective transfer learning. *Radiology: Artificial Intelligence*, vol. 4(5), página e210315, 2022.
- MILLETARI, F., NAVAB, N. y AHMADI, S.-A. V-Net: Fully convolutional neural networks for volumetric medical image segmentation. En *2016 Fourth International Conference on 3D Vision (3DV)*, páginas 565–571. IEEE, 2016.
- NEUROIMAGING INFORMATICS TECHNOLOGY INITIATIVE. NIfTI-1 data format specification. <https://nifti.nimh.nih.gov/nifti-1/>, 2003. Consultado el 24 de mayo de 2026.
- NEUROIMAGING INFORMATICS TECHNOLOGY INITIATIVE. NIfTI-1 fields. <https://nifti.nimh.nih.gov/nifti-1/documentation/nifti1fields.html>, 2005. Consultado el 24 de mayo de 2026.

- NIBABEL DEVELOPERS. NiBabel: Access a multitude of neuroimaging data formats. <https://nipy.org/nibabel/>, 2026a. Consultado el 24 de mayo de 2026.
- NIBABEL DEVELOPERS. Working with NIfTI images. https://nipy.org/nibabel/nifti_images.html, 2026b. Consultado el 24 de mayo de 2026.
- ODENA, A., DUMOULIN, V. y OLAH, C. Deconvolution and checkerboard artifacts. *Distill*, vol. 1(10), página e3, 2016.
- OKTAY, O., SCHLEMPER, J., LE FOLGOC, L., LEE, M., HEINRICH, M., MISAWA, K., MORI, K., McDONAGH, S., HAMMERLA, N. Y., KAINZ, B., GLOCKER, B. y RUECKERT, D. Attention U-Net: Learning where to look for the pancreas. En *Medical Imaging with Deep Learning*. 2018. Consultado el 24 de mayo de 2026.
- DE OLIVEIRA, M. ET AL. Lesion volume quantification using two convolutional neural networks in MRIs of multiple sclerosis patients. *Sensors*, vol. 22(4), página 1661, 2022.
- OSPEL, J. M. ET AL. How do quantitative tissue imaging outcomes in acute ischemic stroke relate to functional outcome? *Stroke*, vol. 55(6), páginas e186–e194, 2024.
- PAN, S. J. y YANG, Q. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, vol. 22(10), páginas 1345–1359, 2010.
- PETSIUK, V., DAS, A. y SAENKO, K. RISE: Randomized input sampling for explanation of black-box models. En *British Machine Vision Conference*. 2018. Consultado el 24 de mayo de 2026.
- PRADILLO, J. M., GARCÍA-CULEBRAS, A., CUARTERO, M. I., PEÑA-MARTÍNEZ, C., MORO, M. Á., LIZASOAIN, I. y MORAGA, A. Del laboratorio a la clínica en el ictus isquémico agudo. modelos experimentales in vitro e in vivo. *Revista de Neurología*, vol. 75(9), páginas 283–293, 2022.
- RONNEBERGER, O., FISCHER, P. y BROX, T. U-Net: Convolutional networks for biomedical image segmentation. En *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, páginas 234–241. Springer, 2015.
- SAITO, S. y UEDA, J. Preclinical magnetic resonance imaging and spectroscopy in the fields of radiological technology, medical physics, and radiology. *Radiological Physics and Technology*, vol. 17(1), páginas 47–59, 2024.
- SAMEK, W., BINDER, A., MONTAVON, G., LAPUSCHKIN, S. y MÜLLER, K.-R. Evaluating the visualization of what a deep neural network has learned. *IEEE Transactions on Neural Networks and Learning Systems*, vol. 28(11), páginas 2660–2673, 2017a.
- SAMEK, W., WIEGAND, T. y MÜLLER, K.-R. Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. 2017b.

- SELVARAJU, R. R., COGSWELL, M., DAS, A., VEDANTAM, R., PARIKH, D. y BATRA, D. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, vol. 128(2), páginas 336–359, 2019.
- SHEN, D., WU, G. y SUK, H.-I. Deep learning in medical image analysis. *Annual Review of Biomedical Engineering*, vol. 19, páginas 221–248, 2017.
- SUNDARARAJAN, M., TALY, A. y YAN, Q. Axiomatic attribution for deep networks. 2017.
- TAJBAKHS, N., SHIN, J. Y., GURUDU, S. R., HURST, R. T., KENDALL, C. B., GOTWAY, M. B. y LIANG, J. Convolutional neural networks for medical image analysis: Full training or fine tuning? *IEEE Transactions on Medical Imaging*, vol. 35(5), páginas 1299–1312, 2016.
- UNIVERSIDAD COMPLUTENSE DE MADRID. Manual de procesamiento de imágenes de rm con imagej. <https://cai.ucm.es/data/cai/7/Manual-de-procesado-de-imagenes-de-RM-con-IMAGEJ-462.pdf>, 2024. Consultado el 24 de mayo de 2026.
- VEIGA-CANUTO, D., CERDÀ-ALBERICH, L., SANGÜESA NEBOT, C., MARTÍNEZ DE LAS HERAS, B., PÖTSCHGER, U., GABELLONI, M., CAROT SIERRA, J. M., TASCHNER-MANDL, S., DÜSTER, V., CAÑETE, A., LADENSTEIN, R., NERI, E. y MARTÍ-BONMATÍ, L. Comparative multicentric evaluation of inter-observer variability in manual and automatic segmentation of neuroblastic tumors in magnetic resonance images. *Cancers*, vol. 14(15), página 3648, 2022.
- YAMASHITA, R., NISHIO, M., DO, R. K. G. y TOGASHI, K. Convolutional neural networks: An overview and application in radiology. *Insights into Imaging*, vol. 9(4), páginas 611–629, 2018.
- YOSINSKI, J., CLUNE, J., BENGIO, Y. y LIPSON, H. How transferable are features in deep neural networks? 2014.
- ZHANG, L., TANNO, R., XU, M., HUANG, Y., BRONIK, K., JIN, C., JACOB, J., ZHENG, Y., SHAO, L., CICCARELLI, O., BARKHOF, F. y ALEXANDER, D. C. Learning from multiple annotators for medical image segmentation. *Pattern Recognition*, vol. 138, página 109400, 2023.
- ZHOU, Z., SIDDIQUEE, M. M. R., TAJBAKHS, N. y LIANG, J. UNet++: A nested U-Net architecture for medical image segmentation. En *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support*, páginas 3–11. Springer, 2018.