
**Herramienta de análisis de imágenes
biomédicas**
Biomedical image analysis tool



Trabajo de Fin de Grado
Curso 2025–2026

Autores

Beatriz Bueno Almagro
Leonardo Sáez Biffi

Directores

María Guijarro Mata-García
David Castejón Ferrer

Grado en Ingeniería del Software
Grado en Ingeniería de Computadores
Facultad de Informática
Universidad Complutense de Madrid

Herramienta de análisis de imágenes
biomédicas
Biomedical image analysis tool

Trabajo de Fin de Grado en Ingeniería del Software e
Ingeniería de Computadores

Autores

Beatriz Bueno Almagro
Leonardo Sáez Biffi

Director

María Guijarro Mata-García
David Castejón Ferrer

Convocatoria: *Junio 2026*

Grado en Ingeniería del Software
Grado en Ingeniería de Computadores
Facultad de Informática
Universidad Complutense de Madrid

25 de Mayo de 2026

Dedicatoria

*A todas las personas que nos han apoyado,
dentro y fuera de la universidad, durante esta
etapa.*

Agradecimientos

Queremos expresar nuestro agradecimiento a nuestros tutores, María y David, por su orientación, su disponibilidad y el seguimiento realizado a lo largo del desarrollo de este Trabajo de Fin de Grado. Sus indicaciones y sugerencias han sido fundamentales tanto en la parte técnica como en la elaboración de esta memoria.

También nos gustaría agradecer a ICTS BioImagen Complutense por la oportunidad de desarrollar este trabajo en un contexto aplicado y por el conocimiento compartido durante el proyecto. En especial, agradecemos la ayuda recibida para comprender mejor el problema biomédico abordado, así como las necesidades reales del caso de uso planteado.

Asimismo, agradecemos a todas las personas que, de una forma u otra, han contribuido al desarrollo del proyecto, ya fuera mediante apoyo técnico, revisión de resultados o acompañamiento durante el proceso.

Por último, queremos agradecer a nuestras familias y a las personas cercanas que nos han acompañado durante esta etapa por su apoyo constante, su paciencia y su confianza a lo largo de estos años.

Resumen

Herramienta de análisis de imágenes biomédicas

El presente Trabajo Fin de Grado aborda el diseño y desarrollo de una herramienta basada en visión por computador para la segmentación de imágenes de resonancia magnética nuclear (RMN) con el objetivo de medir volúmenes de un órgano y una lesión en un marco científico o clínico.

En el ámbito de la investigación biomédica, la segmentación manual de imágenes preclínicas de resonancia magnética nuclear (RMN) resulta un proceso arduo y repetitivo que además suele carecer de consistencia en el dato, ya que la decisión de los límites de segmentación dependen de criterio personal.

En colaboración con la ICTS BioImagen Complutense, se ha desarrollado un prototipo funcional que realiza segmentación automática de uno de los casos que el instituto nos presenta: la segmentación de lesión isquémica en cerebro de ratón. Usando dos modelos, la herramienta realiza el proceso de segmentación sobre cada uno de los cortes, primero sobre el cerebro y segundo sobre la lesión. Después calcula los volúmenes y los devuelve al usuario para su procesamiento posterior.

Debido a la escasez de datos anotados, típica en entornos médicos (30 pacientes de estudio), la metodología se ha fundamentado en el uso de *transfer learning* sobre una arquitectura U-Net. Además, para aportar robustez al prototipo y garantizar la interpretabilidad de las predicciones, paralelamente se aplican técnicas de Inteligencia Artificial Explicable (XAI) como Grad-CAM e *Integrated Gradients*.

Palabras clave

Isquemia cerebral, Segmentación médica, Inteligencia Artificial (IA), Redes Neuronales Convolucionales (CNN), U-Net, Inteligencia Artificial Explicable (XAI), Visión por computadora

Abstract

Biomedical image analysis tool

The present Bachelor's Thesis approaches the design and development of a computer vision based tool focused on the segmentation of Magnetic Resonance Imaging (MRI) with the objective of measuring volumes of organ and lesion in a specific scientific or clinical field.

In the current scope of biomedical research, manual segmentation of preclinical Magnetic Resonance Imaging (MRI) images is an arduous and repetitive process that can lack data consistency, given that the decision for limits of the segmented zone can depend on personal criteria.

In collaboration with ICTS BioImagen Complutense, a functional prototype that achieves automatic segmentation has been developed in one of the cases that the institute presented: segmentation of ischemic lesions in the mouse brain. Using two models based on the U-Net architecture, the tool completes the segmentation process over each of the slices, first with the brain and then over the lesion. Finally, it calculates volumes which are returned to the end user for its posterior processing.

Due to the scarcity of the annotated data, typical in the medical field (30 patients in our dataset), the methodology has been substantiated in the use of transfer learning over the U-Net architecture. Furthermore, to make sure the prototype is robust and predictions' interpretability is guaranteed, eXplainable Artificial Intelligence (XAI) techniques have been implemented, such as Grad-CAM and Integrated Gradients.

Keywords

Cerebral ischemia, medical segmentation, Artificial Intelligence (AI), Convolutional Neural Networks (CNN), U-Net, eXplicable Artificial Intelligence (XAI), Computer vision

Índice

1. Introducción	1
1.1. Contexto, antecedentes y motivación	1
1.2. Objetivos	2
1.2.1. Objetivo general	3
1.2.2. Objetivos específicos	3
1.3. Plan de trabajo	3
1.3.1. Seguimiento del proyecto y reuniones con los tutores	3
1.3.2. Fases de desarrollo	4
1.4. Estructura de la memoria	4
2. Estado de la Cuestión	5
2.1. Conceptos biomédicos: RMN preclínica y lesiones cerebrales	5
2.2. Visión por computador en imagen biomédica	5
2.3. Arquitecturas de segmentación: U-Net	6
2.4. Aprendizaje por transferencia (Transfer Learning)	8
2.5. Explicabilidad en Inteligencia Artificial (XAI)	9
3. Metodología y Desarrollo	13
3.1. Descripción del conjunto de datos (<i>Dataset</i>)	13
3.1.1. Estructura del dataset	13
3.1.2. Tamaño de dataset	14
3.2. Preprocesamiento de imágenes	15
3.2.1. Conversión de datos RAW a formato NIfTI	16
3.2.2. Segmentación manual mediante ROI	16
3.2.3. Generación de máscaras binarias	17
3.2.4. Normalización y adaptación de las imágenes	17
3.3. Arquitectura de los modelos y <i>Transfer Learning</i>	18
3.3.1. Arquitectura U-Net y decisiones de implementación	19
3.3.2. Justificación de la arquitectura y uso de <i>Transfer Learning</i>	20
3.3.3. Estrategia de entrenamiento y ajuste de la salida	21
3.3.4. Funcionamiento conjunto de los modelos en el pipeline de segmentación	22

3.4.	Cuantificación y métricas biomédicas (volumen)	23
3.5.	Integración de explicabilidad	26
3.5.1.	Fundamentos y motivación de la explicabilidad	26
3.5.2.	Adaptación de técnicas de XAI a segmentación	26
3.5.3.	Métodos de explicabilidad empleados	27
3.5.4.	Aplicación al modelo de segmentación de isquemia	28
3.5.5.	Aplicación de explicabilidad al modelo de segmentación cerebral	30
4.	Resultados y Discusión	33
4.1.	Configuración experimental	33
4.2.	Resultados en segmentación cerebral	33
4.2.1.	Resultados cuantitativos	33
4.2.2.	Análisis cualitativo	34
4.2.3.	Resultados de explicabilidad en la segmentación de cerebro . .	35
4.2.4.	Discusión	39
4.3.	Resultados en segmentación de isquemia	39
4.3.1.	Resultados cuantitativos	39
4.3.2.	Naturaleza del problema y subjetividad	40
4.3.3.	Interpretación de métricas	40
4.3.4.	Impacto del threshold	41
4.3.5.	Análisis cualitativo	41
4.3.6.	Resultados de explicabilidad en la segmentación de isquemia .	43
4.3.7.	Discusión crítica del modelo de isquemia	45
4.4.	Análisis comparativo global	46
4.5.	Relación con el objetivo del TFG	46
4.6.	Limitaciones	46
4.7.	Conclusiones del capítulo	46
5.	Conclusiones y Trabajo Futuro	49
	Introduction	51
	Conclusions and Future Work	53
	Contribuciones Personales	55
	Bibliografía	57
A.	Título del Apéndice A	59
B.	Título del Apéndice B	61

Índice de figuras

2.1.	Flujo general de análisis en imagen médica mediante técnicas de visión por computador. A partir de una imagen biomédica pueden aplicarse distintas tareas automáticas, entre ellas la clasificación, la detección y la segmentación, con el objetivo de obtener resultados visuales o cuantitativos que apoyen el análisis posterior. Elaboración propia. . .	6
2.2.	Ejemplo de arquitectura U-Net para segmentación de imágenes. La red sigue una estructura encoder–decoder con conexiones de salto entre niveles de resolución equivalentes. Fuente: Mehrdad Yazdani, Wikimedia Commons, licencia CC BY-SA 4.0.	8
2.3.	Esquema general del aprendizaje por transferencia. Un modelo previamente entrenado se reutiliza como punto de partida para una nueva tarea, aprovechando representaciones ya aprendidas y adaptándolas posteriormente al problema específico. Elaboración propia.	9
2.4.	Esquema general de aplicación de técnicas de explicabilidad visual. A partir de la imagen y de la salida del modelo, un método de XAI genera un mapa de relevancia que permite analizar qué regiones han influido más en la predicción. Elaboración propia.	11
3.1.	Pipeline de procesamiento desde datos RAW hasta el dataset final . .	15
3.2.	Ejemplo de slices de RMN	16
3.3.	Ejemplo de segmentación ROI	17
3.4.	Ejemplo de máscara binaria	18
3.5.	Visualización de superposición de máscaras	18
3.6.	Esquema de la arquitectura U-Net 2D empleada en este trabajo. La figura muestra la entrada de tamaño $120 \times 120 \times 3$, el encoder ResNet50 preentrenado sobre <i>RadImageNet</i> , las conexiones de salto, el decoder basado en UpSampling2D y convoluciones, y la generación de la máscara binaria de salida. Esta misma arquitectura base se utiliza tanto para el modelo de segmentación de cerebro como para el de segmentación de isquemia, diferenciándose únicamente en la máscara objetivo empleada durante el entrenamiento. Elaboración propia.	20

3.7.	Proceso de cálculo del volumen de la lesión a partir de la máscara segmentada. Para cada corte, se obtiene el número de píxeles pertenecientes a la lesión, que se transforma en un área física utilizando la resolución espacial de la imagen en el plano $(\Delta x, \Delta y)$. Posteriormente, la suma de las áreas segmentadas en todos los cortes se combina con el espaciado entre cortes (Δz) para estimar el volumen total de la lesión.	25
3.8.	Ejemplo de mapas de explicabilidad generados sobre una imagen de entrada. Se muestra la imagen original, la máscara predicha y el mapa de relevancia superpuesto.	28
3.9.	Ejemplo de visualización generada por el procedimiento de explicabilidad aplicado al modelo de segmentación de isquemia. Se muestran el corte original de RMN, la máscara de referencia, la predicción del modelo y los mapas de relevancia obtenidos mediante distintos métodos de explicabilidad. La figura ilustra el tipo de salida utilizada para el análisis cualitativo del comportamiento del modelo.	30
3.10.	Ejemplo de visualización generada por el procedimiento de explicabilidad aplicado al modelo de segmentación cerebral. Se muestran, de izquierda a derecha, el corte original de RMN, la máscara de referencia, la máscara predicha por el modelo y los mapas de relevancia obtenidos mediante distintos métodos de explicabilidad. Esta figura ilustra el tipo de salida utilizada para el análisis cualitativo del comportamiento del modelo.	31
4.1.	Evolución del coeficiente Dice por Caso	34
4.2.	Evolución del coeficiente Dice por caso	34
4.3.	Ejemplos cualitativos de segmentación de isquemia en distintos escenarios	35
4.4.	Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación cerebral. Se muestra la imagen original, la máscara manual, la máscara predicha, los mapas obtenidos mediante Grad-CAM, Grad-CAM++ e Integrated Gradients, y la curva de eliminación normalizada.	36
4.5.	Evolución del coeficiente Dice por Caso	39
4.6.	Evolución del coeficiente Dice por caso	41
4.7.	Ejemplos cualitativos de segmentación de isquemia en distintos escenarios	42
4.8.	Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación de isquemia. Se muestran la imagen original, la máscara manual, la máscara predicha y los mapas de relevancia obtenidos mediante Grad-CAM, Grad-CAM++ e Integrated Gradients.	44
4.9.	bland altman	46
4.10.	bland altman	46
4.11.	bland altman	47

Índice de tablas

3.1. Resumen del dataset utilizado	15
3.2. Configuración general del entrenamiento de los modelos de segmentación.	22
3.3. Comparación del rendimiento medio del modelo de isquemia para distintos umbrales de binarización.	23
4.1. Resumen de métricas del modelo de segmentación cerebral	33
4.2. Rendimiento medio del modelo de segmentación cerebral en los cortes analizados para explicabilidad.	36
4.3. Resumen cuantitativo de las métricas de fidelidad para los métodos de explicabilidad aplicados al modelo de segmentación cerebral. . . .	38
4.4. Resumen de métricas del modelo de segmentación de isquemia	39
4.5. Resultados cuantitativos de explicabilidad para los cortes de isquemia correctamente detectados.	45

Introducción

1.1. Contexto, antecedentes y motivación

En el ámbito de la investigación biomédica, el análisis de imágenes de resonancia magnética nuclear (RMN) constituye una herramienta fundamental para el estudio de estructuras anatómicas y el análisis de su evolución. En particular, en estudios preclínicos sobre modelos animales, como el cerebro de ratón, la RMN permite observar la evolución de distintas patologías, proporcionando información relevante para la investigación en neurociencia y el análisis de biomarcadores.

El procesamiento de este tipo de imágenes, conocido como **segmentación**, consiste en delimitar la zona de estudio, denominada **región de interés**, con el objetivo de cuantificar las características del órgano o de la lesión, así como estimar su volumen. Estas tareas resultan esenciales para garantizar la reproducibilidad de los experimentos y la comparabilidad de los resultados entre distintos estudios y sujetos, especialmente en aquellos casos en los que se analiza la evolución temporal de una patología.

Tradicionalmente, como se pudo observar durante las visitas al centro **ICTS BioImagen Complutense**, estas tareas se han realizado de forma manual: El flujo de trabajo habitual consiste en analizar cada uno de los cortes de la resonancia (aproximadamente entre 20 y 50 cortes por sujeto), identificar las regiones de interés y delimitarlas manualmente mediante herramientas de selección específicas, a partir de las cuales se procede posteriormente al cálculo de magnitudes de interés.

Aunque este procedimiento permite obtener resultados experimentales válidos, presenta diversas limitaciones. Por un lado, se trata de un proceso laborioso que consume una gran cantidad de tiempo, especialmente en estudios con un elevado número de sujetos. Esta carga de trabajo supone una inversión significativa de tiempo por parte de los investigadores, lo que puede repercutir en los tiempos de desarrollo de la investigación. Por otro lado, la delimitación manual de ciertas regiones, como las lesiones isquémicas, presenta un grado de ambigüedad, ya que sus fronteras no siempre están claramente definidas. Esto puede introducir variabilidad entre anotaciones en función del criterio del profesional.

A estas limitaciones se suma el crecimiento progresivo de la cantidad de datos generados en los estudios de bioimagen, así como la demanda de análisis detallados

y precisos, lo que dificulta la escalabilidad de los procesos manuales.

En este contexto, surge la necesidad de desarrollar herramientas que permitan agilizar y automatizar de manera supervisada estas tareas, mejorando la eficiencia del proceso y aumentando la consistencia y reproducibilidad de los resultados.

El avance reciente de las técnicas de inteligencia artificial aplicadas a imagen ha demostrado su capacidad para identificar patrones complejos en datos visuales, abriendo la puerta a su aplicación en entornos biomédicos. No obstante, la integración de este tipo de soluciones en contextos reales de trabajo requiere no solo obtener resultados precisos, sino también garantizar que dichos resultados sean interpretables y coherentes desde el punto de vista del dominio de aplicación. Por ello, la motivación de este trabajo no se limita únicamente a la implementación de un modelo automático, sino que se centra en el desarrollo de una herramienta que pueda integrarse dentro del flujo de trabajo existente, aportando valor como sistema de apoyo a la decisión. El objetivo es combinar la automatización con la supervisión por parte del experto, manteniendo el control sobre los resultados finales.

Este Trabajo de Fin de Grado, en colaboración con el centro **ICTS BioImagen Complutense**, pretende dar respuesta a una necesidad real observada en el entorno de investigación. A partir del conocimiento adquirido durante las visitas al centro, el análisis del estado del arte y la revisión de la bibliografía, se plantea el desarrollo de una herramienta basada en modelos supervisados que permita contribuir a la mejora del proceso de análisis de imágenes de resonancia magnética en investigación preclínica, proponiendo una solución que reduzca la carga de trabajo manual y mejore la consistencia de los resultados.

1.2. Objetivos

ESBOZO

- Comprender el flujo de adquisición, procesado y análisis de imágenes de RMN preclínica empleado en ICTS BioImagen Complutense.
- Construir un conjunto de datos a partir de imágenes reales, anotaciones ROI y máscaras binarias de segmentación.
- Diseñar un pipeline de preprocesamiento que permita convertir, normalizar y adaptar las imágenes al entrenamiento de modelos supervisados.
- Entrenar modelos de segmentación automática para cerebro e isquemia cerebral empleando una arquitectura U-Net con aprendizaje por transferencia.
- Calcular métricas cuantitativas de interés biomédico, especialmente el volumen de las regiones segmentadas.
- Incorporar técnicas de inteligencia artificial explicable para analizar la coherencia espacial de las predicciones.
- Evaluar el comportamiento del sistema mediante métricas cuantitativas, análisis cualitativo y discusión crítica de sus limitaciones.

1.2.1. Objetivo general

1.2.2. Objetivos específicos

1.3. Plan de trabajo

El desarrollo de este Trabajo de Fin de Grado se ha organizado de forma progresiva, partiendo de una fase inicial de comprensión del problema biomédico hasta la implementación y evaluación del sistema propuesto. Dado que el proyecto combina aspectos de ingeniería del software, procesamiento de imagen médica, aprendizaje automático y validación experimental, resultó necesario estructurar el trabajo en distintas fases claramente diferenciadas.

Además, al tratarse de un proyecto desarrollado en colaboración con el centro ICTS BioImagen Complutense, el plan de trabajo estuvo condicionado por las necesidades detectadas durante las reuniones de seguimiento y las visitas realizadas al centro. Estas sesiones permitieron orientar las decisiones técnicas hacia un caso de uso real, definir los requisitos funcionales de la herramienta y adaptar el desarrollo a las características del conjunto de datos disponible.

En los siguientes apartados se describe, en primer lugar, el proceso de seguimiento llevado a cabo mediante actas de reunión y, posteriormente, las principales fases de desarrollo seguidas hasta la obtención del prototipo final.

1.3.1. Seguimiento del proyecto y reuniones con los tutores

A lo largo del desarrollo del proyecto se mantuvo un proceso de seguimiento continuado mediante reuniones periódicas con los tutores, tanto de manera presencial como telemática. Con el objetivo de tener registro de la evolución del desarrollo y las decisiones tomadas, se realizaron actas de reunión después de cada encuentro.

Estas actas tuvieron un papel especialmente importante durante las primeras fases del proyecto, ya que permitieron documentar la definición inicial del problema, el contexto de la aplicación y las necesidades del usuario final. Además, en las actas se recogieron los aspectos teóricos y técnicos guiados por los profesores, tanto en el ámbito de la inteligencia artificial como en el de la aplicación biomédica, donde los alumnos también tuvieron una formación básica.

Durante las visitas al centro **ICTS BioImagen Complutense**, las actas permitieron recoger información esencial sobre el flujo de trabajo seguido por los investigadores. Se analizaron ejemplos reales de imágenes y se estudiaron diversas aplicaciones de las RMN tratadas en el centro. Además, se adquirieron nociones básicas sobre el funcionamiento físico de las resonancias magnéticas nucleares, aprendiendo a diferenciar zonas de hiperintensidad e hipointensidad, claves para la elaboración posterior del dataset.

Las actas también reflejan la evolución técnica del proyecto. A medida que avanzó el desarrollo, se tomaron decisiones relacionadas con la estructura del conjunto de datos, la eliminación de cortes poco informativos, la preparación de los notebooks de entrenamiento y la mejora del modelo de segmentación de isquemia. En particular, se decidió utilizar la segmentación cerebral como paso previo para restringir el área

de análisis del modelo de isquemia al tejido cerebral, con el objetivo de reducir falsos positivos y mejorar la coherencia anatómica de las predicciones.

Por último, el seguimiento de las actas permitió incorporar nuevas necesidades detectadas durante el desarrollo, como el uso de notebooks a través de Google Collab para facilitar el acceso a la herramienta por parte de los investigadores, eliminando la necesidad de instalar software adicional y permitiendo un acceso más directo a los resultados.

1.3.2. Fases de desarrollo

El desarrollo del trabajo se ha organizado en varias fases. En primer lugar, se realizó una fase de toma de contacto con el problema biomédico mediante reuniones con los directores del trabajo y visitas al centro ICTS BioImagen Complutense. En esta fase se estudió el proceso de adquisición de imágenes de RMN, la generación de regiones de interés y la forma en la que los investigadores obtienen actualmente medidas cuantitativas a partir de las segmentaciones manuales.

Posteriormente, se abordó la preparación del conjunto de datos. Se seleccionó como caso de estudio la segmentación de lesiones de isquemia cerebral, debido tanto a la disponibilidad de datos proporcionados por el ICTS BioImagen Complutense como a su relevancia dentro de las líneas de investigación actuales del centro. En esta etapa se llevó a cabo la adaptación de las imágenes al formato requerido por los modelos de aprendizaje automático.

A continuación, se diseñó e implementó el pipeline de segmentación automática, compuesto por dos modelos: uno orientado a la segmentación del cerebro y otro a la segmentación de la lesión isquémica. Finalmente, se realizó la evaluación de los resultados obtenidos mediante métricas de segmentación y cuantificación volumétrica, complementando este análisis con técnicas de explicabilidad que permiten estudiar el comportamiento interno de los modelos.

1.4. Estructura de la memoria

La memoria se organiza de la siguiente forma. En el Capítulo 2 se presenta el estado de la cuestión, incluyendo los conceptos biomédicos necesarios, la visión por computador aplicada a imagen médica, las arquitecturas de segmentación, el aprendizaje por transferencia y la inteligencia artificial explicable. En el Capítulo 3 se describe la metodología seguida, desde la construcción del dataset y el preprocesamiento de imágenes hasta la arquitectura de los modelos, la cuantificación volumétrica y la integración de explicabilidad. En el Capítulo 4 se presentan y discuten los resultados obtenidos para la segmentación cerebral y la segmentación de isquemia. Finalmente, el Capítulo 5 recoge las conclusiones del trabajo y las principales líneas de trabajo futuro.

Estado de la Cuestión

2.1. Conceptos biomédicos: RMN preclínica y lesiones cerebrales

2.2. Visión por computador en imagen biomédica

La visión por computador o visión artificial es un campo de la inteligencia artificial que se centra en desarrollar métodos para transformar las imágenes del mundo real en información que pueda ser interpretada por un ordenador. La visión por computador aplicada a imagen biomédica consiste en usar técnicas automáticas para analizar imágenes biomédicas. Estas imágenes pueden venir de resonancia magnética, tomografía computarizada, ecografía o radiografía. Cada modalidad muestra la información de una forma distinta y eso afecta al tipo de análisis que se puede hacer.

En medicina, muchas veces no basta con decir si una imagen tiene o no una lesión. También interesa saber dónde está, cuánto ocupa y qué parte del órgano afecta. Por eso se usan tareas como la detección y la segmentación. Aunque la detección es una tarea parecida a la clasificación, la segmentación va un paso más allá, ya que separa píxel a píxel la zona que se quiere estudiar del resto de la imagen.

Esta máscara de segmentación permite medir, por ejemplo, el área de una lesión en un corte o su volumen total si se trabaja con varios cortes de una resonancia. Esto es útil porque convierte una observación visual en un dato numérico, no elimina la revisión experta, pero sí puede hacer el proceso más rápido y más fácil de comparar entre casos.

En los últimos años, las redes neuronales convolucionales han tenido un gran uso en imagen biomédica. Estas redes aprenden patrones directamente desde las imágenes, sin tener que definir a mano todas las características y pueden detectar bordes, cambios de intensidad o formas más complejas. En revisiones como la de (?) se recoge su uso en tareas de clasificación, detección y segmentación médica.

El problema es que en imagen médica es la falta de dato. Anotar imágenes lleva tiempo y suele requerir conocimiento experto. En segmentación, además, no se etiqueta solo la imagen completa, sino que se dibuja la región de interés, esto hace que los conjuntos de datos sean más pequeños que en otros campos.

También hay variaciones entre imágenes. Cambia el equipo, cambia el protocolo y cambia la modalidad. Incluso dos personas pueden segmentar de forma algo distinta una misma lesión si el borde no se ve claro. Por eso, en este tipo de trabajos no basta con entrenar un modelo y mostrar una predicción. Hay que comprobar si el resultado tiene sentido y si las medidas que se obtienen son coherentes.

En este Trabajo de Fin de Grado se aplica visión por computador al análisis de resonancias magnéticas preclínicas. El objetivo es automatizar parte de la segmentación del cerebro y de la lesión, y después calcular medidas como el volumen.




Figura 2.1: Flujo general de análisis en imagen médica mediante técnicas de visión por computador. A partir de una imagen biomédica pueden aplicarse distintas tareas automáticas, entre ellas la clasificación, la detección y la segmentación, con el objetivo de obtener resultados visuales o cuantitativos que apoyen el análisis posterior. Elaboración propia.

2.3. Arquitecturas de segmentación: U-Net

La arquitectura U-Net, propuesta originalmente por Ronneberger et al. en 2015, fue diseñada para abordar las particularidades del análisis de imágenes biomédicas, un dominio con necesidades distintas a las de la visión por computador aplicada a imágenes naturales (Ronneberger et al., 2015). En segmentación médica no basta con clasificar una imagen completa, sino que es necesario asignar una etiqueta a cada píxel o vóxel de la imagen de entrada, con el objetivo de delimitar con precisión estructuras anatómicas o regiones patológicas.

Además, los conjuntos de datos biomédicos anotados suelen ser reducidos, principalmente por restricciones de privacidad, disponibilidad limitada de datos y el elevado coste temporal y económico de la anotación experta. Por este motivo, los modelos destinados a este tipo de imágenes requieren arquitecturas eficientes en datos, capaces de aprender a partir de un número limitado de ejemplos.

U-Net presenta una estructura simétrica en forma de “U”, compuesta por un camino contractivo o *encoder* y un camino expansivo o *decoder*. Esta organización responde a un objetivo funcional: procesar la información visual de forma jerárquica, combinando contexto semántico con precisión espacial.

El camino contractivo actúa como extractor jerárquico de características. En la formulación original de U-Net, este bloque aplica de forma repetida dos convoluciones 3×3 , seguidas de funciones de activación ReLU, y una operación de reducción espacial mediante *max pooling* 2×2 . A medida que disminuye la resolución espacial de los mapas de características, el número de canales aumenta progresivamente. Por ejemplo, una imagen puede pasar de una resolución de 128×128 a 64×64 , mientras que el número de filtros aumenta de 32 a 64, después a 128 y finalmente a 256 o 512. Este diseño permite ampliar el campo receptivo de la red y aprender representaciones cada vez más abstractas.

En las primeras capas, la red captura detalles locales de alta frecuencia, como bordes, texturas y gradientes de intensidad. Estas características son especialmente relevantes en resonancia magnética, ya que ayudan a definir los límites inmediatos de una región de interés. A medida que la red profundiza y la resolución espacial disminuye, el campo receptivo efectivo aumenta, permitiendo que las capas más profundas representen patrones de mayor nivel. En este punto, el *bottleneck* concentra la información semántica de la imagen, es decir, el “qué” aparece en ella, aunque a costa de perder parte de la precisión espacial, es decir, el “dónde”.

El camino expansivo trata de revertir este proceso para reconstruir el mapa de segmentación final. Para ello, aumenta progresivamente la resolución de los mapas de características hasta recuperar el tamaño espacial necesario para generar una máscara de salida. Sin embargo, un simple sobremuestreo de las características profundas puede producir contornos imprecisos, ya que parte de la información espacial fina se pierde durante las operaciones de reducción del *encoder*. Esta limitación se aborda mediante uno de los elementos más característicos de U-Net: las conexiones de salto o *skip connections*.

Las *skip connections*, implementadas habitualmente mediante concatenación, permiten fusionar los mapas de características del *encoder* con los mapas sobremuestreados del *decoder* en niveles de resolución equivalentes. De esta forma, el *decoder* recibe simultáneamente información semántica procedente de las capas profundas e información espacial de alta resolución procedente de las capas iniciales.

De manera simplificada, si x_l representa la salida del nivel l del *encoder* e y_{l+1} representa la salida del nivel más profundo del *decoder*, la entrada del nivel correspondiente del *decoder* puede expresarse como:

$$\text{Input}_{\text{decoder},l} = \text{Concat}(\text{Up}(y_{l+1}), x_l)$$

donde $\text{Up}(\cdot)$ representa la operación de sobremuestreo y $\text{Concat}(\cdot)$ la concate-

nación de características. Esta combinación permite recuperar detalle espacial sin renunciar al contexto global aprendido por la red.

Como se muestra en la Figura 2.2, U-Net sigue una estructura encoder-decoder en la que las conexiones de salto permiten combinar información profunda con detalles espaciales de mayor resolución.




Figura 2.2: Ejemplo de arquitectura U-Net para segmentación de imágenes. La red sigue una estructura encoder-decoder con conexiones de salto entre niveles de resolución equivalentes. Fuente: Mehrdad Yazdani, Wikimedia Commons, licencia CC BY-SA 4.0.

2.4. Aprendizaje por transferencia (Transfer Learning)

El aprendizaje por transferencia consiste en partir de un modelo previamente entrenado y adaptarlo a una tarea nueva. En lugar de entrenar una red desde cero, se aprovechan pesos que ya han aprendido a extraer información útil de otras imágenes.

Esta técnica resulta especialmente útil cuando hay pocos datos disponibles, algo frecuente en imagen médica. Conseguir imágenes anotadas no es sencillo y, en el caso de la segmentación, el proceso es todavía más costoso, ya que no basta con asignar una etiqueta a cada imagen. También es necesario delimitar manualmente la región de interés, y esa máscara debe estar bien alineada si después se va a utilizar para calcular volúmenes.

Cuando una red profunda se entrena desde cero con pocos ejemplos, puede aparecer sobreajuste. En ese caso, el modelo aprende demasiado bien los ejemplos de entrenamiento, pero no generaliza correctamente ante imágenes nuevas. El aprendizaje por transferencia ayuda a reducir este riesgo, ya que el modelo parte de características visuales aprendidas previamente.

En visión por computador se ha utilizado tradicionalmente ImageNet como conjunto de preentrenamiento. Sin embargo, ImageNet está formado por imágenes naturales, como animales, objetos o escenas cotidianas, que son bastante distintas de

las imágenes biomédicas. Por este motivo, en aplicaciones biomédicas puede resultar más adecuado utilizar modelos preentrenados con datos radiológicos.

RadImageNet es un ejemplo de este tipo de recurso, ya que incluye imágenes médicas de distintas modalidades, como resonancia magnética, tomografía computarizada y ecografía (Mei et al., 2022). El uso de pesos preentrenados en un dominio más cercano al de la imagen médica puede aportar una base más adecuada que la obtenida únicamente a partir de imágenes naturales.

En arquitecturas como U-Net, el aprendizaje por transferencia puede aplicarse utilizando un encoder preentrenado. De esta forma, el encoder actúa como extractor de características, mientras que el decoder aprende a generar la máscara de segmentación correspondiente. Así se aprovecha una base visual ya entrenada, pero el modelo sigue adaptándose a la tarea concreta.

En este tipo de trabajos, el *Transfer Learning* no se utiliza solo como una mejora adicional, sino como una respuesta a una limitación práctica del problema: la escasez de datos anotados. Partir de un modelo previamente entrenado permite trabajar con redes de mayor capacidad sin depender completamente de disponer de un conjunto de datos grande.




Figura 2.3: Esquema general del aprendizaje por transferencia. Un modelo previamente entrenado se reutiliza como punto de partida para una nueva tarea, aprovechando representaciones ya aprendidas y adaptándolas posteriormente al problema específico. Elaboración propia.

2.5. Explicabilidad en Inteligencia Artificial (XAI)

La Inteligencia Artificial Explicable, o XAI, agrupa técnicas que permiten entender mejor por qué un modelo produce una salida determinada. Esta cuestión

es especialmente relevante en redes neuronales profundas, donde no resulta sencillo interpretar directamente qué ocurre dentro del modelo.

En imagen médica, la explicabilidad tiene un papel importante porque el resultado del modelo no debería analizarse solo mediante métricas. También interesa comprobar si la red está utilizando zonas relevantes de la imagen. Por ejemplo, si el modelo segmenta una lesión, lo esperable es que la información más influyente esté cerca de esa lesión y no en el fondo, en los bordes de la imagen o en ruido.

Una forma habitual de estudiar este comportamiento es generar mapas de calor. Estos mapas muestran qué zonas de la imagen han influido más en la salida del modelo, de manera que permiten revisar visualmente si la predicción se apoya en regiones coherentes. No demuestran por sí solos que el modelo sea correcto, pero sí aportan información útil sobre su comportamiento.

Entre los métodos más utilizados se encuentran los mapas de saliencia, Integrated Gradients y Grad-CAM. Los mapas de saliencia estudian cómo cambia la salida del modelo cuando varían los píxeles de entrada. Integrated Gradients compara la imagen con una referencia y calcula la contribución de cada píxel a la predicción (Sundararajan et al., 2017). Grad-CAM, por su parte, utiliza los gradientes de una salida concreta sobre una capa convolucional para generar un mapa de relevancia (Selvaraju et al., 2019).

Muchos de estos métodos se plantearon inicialmente para clasificación, donde suele explicarse la probabilidad asociada a una clase. En segmentación, el caso es distinto, ya que la salida del modelo no es un único valor, sino un mapa de probabilidades por píxel. Por esta razón, antes de aplicar estas técnicas es necesario definir qué parte de la salida se quiere explicar.

Esta decisión cambia la interpretación de la explicación. No es lo mismo explicar toda la activación de la clase lesión que explicar únicamente la región segmentada por el modelo. Por ello, cuando se utilizan técnicas de XAI en segmentación, conviene indicar con claridad qué salida se explica y cómo se ha generado el mapa resultante.

La explicabilidad no sustituye a métricas como Dice o IoU, ya que estas siguen siendo necesarias para medir el parecido entre la máscara predicha y la máscara manual. Sin embargo, dichas métricas no indican por qué el modelo ha producido una predicción concreta. Los métodos de XAI añaden otra forma de revisar el resultado, centrada en analizar qué zonas de la imagen han influido en la decisión del modelo.

En este trabajo, la explicabilidad se utiliza como apoyo al análisis del modelo, con el objetivo de comprobar si las predicciones se basan en regiones coherentes con el problema biomédico estudiado.




Figura 2.4: Esquema general de aplicación de técnicas de explicabilidad visual. A partir de la imagen y de la salida del modelo, un método de XAI genera un mapa de relevancia que permite analizar qué regiones han influido más en la predicción. Elaboración propia.

Metodología y Desarrollo

3.1. Descripción del conjunto de datos (*Dataset*)

El conjunto de datos empleado está compuesto por imágenes de resonancia magnética nuclear (*RMN*) preclínicas de cerebros de ratón, obtenidas en el contexto de colaboración con el centro *ICTS BioImagen Complutense*. Estas imágenes constituyen la base para el entrenamiento y evaluación de los modelos de segmentación automática de la estructura cerebral y las lesiones asociadas, en este caso, la lesión por isquemia cerebral.

Tal y como se establece en los objetivos del proyecto, el dataset ha sido diseñado para permitir tanto la delimitación anatómica del cerebro como la identificación de regiones patológicas, lo que implica la coexistencia de dos tipos de anotaciones: segmentación de órgano sano y segmentación de lesión.

3.1.1. Estructura del dataset

El dataset presenta una estructura jerárquica, en la que cada caso de estudio se presenta en una carpeta individual con la denominación "*CASE n*". Para cada caso, se dispone de los siguientes elementos:

3.1.1.1. Volúmenes MRI en formato NIfTI (*.nii*)

El formato **NIfTI** (*Neuroimaging Informatics Technology Initiative*) es el estándar en neuroimagen por su capacidad de almacenar datos volumétricos junto a metadatos asociados, como se describe en la documentación oficial estándar (Neuroimaging Informatics Technology Initiative, 2003) .

Además, se ha decidido usar NIfTI frente a otros formatos debido a que es uno de los estándares más utilizados en el ecosistema de procesamiento de imágenes médicas en Python, debido a su compatibilidad con librerías ampliamente empleadas como *nibabel*, que permiten la carga, manipulación y análisis de volúmenes de neuroimagen de forma eficiente (Neuroimaging Informatics Technology Initiative, 2003; Developers, 2024).

Su estructura interna está constituida por una matriz de datos tridimensionales,

en la cual cada voxel representa una medida de intensidad, la señal RMN. Además, en su cabecera se almacenan metadatos críticos para el estudio de cada sujeto, entre los cuales la resolución espacial (tamaño del voxel), necesario para calcular los volúmenes de una región de la imagen, orientación, el tipo de dato (en nuestro caso `\int16`) y el identificador del sujeto y de estudio.

Cada uno de estos archivos, facilitados por el centro *ICTS BioImagen Com-plutense*, contienen 28 *slices*. Las *slice* son cortes bidimensionales que muestran una sección anatómica del cerebro, los cuales son utilizados para analizar el órgano y la lesión, así como para calcular posteriormente su volumen en base al tamaño de Voxel definido.

3.1.1.2. Regiones de interés (.ROI)

Las **ROI** (*Regions Of Interest*) son una herramienta estándar en análisis de imagen médica para delimitar manualmente estructuras anatómicas o patológicas relevantes (Neuroimaging Informatics Technology Initiative, 2003). Se tratan de anotaciones geométricas representadas como contornos que aíslan la región de estudio, delimitando su extensión espacial. Estas selecciones se realizan para cada una de las *slices* de la RMN, definiendo así la estructura anatómica de la característica de estudio. Para cada caso de estudio, se cuenta con dos conjuntos de datos **ROI**, el conjunto de selección del cerebro y el conjunto de selección de la isquemia cerebral. Cabe destacar que, especialmente en el caso de la isquemia, las ROI presentan bordes difusos, regiones de transición (gradientes de intensidad) y variabilidad entre anotadores

3.1.1.3. Máscaras de segmentación (.png)

Las máscaras son la representación final utilizada en el entrenamiento supervisado. Estas máscaras consisten en imágenes 2D binarias en las que se representan con los valores 0 (color negro) el fondo y 255 (color blanco) la región de selección. Estas máscaras son producidas a partir de las selecciones ROI, respetando su tamaño y alineación, y constituyen el *ground truth* del entrenamiento. Se opta por trabajar con slices bidimensionales en lugar de volúmenes tridimensionales completos debido a la reducción del coste computacional y a la disponibilidad de arquitecturas preentrenadas en 2D.

3.1.2. Tamaño de dataset

El conjunto de datos utilizado está compuesto por un total de 30 casos de estudio. Estos incluyen imágenes de resonancia magnética correspondientes a lesiones cerebrales de tipo isquémico, tanto transitorias como permanentes, adquiridas en dos instantes temporales distintos: 4 horas y 24 horas tras la inducción de la lesión. Esta configuración permite analizar la evolución temporal del daño cerebral, abarcando desde fases tempranas hasta estados más avanzados, así como distintos grados de reversibilidad del tejido afectado.

Adicionalmente, se han incorporado casos de control sin presencia de lesión, con el objetivo de mejorar la capacidad del modelo para discriminar entre tejido

sano y patológico, contribuyendo así a una mayor robustez en la clasificación y segmentación.

Pese a que cada uno de estos 30 casos cuenta con un total de 28 *slices*, se han descartado los 2 primeros y el último corte de cada resonancia. Esto se debe a la baja calidad de señal en estas regiones, donde la presencia de ruido y artefactos compromete la fiabilidad de las anotaciones y puede introducir sesgos en el entrenamiento del modelo. Tras esta limpieza, se cuenta con un total de 750 imágenes bidimensionales utilizadas como entrada del modelo.

Para cada una de estas *slices*, se dispone de anotaciones manuales en forma de máscaras binarias correspondientes a dos tareas de segmentación: cerebro e isquemia. En el caso de la segmentación cerebral, esto supone un total de **750 máscaras de *ground truth***. Para la segmentación de isquemia, el número de máscaras efectivas es menor ya que únicamente están presentes en aquellos casos donde existe lesión. Como media, se cuenta con 9 máscaras de selección de isquemia por sujeto.

En conjunto, considerando ambas tareas, el dataset incluye más de 1.000 anotaciones de *ground truth*, lo que proporciona un volumen significativo de datos etiquetados a nivel de píxel para el entrenamiento supervisado del modelo.

Número de casos	30
Slices por caso	28 (25 utilizados)
Imágenes totales	750
Máscaras cerebro	750
Máscaras isquemia (media)	~270
Resolución	120x120

Tabla 3.1: Resumen del dataset utilizado

3.2. Preprocesamiento de imágenes

El preprocesamiento de imágenes constituye una etapa crítica en el pipeline de entrenamiento, ya que garantiza la homogeneidad de los datos de entrada y mejora la estabilidad del modelo. Para obtener los datos necesarios para formar el dataset, el procesamiento ha sido realizado por los alumnos bajo las directrices y supervisión de los profesionales del *ICTS BioImagen Complutense*.

El procesamiento de las imágenes, desde la MRI en formato RAW (.bruker) hasta el dataset final usado para el entrenamiento, se describe con el siguiente pipeline:



Figura 3.1: Pipeline de procesamiento desde datos RAW hasta el dataset final

3.2.1. Conversión de datos RAW a formato NIfTI

Las imágenes originales son adquiridas en formato propietario del fabricante del escáner RMN utilizado (`.bruker`), el cual contiene tanto la señal de resonancia magnética como información específica del dispositivo. Sin embargo, este formato no es directamente compatible con las herramientas estándar de procesamiento de imagen médica ni con los frameworks de aprendizaje profundo.

Por este motivo, se realiza una conversión a formato **NIfTI**, el cual permite trabajar con los datos de manera más flexible, amplia y estándar.

Durante este proceso, se preserva la información tridimensional original, así como los parámetros necesarios para el análisis cuantitativo posterior.

Para la realización de este proceso, así como de las etapas posteriores de segmentación manual, se ha empleado el software *MRI File Manager*, una herramienta de código abierto para la gestión y conversión de datos de resonancia magnética. Asimismo, para la correcta utilización del software y la comprensión del flujo de procesado de imágenes, se ha estudiado el manual proporcionado por la **Universidad Complutense de Madrid** sobre el tratamiento de imágenes de resonancia magnética mediante *ImageJ*. Universidad Complutense de Madrid (s.f.).




Figura 3.2: Ejemplo de slices de RMN

3.2.2. Segmentación manual mediante ROI

Una vez obtenidos los volúmenes en formato NIfTI, se procede a la segmentación manual de las estructuras de interés mediante la definición de regiones de interés (ROI). Este proceso ha sido realizado utilizando las herramientas *MRIFileManager* junto con la librería *ImageJ*, siguiendo el manual de uso y bajo la supervisión de expertos del centro ICTS BioImagen Complutense.

Las ROI se definen como contornos sobre cada *slice*, delimitando tanto el cerebro completo como las regiones afectadas por isquemia. Este proceso requiere una interpretación visual experta, especialmente en el caso de las lesiones isquémicas, donde los bordes no están claramente definidos y existen gradientes de intensidad. Como consecuencia, las anotaciones presentan un cierto grado de subjetividad, lo cual constituye una limitación inherente al problema abordado.




Figura 3.3: Ejemplo de segmentación ROI

3.2.3. Generación de máscaras binarias

A partir de las anotaciones ROI, se generan máscaras binarias que representan la información de segmentación en un formato adecuado para el entrenamiento supervisado.

Este proceso ha sido implementado mediante un script específico desarrollado en Python, que permite transformar las regiones definidas por contornos en imágenes discretas binarias alineadas con las *slices* originales. En estas máscaras, cada píxel se etiqueta como fondo (valor 0) o región de interés (valor 255), garantizando la correspondencia espacial con la imagen de entrada.

Adicionalmente, el script realiza las operaciones de adaptación necesarias para el entrenamiento del modelo, incluyendo el redimensionado de las imágenes y máscaras a una resolución uniforme (120px x 120px), así como la interpolación correspondiente. Este paso es crítico para asegurar la coherencia dimensional del dataset y su compatibilidad con la arquitectura de la red neuronal empleada.

El desarrollo de esta herramienta ha permitido automatizar el proceso de generación de *ground truth*, asegurando la consistencia del dataset y reduciendo posibles errores derivados de la intervención manual. Asimismo, facilita la reutilización del pipeline por parte de usuarios con menor experiencia técnica, permitiendo la generación de nuevos conjuntos de entrenamiento y el reentrenamiento de los modelos de forma más accesible. (**Agregar enlace a notebook**)

3.2.4. Normalización y adaptación de las imágenes

Con el objetivo de garantizar la homogeneidad de los datos de entrada, las imágenes y sus máscaras son sometidas a un proceso de adaptación previo al entrenamiento.

En primer lugar, todas las imágenes son redimensionadas a una resolución de 120x120 píxeles. Esta decisión permite adaptar los datos a la arquitectura de la red neuronal empleada y reducir el coste computacional.

Durante este proceso se aplica interpolación, lo que puede introducir suavizado en los bordes y pérdida de detalle en estructuras pequeñas.




Figura 3.4: Ejemplo de máscara binaria

Asimismo, las intensidades de las imágenes, originalmente almacenadas en formato entero (`int16`), se convierten a formato de coma flotante (`float32`) y se normalizan para estabilizar el proceso de entrenamiento.

Por último, tanto las máscaras de entrenamiento como las *slices* de la RMN se orientan y se muestra una superposición para asegurar que el entrenamiento va a realizarse de manera correcta, alineando la máscara de entrenamiento con el órgano.




Figura 3.5: Visualización de superposición de máscaras

3.3. Arquitectura de los modelos y *Transfer Learning*

Tras realizar un preprocesamiento de las imágenes para su uso en el entrenamiento, procedemos a definir la arquitectura a alto nivel de la aplicación de segmentación automática. En el caso de uso actual que nos presenta ICTS BioImagen Complutense, requieren la automatización de la medición de volúmenes de la lesión isquémica en el cerebro, además de la afectación en este órgano; por lo que es necesaria la segmentación automática del órgano y la lesión en el paciente, las cuales realizaremos a través de modelos de visión por computadora.

Para esta tarea, alistamos la arquitectura U-Net para crear dos modelos, entrenados con las mismas imágenes pero con distintas máscaras binarias. Aunque existen

múltiples variantes de UNet (UNet++, Attention UNet, ResUNet), se decide usar UNet como la estructura básica, teniendo en cuenta ventajas e inconvenientes en características técnicas, capacidad y costes de computación, que se expondrán más adelante en esta sección.

Debido al bajo número de datos anotados, habitual en el ámbito biomédico, usaremos además *Transfer Learning*, una técnica de *Deep Learning* usada para entrenar redes neuronales en base a otros modelos ya entrenados, para un caso de uso más concreto. Para esto, usaremos los pesos del modelo RadImageNet, un modelo entrenado en imágenes de MRI, TAC y Ecografía.

Tras el entrenamiento, se observó una clara "sobresgmentación" sobre los casos de prueba en el caso de la isquemia. Para intentar mitigar este problema, se aplicaron varias estrategias, entre ellas cambiar la función de pérdida para penalizar los falsos positivos, pero se acabó eligiendo una estrategia de umbral del 0.8 elegido en base a los resultados en error absoluto y métricas de validación.

Además, es completamente necesaria la aplicación de técnicas de Inteligencia Artificial Explicable para proporcionar robustez al análisis, verificar que el modelo basa sus predicciones en regiones anatómica y patológicamente relevantes, y mejorar la confianza en los resultados obtenidos.

3.3.1. Arquitectura U-Net y decisiones de implementación

La arquitectura principal empleada en este trabajo para la segmentación automática se basa en una U-Net 2D, la cual se repite en los dos modelos desarrollados (cerebro e isquemia). En nuestro caso, esta arquitectura se adaptó para trabajar con cortes bidimensionales de resonancia magnética preclínica, de manera que cada muestra de entrada se representa como una imagen en escala de grises redimensionada a 120×120 píxeles. Además, dado que el encoder seleccionado requiere tres canales de entrada, cada imagen monocanal se replicó tres veces antes de ser introducida en la red.

A nivel estructural, la red mantiene el esquema clásico encoder-decoder característico de U-Net. En la rama contractiva, el encoder **ResNet50** actúa como extractor jerárquico de características, generando representaciones cada vez más abstractas de la imagen de entrada conforme aumenta la profundidad de la red. A su vez, de este encoder se obtienen varios mapas de características intermedios que posteriormente se reutilizan en el decoder a través de conexiones de salto, preservando así información espacial de alta resolución que resulta fundamental para conseguir una segmentación precisa Ronneberger et al. (2015). En la rama expansiva, la máscara de salida se reconstruye mediante varias etapas sucesivas de sobremuestreo y concatenación con estos mapas intermedios.

En la implementación del decoder se optó por una estrategia de sobremuestreo mediante **UpSampling2D** seguida de convoluciones convencionales, en lugar de utilizar convoluciones transpuestas. Esta decisión permite separar el aumento de resolución del refinamiento de características y ayuda a reducir la aparición de artefactos tipo *checkerboard*, asociados a ciertas configuraciones de deconvolución Odena et al. (2016).

En cuanto a la salida del modelo, esta se obtiene mediante una convolución

1×1 con activación sigmoideal, lo que permite generar una máscara binaria de probabilidad por píxel para la clase objetivo. Esta formulación es coherente con el problema planteado, ya que tanto la segmentación del cerebro como la de la lesión se modelan como tareas de segmentación binaria, donde cada píxel debe clasificarse como perteneciente o no a la región de interés.

Como se muestra en la Figura 3.6, ambos modelos comparten la misma arquitectura base, diferenciándose únicamente en la máscara objetivo empleada durante el entrenamiento, ya que uno se orienta hacia la segmentación del cerebro y el otro hacia la segmentación de la lesión isquémica.




Figura 3.6: Esquema de la arquitectura U-Net 2D empleada en este trabajo. La figura muestra la entrada de tamaño $120 \times 120 \times 3$, el encoder **ResNet50** preentrenado sobre *RadImageNet*, las conexiones de salto, el decoder basado en **UpSampling2D** y convoluciones, y la generación de la máscara binaria de salida. Esta misma arquitectura base se utiliza tanto para el modelo de segmentación de cerebro como para el de segmentación de isquemia, diferenciándose únicamente en la máscara objetivo empleada durante el entrenamiento. Elaboración propia.

3.3.2. Justificación de la arquitectura y uso de *Transfer Learning*

Aunque existen variantes más complejas de esta arquitectura, como U-Net++ Zhou et al. (2018) o Attention U-Net Oktay et al. (2018), se decide utilizar U-Net como estructura base del sistema. Esta elección se toma teniendo en cuenta que, aunque dichas variantes introducen mejoras interesantes a nivel arquitectónico, también aumentan la complejidad del modelo y el número de elementos a ajustar durante el entrenamiento. En nuestro caso, al trabajar con un conjunto de datos reducido y dentro del alcance de un TFG, resulta más razonable partir de una arquitectura ya consolidada en segmentación biomédica, suficientemente robusta y más sencilla de controlar experimentalmente Ronneberger et al. (2015). De este modo, en lugar de añadir complejidad extra desde la propia arquitectura, se opta por mantener una U-Net base y reforzarla mediante *transfer learning*, buscando así un equilibrio entre capacidad de segmentación, coste computacional y facilidad de implementación.

Además, debido al bajo número de datos anotados disponibles, se optó por aplicar *Transfer Learning*, una técnica de *Deep Learning* especialmente útil cuando no se dispone de un conjunto de entrenamiento lo suficientemente grande como para entrenar un modelo profundo desde cero. Para ello, se incorporó un encoder **ResNet50** preentrenado con pesos de *RadImageNet*, con el objetivo de partir de una base de conocimiento visual ya aprendida en imagen médica, en lugar de comenzar con una inicialización aleatoria de los pesos. Esta decisión está respaldada por el trabajo de

Mei et al., donde se muestra que los modelos preentrenados en *RadImageNet* pueden servir como un punto de partida eficaz para tareas posteriores de imagen biomédica Mei et al. (2022). De este modo, la U-Net implementada en este trabajo no parte de un encoder entrenado desde cero, sino de un backbone previamente adaptado al dominio radiológico, lo que refuerza la justificación de esta elección.

En conjunto, ambas decisiones responden a una misma necesidad: disponer de un modelo con suficiente capacidad de representación para segmentar estructuras biomédicas complejas, pero que al mismo tiempo pueda entrenarse de forma estable en un contexto de datos limitados. Por ello, en lugar de recurrir a variantes arquitectónicas más complejas o a una inicialización completamente aleatoria, se optó por una arquitectura base más controlable reforzada mediante *Transfer Learning*.

3.3.3. Estrategia de entrenamiento y ajuste de la salida

Respecto al proceso de entrenamiento, se siguió una estrategia en dos fases. En una primera etapa, el encoder preentrenado permaneció congelado y únicamente se entrenó la parte decodificadora de la red, de forma que el modelo pudiera adaptarse a la tarea concreta sin modificar todavía las representaciones aprendidas previamente. En una segunda etapa, se descongelaron las últimas capas del encoder para realizar un ajuste fino controlado del modelo completo. Con ello se buscó mantener el conocimiento transferido desde el preentrenamiento, pero permitiendo al mismo tiempo cierta especialización del extractor de características al dominio concreto de la resonancia magnética preclínica.

La función de pérdida seleccionada fue una combinación de entropía cruzada binaria y pérdida Dice ($BCE + Dice\ loss$). Esta elección se tomó porque permite optimizar simultáneamente dos aspectos importantes de la segmentación: por un lado, la clasificación correcta de cada píxel de forma individual y, por otro, el grado de solapamiento global entre la máscara predicha y la máscara de referencia. Mientras que la componente BCE penaliza errores locales de clasificación, la componente Dice resulta especialmente útil en segmentación médica cuando existe un claro desbalance entre fondo y región objetivo, como ocurre con frecuencia en la delimitación de lesiones pequeñas Milletari et al. (2016). Como métrica principal de seguimiento durante el entrenamiento se utilizó el coeficiente Dice, por ofrecer una medida directa del grado de coincidencia entre la segmentación automática y la segmentación manual.

A nivel de configuración, el entrenamiento se realizó con el optimizador Adam y un tamaño de lote de 4. En la primera fase se utilizó una tasa de aprendizaje de 10^{-4} , que posteriormente se redujo a 10^{-5} durante la fase de ajuste fino del encoder. En total, el entrenamiento quedó estructurado en 25 épocas con el encoder congelado y 10 épocas adicionales de *fine-tuning*, incorporando además una partición de validación para monitorizar la evolución del modelo y seleccionar configuraciones estables.

Tras los primeros experimentos con el modelo de isquemia, se observó que el umbral de binarización influía de forma directa tanto en la calidad espacial de la segmentación como en la precisión de la cuantificación volumétrica. Por ello, se evaluaron distintos valores de umbral entre 0.50 y 0.95, comparando para cada uno

Tabla 3.2: Configuración general del entrenamiento de los modelos de segmentación.

Parámetro	Valor
Arquitectura base	U-Net 2D con encoder ResNet50
Tamaño de entrada	$120 \times 120 \times 3$
Optimizador	Adam
Tamaño de lote	4
Función de pérdida	BCE + Dice Loss
Métrica principal	Coficiente Dice
Tasa de aprendizaje (fase 1)	10^{-4}
Tasa de aprendizaje (fase 2)	10^{-5}
Épocas con encoder congelado	25
Épocas de <i>fine-tuning</i>	10
Salida del modelo	Máscara probabilística con activación sigmoideal

de ellos el coeficiente Dice medio, el error absoluto de volumen y el error relativo porcentual.

Los resultados mostraron que el mayor valor de Dice medio se obtenía con un umbral de 0.50, con una puntuación de 0.8323. Sin embargo, al aumentar progresivamente el umbral, el error volumétrico disminuía de forma notable, alcanzando su valor mínimo con un umbral de 0.80, donde se obtuvo un error absoluto de 0.0001 ml y un error relativo del 0.86 %. A partir de ese punto, incrementos adicionales del umbral empeoraban de nuevo tanto el error absoluto como el relativo, además de producir una ligera caída adicional en Dice.

Estos resultados indican que el umbral óptimo depende del criterio que se quiera priorizar. Mientras que un umbral de 0.50 maximiza ligeramente el solapamiento espacial entre la máscara predicha y la manual, un umbral de 0.80 ofrece el mejor compromiso para la cuantificación del volumen de la lesión, que constituye uno de los objetivos principales de la herramienta desarrollada. Por este motivo, se adoptó finalmente un umbral de 0.80 en la fase de inferencia.

Conviene señalar que este proceso de ajuste del umbral se consideró necesario únicamente para el modelo de segmentación de isquemia. En el caso del modelo de cerebro, los resultados obtenidos fueron ya suficientemente estables y elevados con la configuración estándar, alcanzando un Dice medio 3D de 0.969 y un error relativo medio del 3.77 %, por lo que no se introdujeron ajustes adicionales en la salida.

3.3.4. Funcionamiento conjunto de los modelos en el pipeline de segmentación

Aunque los dos modelos desarrollados comparten la misma arquitectura base, no cumplen la misma función dentro del sistema. El modelo de segmentación de cerebro se utiliza como primer paso del pipeline, ya que permite delimitar automáticamente el órgano y restringir la región de análisis al tejido cerebral. Esta segmentación previa resulta especialmente útil porque elimina de la entrada información irrelevante del resto de la imagen, reduciendo así el ruido y facilitando que el análisis posterior se

Tabla 3.3: Comparación del rendimiento medio del modelo de isquemia para distintos umbrales de binarización.

Umbral	Dice medio	Error absoluto (ml)	Error relativo (%)	Casos procesados
0.50	0.8323	0.0009	6.65	3
0.55	0.8310	0.0008	5.89	3
0.60	0.8308	0.0007	4.95	3
0.65	0.8314	0.0005	3.85	3
0.70	0.8301	0.0004	2.59	3
0.75	0.8301	0.0003	1.73	3
0.80	0.8290	0.0001	0.86	3
0.85	0.8281	0.0002	1.33	3
0.90	0.8256	0.0004	3.02	3
0.95	0.8220	0.0007	5.65	3

centre únicamente en la zona anatómicamente relevante.

Una vez obtenida la máscara del cerebro, esta se emplea para acotar la región sobre la que trabaja el modelo de segmentación de isquemia. De este modo, el segundo modelo no analiza la imagen completa, sino únicamente el tejido cerebral previamente aislado. Esta estrategia permite reducir la aparición de activaciones espurias fuera del órgano y hace más robusta la detección de la lesión, ya que limita la búsqueda a una región donde la predicción tiene sentido desde el punto de vista anatómico.

Por tanto, ambos modelos no se entienden como soluciones independientes, sino como partes complementarias de una misma cadena de procesamiento. El primero se encarga de localizar y segmentar el cerebro, mientras que el segundo utiliza esa información para segmentar la lesión isquémica dentro del órgano ya delimitado. Esta organización secuencial permite estructurar el análisis de forma más coherente con el caso de uso real del proyecto, donde no solo interesa detectar la lesión, sino hacerlo de manera localizada y sobre una región anatómica correctamente identificada.

Finalmente, a partir de las máscaras generadas por ambos modelos, la herramienta puede llevar a cabo la cuantificación de métricas de interés, como el volumen segmentado del cerebro y de la lesión. De este modo, la salida combinada de ambos modelos constituye la base del análisis posterior, tanto para la cuantificación volumétrica como para la evaluación e interpretación de las segmentaciones generadas.

3.4. Cuantificación y métricas biomédicas (volumen)

Aunque el objetivo principal de la arquitectura propuesta es la segmentación automática del cerebro y de la lesión isquémica, la segmentación constituye por sí sola una delimitación espacial de las regiones de interés. Para que dicha delimitación resulte útil en un contexto de investigación biomédica, es necesario transformarla en magnitudes cuantitativas que permitan realizar análisis objetivos y comparables entre casos.

En este trabajo, la métrica cuantitativa principal considerada es el **volumen** de las regiones segmentadas. Esta magnitud permite estimar de forma objetiva la extensión de la lesión y del órgano analizado, facilitando la comparación entre segmentaciones manuales y automáticas, así como el análisis posterior de los casos estudiados. En el ámbito de la imagen cerebral, y en particular en estudios de ictus, el volumen de la lesión se utiliza habitualmente como una medida cuantitativa relevante para el análisis de biomarcadores de imagen y de la afectación observada en la resonancia magnética. (Harston et al., 2015; Ospel et al., 2024)

Para realizar esta cuantificación, se toma como entrada la salida del *pipeline* de segmentación. Dicha salida consiste en una máscara binaria asociada a cada corte de la resonancia magnética, en la que cada píxel queda etiquetado como perteneciente o no a la región de interés. En estas máscaras, los píxeles con valor positivo representan la presencia de tejido segmentado, mientras que el resto corresponde a fondo o regiones no incluidas en la segmentación.

Dado que el procesamiento se realiza sobre imágenes médicas almacenadas en formato NIfTI, el volumen total no se obtiene a partir de una única imagen, sino mediante la agregación de todos los cortes segmentados. En primer lugar, para cada corte se contabiliza el número de píxeles pertenecientes a la región segmentada. A continuación, este recuento se transforma a una magnitud física empleando la información espacial contenida en la cabecera de la imagen NIfTI.

En este formato, el campo `pixdim` codifica el espaciado físico de la rejilla en cada dimensión, mientras que la información *affine* (`sform/qform`) permite representar la geometría espacial asociada a la imagen. (Neuroimaging Informatics Technology Initiative, 2005; NiBabel Developers, 2026) De este modo, si N representa el número total de vóxeles segmentados, y s_x , s_y y s_z representan, respectivamente, el tamaño físico del vóxel en cada una de las tres dimensiones espaciales, el volumen total puede expresarse como:

$$V = N \cdot s_x \cdot s_y \cdot s_z \quad (3.1)$$

donde:

- V es el volumen total de la región segmentada,
- N es el número total de vóxeles clasificados como pertenecientes al órgano o a la lesión,
- s_x y s_y corresponden a la resolución espacial en el plano de la imagen,
- s_z corresponde al espesor del corte, expresado en unidades físicas.

En la práctica, dado que la segmentación se obtiene corte a corte, este cálculo puede formularse también como la suma del volumen parcial aportado por cada corte. Si A_i representa el área segmentada en el corte i , el volumen total se obtiene como:

$$V = \sum_{i=1}^n A_i \cdot s_z \quad (3.2)$$

siendo n el número total de cortes segmentados. A su vez, el área segmentada en cada corte puede expresarse como:

$$A_i = N_i \cdot s_x \cdot s_y \quad (3.3)$$

donde N_i es el número de píxeles segmentados en el corte i .

Finalmente, la estimación volumétrica se realiza de forma secuencial, partiendo del recuento de píxeles segmentados por corte hasta la obtención del volumen total, tal como se ilustra en la Figura 3.7.




Figura 3.7: Proceso de cálculo del volumen de la lesión a partir de la máscara segmentada. Para cada corte, se obtiene el número de píxeles pertenecientes a la lesión, que se transforma en un área física utilizando la resolución espacial de la imagen en el plano ($\Delta x, \Delta y$). Posteriormente, la suma de las áreas segmentadas en todos los cortes se combina con el espaciado entre cortes (Δz) para estimar el volumen total de la lesión.

Este procedimiento permite transformar la salida binaria del modelo en una medida físicamente interpretable, expresada en milímetros cúbicos (mm³). La utilización de unidades físicas, en lugar de recuentos de píxeles sin escala, resulta esencial para garantizar que las medidas obtenidas sean comparables entre diferentes resonancias, sujetos y estudios experimentales.

Desde el punto de vista metodológico, esta cuantificación volumétrica amplía la utilidad del sistema desarrollado, ya que no solo proporciona una segmentación visual de la lesión, sino también una medida numérica objetiva susceptible de ser utilizada en tareas de análisis, comparación y evaluación experimental. Además, la cuantificación automática del volumen a partir de máscaras de cerebro y lesión constituye un enfoque coherente con otros trabajos de segmentación biomédica orientados a la

medición automática de carga lesional en resonancia magnética (de Oliveira et al., 2022; Akkus et al., 2017) además de coincidir con el proceso de trabajo manual en BioImagen Complutense, en concreto, el proceso que se quiere automatizar y siendo el instituto nuestro usuario final establecido.

3.5. Integración de explicabilidad

Desde el inicio de este Trabajo de Fin de Grado, uno de nuestros mayores objetivos (OX) implicaba no sólo el desarrollo del pipeline de segmentación y cálculo de volúmenes, sino la validación y la robustez de los modelos. Si se aplican modelos de Deep Learning a una tarea realizada por expertos investigadores, nos exponemos a introducir un proceso de caja negra en un marco en el que se prioriza la transparencia como es el ámbito biomédico, donde la interpretabilidad resulta especialmente relevante para generar confianza en los resultados y facilitar su análisis crítico (Samek et al., 2017b; Doshi-Velez y Kim, 2017).

Por lo tanto, en este apartado exponemos cómo hemos aplicado Inteligencia Artificial Explicable (XAI) a los dos modelos que forman parte del pipeline de segmentación automática. Dado que las técnicas de explicabilidad se aplican de forma transversal a los modelos desarrollados, se presenta en primer lugar el marco metodológico común para posteriormente detallar su aplicación específica en cada caso.

3.5.1. Fundamentos y motivación de la explicabilidad

Aunque los resultados del modelo pueden evaluarse mediante métricas cuantitativas, estas no permiten por sí solas entender cómo se están generando las predicciones y es necesario analizar también el comportamiento interno de los modelos. Este aspecto resulta especialmente relevante en el caso de la segmentación isquémica, donde los límites de la región afectada no siempre están claramente definidos y dependen del criterio experto (Samek et al., 2017b).

Además, el uso de un conjunto de datos reducido incrementa la probabilidad de que el modelo aprenda patrones no deseados o poco generalizables. Por este motivo, resulta necesario complementar el análisis cuantitativo con técnicas que permitan estudiar el comportamiento interno del modelo.

En este trabajo, esta necesidad se aborda mediante la incorporación de técnicas de Inteligencia Artificial Explicable (XAI). Estas técnicas permiten analizar en qué regiones de la imagen se basa el modelo para generar sus predicciones, aportando un nivel adicional de validación cualitativa (Samek et al., 2017b; Doshi-Velez y Kim, 2017).

3.5.2. Adaptación de técnicas de XAI a segmentación

Una vez decidimos aplicar técnicas de XAI a nuestra herramienta, nos encontramos con el primer bloque: la mayoría de técnicas de explicabilidad que han sido diseñadas originalmente lo fueron con tareas de clasificación como objetivo principal. Las tareas de clasificación tienen como salida un escalar asociado a un enumerado,

y nuestros modelos, al ser modelos diseñados para la tarea de segmentación, tienen como salida una máscara de segmentación a nivel de píxel.

Esto implica que no es posible aplicar directamente estos métodos sin realizar una adaptación previa. Para ello se define una función de score escalar a partir de la salida del modelo, que permite resumir la predicción en un único valor. En este trabajo, dicha función se obtiene a partir de la activación del modelo en la región segmentada, lo que permite aplicar técnicas basadas en gradientes de forma consistente.

3.5.3. Métodos de explicabilidad empleados

Para el análisis de explicabilidad se han seleccionado técnicas basadas en gradientes, por su facilidad de integración con modelos convolucionales. En concreto, se han implementado los métodos Grad-CAM (Selvaraju et al., 2019), Grad-CAM++ (Chattopadhyay et al., 2018) e Integrated Gradients (Sundararajan et al., 2017).

Grad-CAM permite identificar qué regiones de la imagen tienen mayor influencia en la predicción del modelo. Para ello, utiliza los gradientes de la salida respecto a las activaciones de una capa convolucional, generando un mapa de relevancia espacial. Este mapa se puede superponer sobre la imagen original, facilitando su interpretación (Selvaraju et al., 2019).

Además, se ha considerado la variante Grad-CAM++, que introduce mejoras en la localización de múltiples regiones relevantes dentro de una misma imagen. Esta extensión resulta especialmente útil en el contexto de la segmentación de lesiones, donde pueden existir varias zonas de activación dentro de la región afectada (Chattopadhyay et al., 2018).

Por su parte, Integrated Gradients, permite estimar la contribución de cada píxel a la predicción del modelo. Este método se basa en integrar los gradientes a lo largo de un camino entre una imagen base y la imagen original. En este trabajo, se ha utilizado como referencia una imagen completamente negra (Sundararajan et al., 2017).

Además del análisis visual mediante mapas de relevancia, se han considerado métricas cuantitativas de explicabilidad basadas en perturbación de la entrada.

En concreto, se han utilizado métricas de inserción y eliminación, así como variantes derivadas como AOPC y métricas normalizadas, que permiten evaluar hasta qué punto las regiones identificadas como relevantes influyen realmente en la predicción del modelo.

Estas métricas se basan en modificar progresivamente la imagen de entrada, eliminando o incorporando información en las zonas destacadas por los métodos de explicabilidad, y observando cómo varía la salida del modelo. Este tipo de análisis resulta especialmente útil para diferenciar entre regiones que tienen un impacto real en la predicción y aquellas que únicamente presentan activaciones de baja intensidad sin relevancia significativa (Samek et al., 2017b).

Cabe destacar que, aunque estas técnicas permiten analizar el comportamiento del modelo, su interpretación en tareas de segmentación debe hacerse con cautela. Los mapas de relevancia no son una segmentación como tal, sino una aproximación.

En la Figura 3.8 se muestra un ejemplo de los mapas de explicabilidad obtenidos

mediante estas técnicas.




Figura 3.8: Ejemplo de mapas de explicabilidad generados sobre una imagen de entrada. Se muestra la imagen original, la máscara predicha y el mapa de relevancia superpuesto.

3.5.4. Aplicación al modelo de segmentación de isquemia

A continuación, se describe cómo se han aplicado las técnicas de explicabilidad al modelo de segmentación de lesiones isquémicas. En este caso, la explicación se centra en una región patológica localizada, de tamaño reducido y con límites potencialmente difusos, por lo que resulta especialmente importante analizar qué zonas de la imagen contribuyen a la predicción generada por el modelo.

El análisis se implementó en un notebook de Python desarrollado específicamente para evaluar el comportamiento del modelo de isquemia. Este notebook carga el modelo entrenado, procesa los volúmenes de resonancia magnética corte a corte y reproduce el mismo flujo seguido durante la inferencia. En primer lugar, se obtiene la máscara predicha por el modelo de segmentación cerebral. A continuación, dicha máscara se combina con la imagen original para restringir la entrada del modelo de isquemia al tejido cerebral. Finalmente, a partir de la predicción de lesión generada por este segundo modelo, se calculan distintos mapas de relevancia asociados a la salida obtenida.

Para generar los mapas de Grad-CAM, se selecciona la última capa convolucional del decoder, al tratarse de una capa próxima a la generación de la máscara final y que todavía conserva información espacial relevante. Aunque Grad-CAM fue propuesto originalmente para tareas de clasificación, puede adaptarse a problemas de segmentación siempre que se defina una puntuación escalar sobre la salida densa del modelo (Selvaraju et al., 2019). En este trabajo, dicha puntuación se define a partir de la activación del modelo en la región segmentada como lesión, agregando la contribución de los píxeles predichos como pertenecientes a la clase isquemia. De este modo, la salida del modelo se reduce a un único valor sobre el que es posible calcular gradientes de forma coherente con la tarea de segmentación.

Además de Grad-CAM, se emplean Grad-CAM++ e *Integrated Gradients* como métodos complementarios de explicación. Grad-CAM++ se incorpora como una variante orientada a mejorar la localización espacial de las regiones relevantes (Chatopadhyay et al., 2018), mientras que *Integrated Gradients* permite estimar la contribución de cada píxel a partir de la comparación progresiva entre una imagen de referencia y la imagen original (Sundararajan et al., 2017). La combinación de estos métodos permite analizar la predicción desde enfoques distintos, evitando depender de una única técnica de explicación.

Los mapas de relevancia obtenidos se normalizan y se superponen sobre la imagen original, junto con la máscara de referencia y la máscara predicha por el modelo. Esta representación permite estudiar de forma cualitativa si las regiones señaladas por los métodos de explicabilidad se corresponden con zonas anatómicamente compatibles con la lesión isquémica o si, por el contrario, aparecen activaciones en áreas no relevantes.

Este análisis resulta especialmente importante en el modelo de isquemia, ya que durante el desarrollo se observaron problemas de sobresegmentación, principalmente en los bordes de la lesión. En estas zonas pueden aparecer activaciones de baja intensidad que, al aplicar un umbral de binarización poco restrictivo, acaban incorporándose a la máscara final como falsos positivos. Por ello, la explicabilidad se utiliza como una herramienta adicional para analizar si esas regiones están siendo realmente relevantes para la predicción del modelo o si corresponden a ruido en la salida probabilística.

De esta forma, el análisis de explicabilidad también permite apoyar la justificación metodológica del umbral aplicado durante la inferencia. Si las zonas eliminadas por el umbral presentan baja relevancia en los mapas de explicación, el umbral puede interpretarse como un mecanismo de filtrado de activaciones poco informativas. No obstante, esta interpretación debe entenderse como un apoyo cualitativo al análisis del modelo, y no como una sustitución de las métricas cuantitativas de segmentación.

Además del análisis visual, se incorporan métricas basadas en perturbación para evaluar la fidelidad de las explicaciones generadas. En concreto, se analiza cómo varía la salida del modelo al modificar progresivamente las regiones consideradas más relevantes por cada método de explicación, utilizando métricas como *Deletion*, *Insertion* y AOPC. Estas métricas permiten comprobar si las zonas destacadas por los mapas de relevancia tienen un impacto real sobre la predicción del modelo (Samek et al., 2017b).

En conjunto, la integración de explicabilidad en el modelo de isquemia se plantea como un mecanismo complementario de análisis del comportamiento de la red. Su objetivo no es únicamente generar visualizaciones interpretables, sino también estudiar la relación entre las activaciones del modelo, la localización de la lesión y las decisiones de postprocesado aplicadas durante la inferencia.

Como se observa en la Figura 3.9, las técnicas de explicabilidad concentran la activación en la región correspondiente a la lesión isquémica, lo que sugiere que el modelo basa su predicción en características espacialmente coherentes con la anotación de referencia.




Figura 3.9: Ejemplo de visualización generada por el procedimiento de explicabilidad aplicado al modelo de segmentación de isquemia. Se muestran el corte original de RMN, la máscara de referencia, la predicción del modelo y los mapas de relevancia obtenidos mediante distintos métodos de explicabilidad. La figura ilustra el tipo de salida utilizada para el análisis cualitativo del comportamiento del modelo.

Una vez descrito el procedimiento aplicado al modelo de isquemia, se presenta a continuación su adaptación al modelo de segmentación cerebral, donde la región objetivo deja de ser una lesión localizada y pasa a corresponderse con una estructura anatómica completa.

3.5.5. Aplicación de explicabilidad al modelo de segmentación cerebral

A continuación, se describe cómo se han aplicado las técnicas de explicabilidad al modelo encargado de segmentar el cerebro. A diferencia del modelo de isquemia, donde la región objetivo corresponde a una lesión localizada, en este caso la explicación se orienta a analizar el comportamiento del modelo ante una estructura anatómica extensa y de contorno relativamente continuo.

El análisis se implementó en un notebook de Python, desarrollado específicamente para evaluar el modelo de segmentación cerebral. Este notebook carga el modelo entrenado, procesa los volúmenes de resonancia magnética corte a corte, obtiene la máscara predicha por el modelo y genera distintos mapas de relevancia asociados a la predicción.

Para el cálculo de Grad-CAM, se selecciona la última capa convolucional del decoder previa a la convolución final 1×1 , al tratarse de una capa cercana a la generación de la máscara de salida y que todavía conserva información espacial relevante. Aunque Grad-CAM fue propuesto originalmente para problemas de clasificación, puede adaptarse a segmentación siempre que se defina una puntuación escalar sobre la salida del modelo (Selvaraju et al., 2019).

En este caso, dicha puntuación se define como la probabilidad media de pertenencia a la clase cerebro dentro de la máscara cerebral predicha por el propio modelo. Esta formulación permite transformar la salida densa de segmentación en un valor escalar sobre el que calcular gradientes, manteniendo la explicación centrada en la región que el modelo ha considerado como cerebro. Es importante destacar que el cálculo se realiza sobre la predicción del modelo y no sobre la máscara de referencia, ya que el objetivo de la explicabilidad es analizar el criterio seguido por la red al generar su propia salida.

Además de Grad-CAM, se incorporan Grad-CAM++ e *Integrated Gradients* como métodos complementarios de explicación. Grad-CAM++ se incluye como una

variante orientada a mejorar la localización espacial de las regiones relevantes (Chatopadhyay et al., 2018), mientras que *Integrated Gradients* permite estimar la contribución de cada píxel a partir de la comparación progresiva entre una imagen de referencia o *baseline* y la imagen original (Sundararajan et al., 2017). En el caso de las imágenes de RMN, la elección del *baseline* debe realizarse con cautela, ya que una imagen completamente negra puede introducir una referencia artificial alejada de la distribución real de intensidades.

Los mapas de relevancia generados se redimensionan al tamaño de la imagen de entrada y se normalizan para facilitar su visualización conjunta. Posteriormente, se superponen sobre el corte original de RMN, junto con la máscara de referencia y la máscara predicha. Esta representación permite analizar de forma cualitativa si las regiones destacadas por los métodos de explicabilidad se sitúan sobre zonas anatómicamente relacionadas con el tejido cerebral o si aparecen activaciones en regiones externas a la estructura de interés.

El procedimiento también contempla el uso de técnicas basadas en perturbación, como la oclusión progresiva de regiones de la imagen. Estas técnicas permiten estudiar cómo cambia la salida del modelo cuando se modifican zonas concretas del corte, proporcionando una perspectiva complementaria a los métodos basados en gradientes. En este contexto, las métricas de inserción, eliminación y AOPC se plantean como herramientas para evaluar la fidelidad de las explicaciones, es decir, si las regiones identificadas como relevantes tienen realmente influencia sobre la predicción del modelo (Samek et al., 2017a; Petsiuk et al., 2018).

En conjunto, la integración de explicabilidad en el modelo de segmentación cerebral no se plantea como una métrica de rendimiento adicional, sino como un mecanismo de análisis metodológico. Su objetivo es comprobar la coherencia espacial del comportamiento del modelo, detectar posibles dependencias no deseadas de regiones externas al cerebro y complementar la evaluación cuantitativa basada en métricas de segmentación.




Figura 3.10: Ejemplo de visualización generada por el procedimiento de explicabilidad aplicado al modelo de segmentación cerebral. Se muestran, de izquierda a derecha, el corte original de RMN, la máscara de referencia, la máscara predicha por el modelo y los mapas de relevancia obtenidos mediante distintos métodos de explicabilidad. Esta figura ilustra el tipo de salida utilizada para el análisis cualitativo del comportamiento del modelo.

Resultados y Discusión

La evaluación de los modelos se ha realizado sobre un subconjunto de test compuesto por tres casos representativos: un sujeto de control sin presencia de lesión y dos sujetos con lesión isquémica, correspondientes a los escenarios de isquemia transitoria y permanente. En el caso del modelo de segmentación de isquemia, se ha aplicado un umbral de binarización de 0.8 sobre la salida probabilística, seleccionado previamente por ofrecer el mejor compromiso entre precisión espacial y error en la estimación volumétrica. Este análisis se plantea como una validación exploratoria orientada a estudiar el comportamiento del modelo en distintos tipos de casos clínicos.

4.1. Configuración experimental

4.2. Resultados en segmentación cerebral

4.2.1. Resultados cuantitativos

Tabla 4.1: Resumen de métricas del modelo de segmentación cerebral

Métrica	Valor
Error absoluto medio (ml)	$0,007 \pm 0,004$
Error relativo medio (%)	$1,56 \pm 0,90$
Acierto medio (%)	98,44
Coefficiente Dice 3D	$0,973 \pm 0,001$
IoU 3D	$0,947 \pm 0,002$

En la Figura 4.1 se representan los valores del coeficiente Dice obtenidos para cada uno de los casos evaluados en la tarea de segmentación de isquemia.




Figura 4.1: Evolución del coeficiente Dice por Caso




Figura 4.2: Evolución del coeficiente Dice por caso

4.2.2. Análisis cualitativo

Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry’s standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum. Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry’s standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum. Lorem Ipsum is simply dummy text of the printing and typesetting industry. Lorem Ipsum has been the industry’s standard dummy text ever since the 1500s, when an unknown printer took a galley of type and scrambled it to make a type specimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.




Figura 4.3: Ejemplos cualitativos de segmentación de isquemia en distintos escenarios

cimen book. It has survived not only five centuries, but also the leap into electronic typesetting, remaining essentially unchanged. It was popularised in the 1960s with the release of Letraset sheets containing Lorem Ipsum passages, and more recently with desktop publishing software like Aldus PageMaker including versions of Lorem Ipsum.

4.2.3. Resultados de explicabilidad en la segmentación de cerebro

Además de evaluar la calidad de las máscaras generadas, se aplicaron técnicas de explicabilidad con el objetivo de analizar la coherencia espacial de las regiones utilizadas por el modelo durante la predicción. Este análisis no pretende sustituir a las métricas clásicas de segmentación, sino complementarlas mediante una evaluación del comportamiento interno del modelo. Esto es especialmente importante en un pipeline aplicado a la investigación biomédica.

El análisis se realizó sobre 84 cortes pertenecientes a tres casos distintos. No obs-

tante, durante la interpretación de los resultados se observó que los cortes extremos de cada volumen presentan un comportamiento diferente al de los cortes centrales. En estas zonas, la presencia de tejido cerebral es reducida o incluso inexistente en la máscara de referencia, lo que afecta negativamente a métricas como Dice e IoU y puede producir valores poco representativos. Por este motivo, los resultados se analizaron distinguiendo entre cortes interiores y cortes extremos.

En el conjunto completo de cortes analizados, el modelo obtuvo un Dice medio de 0,802 y un IoU medio de 0,774. Sin embargo, al considerar únicamente los cortes interiores, más representativos de la tarea principal de segmentación cerebral, el rendimiento aumentó notablemente, alcanzando un Dice medio de 0,969 y un IoU medio de 0,940. Esta diferencia indica que la reducción del rendimiento global se debe principalmente a los cortes de borde, donde la región anatómica objetivo es pequeña o ambigua, y no a un fallo sistemático del modelo en la segmentación del cerebro.

Tabla 4.2: Rendimiento medio del modelo de segmentación cerebral en los cortes analizados para explicabilidad.

Conjunto de cortes	N	Dice medio	IoU medio
Todos los cortes	84	0,802	0,774
Cortes interiores	66	0,969	0,940
Cortes extremos	18	0,189	0,174

La Figura 4.4 muestra ejemplos representativos de cortes interiores en los que el modelo obtiene una segmentación cerebral precisa. En cada fila se presenta la imagen original, la máscara de referencia, la máscara predicha, los mapas de relevancia generados por Grad-CAM, Grad-CAM++ e Integrated Gradients, y la curva de eliminación normalizada asociada.




Figura 4.4: Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación cerebral. Se muestra la imagen original, la máscara manual, la máscara predicha, los mapas obtenidos mediante Grad-CAM, Grad-CAM++ e Integrated Gradients, y la curva de eliminación normalizada.

En estos ejemplos, la máscara predicha presenta un alto grado de solapamiento con la segmentación manual, con valores Dice próximos a 1. Esta coincidencia entre la evaluación cuantitativa y la visualización de los mapas de relevancia refuerza la interpretación de que, en los cortes representativos del volumen, el modelo realiza una segmentación estable y espacialmente coherente. Además, tanto Grad-CAM como Grad-CAM++ producen mapas suaves y continuos, lo que facilita su interpretación visual en el contexto de una tarea de segmentación anatómica.

Integrated Gradients, por el contrario, muestra un patrón más localizado y disperso. En lugar de generar una región amplia de activación sobre todo el cerebro, tiende a resaltar puntos concretos, bordes o zonas de mayor variación de intensidad. Este comportamiento puede resultar menos intuitivo desde el punto de vista visual, pero es coherente con los resultados cuantitativos obtenidos en las métricas de eliminación, donde este método mostró una mayor sensibilidad al retirar las regiones consideradas relevantes. Por tanto, Integrated Gradients parece identificar zonas críticas para la predicción, aunque su representación sea menos directa que la obtenida mediante Grad-CAM o Grad-CAM++.

Las curvas de eliminación normalizada permiten complementar esta interpretación visual. En ellas se observa cómo varía la puntuación del modelo al perturbar progresivamente las regiones identificadas como relevantes por cada método. En los casos con buena segmentación, la eliminación de las zonas destacadas provoca una caída progresiva de la puntuación, lo que indica que dichas regiones tienen una influencia real sobre la salida del modelo. Esta relación entre mapas de relevancia y caída del score aporta una medida adicional de fidelidad de las explicaciones.

No obstante, el análisis cualitativo también evidencia ciertas limitaciones. En los cortes extremos del volumen, la interpretación de los mapas resulta menos estable. En algunos de estos cortes, la máscara manual contiene muy poca región cerebral o incluso ningún píxel etiquetado, mientras que la imagen todavía puede presentar estructuras anatómicas residuales. En estos casos, el modelo puede generar una predicción parcial de cerebro, lo que conduce a valores Dice nulos o muy bajos y a ratios de área no representativos. Por ello, estos cortes no deben interpretarse del mismo modo que los cortes interiores.

Esta diferencia justifica la separación realizada entre cortes interiores y cortes extremos en el análisis cuantitativo. Los cortes interiores permiten evaluar el comportamiento del modelo en las regiones donde la estructura cerebral está claramente presente, mientras que los cortes de borde reflejan situaciones más ambiguas, condicionadas tanto por la anatomía visible como por el criterio de anotación manual. En consecuencia, las explicaciones obtenidas en cortes extremos deben entenderse como una herramienta para estudiar el comportamiento del modelo ante casos límite, no como una medida directa de buen funcionamiento.

En conjunto, el análisis cualitativo de los mapas de relevancia muestra que, en los cortes representativos de la estructura cerebral, las explicaciones son coherentes con la segmentación obtenida. Grad-CAM y Grad-CAM++ ofrecen visualizaciones más suaves y anatómicamente interpretables, mientras que Integrated Gradients proporciona una explicación más sensible a regiones concretas de la imagen. La combinación de estos métodos permite analizar el modelo desde perspectivas complementarias y aporta información útil sobre la relación entre la imagen de entrada, la máscara predicha y las regiones que influyen en la predicción.

Una vez caracterizado el comportamiento del modelo, se evaluó la fidelidad de las explicaciones mediante métricas basadas en perturbación. En particular, se utilizaron curvas de eliminación e inserción, así como sus variantes MoRF y LeRF. En las curvas de eliminación, se eliminan progresivamente las regiones más relevantes según el mapa de explicación; por tanto, un valor bajo de *Deletion AUC* indica que la explicación identifica regiones importantes para la predicción. En cambio,

en las curvas de inserción, valores altos de *Insertion AUC* indican que las regiones destacadas por el método permiten reconstruir progresivamente la activación del modelo.

La Tabla 4.3 resume los resultados medios obtenidos para Grad-CAM, Grad-CAM++ e Integrated Gradients. La sensibilidad por oclusión se empleó como análisis complementario, pero no se incluye en esta tabla al no calcular las mismas métricas agregadas que los métodos basados en mapas de relevancia.

Tabla 4.3: Resumen cuantitativo de las métricas de fidelidad para los métodos de explicabilidad aplicados al modelo de segmentación cerebral.

Método	Deletion AUC ↓	Insertion AUC ↑	LeRF AUC ↑	AOPC ↑	AOPC norm. ↑
Grad-CAM	0,264	0,712	0,755	0,753	0,761
Grad-CAM++	0,304	0,795	0,807	0,714	0,721
Integrated Gradients	0,102	0,755	0,721	0,914	0,923

Los resultados muestran que Integrated Gradients obtuvo el mejor comportamiento en las métricas basadas en eliminación, con un *Deletion AUC* medio de 0,102 y un *AOPC* normalizado de 0,923. Esto indica que las regiones identificadas como relevantes por este método tienen una influencia directa sobre la predicción del modelo, ya que su eliminación provoca una reducción rápida de la puntuación asociada a la segmentación cerebral.

Por otro lado, Grad-CAM++ presentó los mejores valores en las métricas de inserción y LeRF, con un *Insertion AUC* medio de 0,795 y un *LeRF AUC* medio de 0,807. Este resultado sugiere que las regiones resaltadas por Grad-CAM++ contienen información suficiente para reconstruir progresivamente la predicción del modelo, y que las zonas consideradas menos relevantes afectan en menor medida a la salida cuando se eliminan en primer lugar.

El comportamiento de las curvas de perturbación refuerza esta interpretación. En el caso de Integrated Gradients, al eliminar el 25 % de los píxeles considerados más relevantes, la puntuación media del modelo descendió hasta 0,097. En cambio, para Grad-CAM y Grad-CAM++, la puntuación en ese mismo punto fue de 0,663 y 0,750, respectivamente. Esto sugiere que Integrated Gradients produce mapas más focalizados en regiones críticas para la predicción, mientras que Grad-CAM y Grad-CAM++ generan explicaciones más distribuidas espacialmente.

En conjunto, los resultados de explicabilidad no deben interpretarse como una validación clínica independiente del modelo, sino como una herramienta complementaria para analizar su comportamiento. Las métricas cuantitativas indican que las regiones destacadas por los métodos XAI influyen de forma significativa en la predicción, especialmente en el caso de Integrated Gradients. Asimismo, Grad-CAM++ aporta una visualización útil para interpretar la reconstrucción progresiva de la evidencia visual. Por tanto, la combinación de estos métodos permite obtener una visión más completa del proceso de segmentación realizado por el modelo.

4.2.4. Discusión

4.3. Resultados en segmentación de isquemia

A continuación, se presentan los resultados obtenidos en la tarea de segmentación de las regiones de lesión por isquemia cerebral, la cual, por razones que se describirán en la siguiente sección, supone un problema más complejo que la segmentación del órgano sano. Para ello, al igual que en el modelo de cerebro, se han evaluado varias configuraciones de arquitecturas *U-Net*, utilizando las métricas descritas anteriormente.

4.3.1. Resultados cuantitativos

Tabla 4.4: Resumen de métricas del modelo de segmentación de isquemia

Métrica	Valor
Error absoluto medio (ml)	$0,001 \pm 0,001$
Error relativo medio (%)	$7,41 \pm 2,64$
Acierto medio (%)	92,59
Coefficiente Dice 3D	$0,820 \pm 0,157$
IoU 3D	$0,717 \pm 0,246$

En la Figura 4.5 se representan los valores del coeficiente Dice obtenidos para cada uno de los casos evaluados en la tarea de segmentación de isquemia.




Figura 4.5: Evolución del coeficiente Dice por Caso

En el caso de control, donde no existe presencia de lesión, el modelo obtiene un valor de Dice igual a 1, lo que indica una coincidencia perfecta entre la predicción y la máscara de referencia al no detectar regiones patológicas. En los casos con presencia de isquemia, los valores de Dice se sitúan en torno a 0.8, lo que refleja un alto grado de solapamiento entre la segmentación automática y la manual, aunque con discrepancias en las zonas de transición y en la delimitación de los bordes.

De manera general, los resultados obtenidos muestran un valor de *coeficiente Dice* inferiores y con mayor variabilidad frente al modelo de cerebro. El error relativo también presenta una ligera degradación respecto al caso base.

Estas diferencias son notables a lo largo de todas las configuraciones y casos analizados, lo que sugiere que la limitación no reside únicamente en el modelo, sino en la naturaleza del problema abordado.

4.3.2. Naturaleza del problema y subjetividad

A diferencia de la segmentación del cerebro, el cual está claramente delimitado por el cráneo y el espacio subcranoideo, debido a las características anatómicas propias de las lesiones de isquemia cerebral, el proceso de segmentación constituye un problema complejo y altamente subjetivo, cuya interpretación puede variar significativamente entre distintos profesionales, tal y como respalda el *ICTS BioImagen Complutense*.

Concretamente, las lesiones presentan las siguientes características visibles en cada corte de MRI afectado:

- Borde difuminado.
- Gradientes de intensidad entre tejido sano y afectado.
- Zonas intermedias en las que la clasificación no es clara.
- Ruido y artefactos propios de la resonancia magnética nuclear.

Como consecuencia, la delimitación manual de estas regiones depende del criterio del experto que realiza la medición, lo que introduce una alta variabilidad en los datos recogidos entre observadores y estudios. La anotación manual está afectada por incertidumbre en la frontera de la lesión, y penaliza las métricas de solapamiento, por lo que el *ground truth* utilizado durante el entrenamiento y la evaluación del modelo debe analizarse con concordancia a una referencia experta operativa.

4.3.3. Interpretación de métricas

Teniendo en cuenta esta problemática, los valores obtenidos en las métricas deben interpretarse con cautela. Por este motivo, ha sido necesaria una validación adicional por parte de profesionales del *ICTS BioImagen Complutense*, con el fin de obtener un veredicto más fiable y ajustado a la realidad clínica. Un *valor Dice* inferior en comparación al modelo de segmentación cerebral no implica necesariamente un menor rendimiento del modelo, sino que refleja la variabilidad técnica del proceso.

Pequeñas variaciones en la delimitación de la zona afectada, producen cambios significativos en el *valor Dice*, por lo que el modelo puede estar generando segmentaciones coherentes desde el punto de vista clínico aún cuando la métrica no alcance los valores óptimos.

En este punto, resulta especialmente relevante considerar el criterio aportado por los profesionales del *ICTS BioImagen Complutense*, quienes señalan que la validez

de las segmentaciones no dependen únicamente de precisión absoluta sino de la robustez en el comportamiento del modelo. Es decir, una ligera sobreestimación o subestimación sistemática en los volúmenes segmentados puede considerarse válida siempre que la desviación sea consistente entre casos y no introduzca artefactos incoherentes, como cortes intermedios vacíos o la detección de regiones incompatibles con la morfología de la isquemia.

Tal y como se observa en la Figura 4.6, las diferencias en los volúmenes estimados se mantienen en rangos consistentes respecto al *ground truth*. Este comportamiento sugiere que el modelo presenta una desviación sistemática controlada, alineada con los criterios de robustez definidos por el centro de Bioimagen.




Figura 4.6: Evolución del coeficiente Dice por caso

4.3.4. Impacto del threshold

Uno de los factores clave en la calidad de la segmentación es el umbral de decisión aplicado sobre la salida del modelo: Valores de umbral bajos tienden a producir segmentaciones más extensas, incrementando la detección de posibles zonas afectadas, pero también introduciendo falsos positivos. Por lo contrario, umbrales altos generan segmentaciones más conservadoras, generando posibles omisiones de zonas de baja hiperintensidad.

Este comportamiento es especialmente crítico en el caso de la isquemia, donde las regiones ambiguas son frecuentes. Por ello, la elección del umbral óptimo depende en gran medida del criterio clínico y del uso final de la herramienta.

4.3.5. Análisis cualitativo

Con el objetivo de complementar el análisis cuantitativo presentado anteriormente, se ha realizado una evaluación cualitativa de las segmentaciones obtenidas en los casos de isquemia cerebral, prestando especial atención al comportamiento del modelo en regiones de alta ambigüedad.

La Figura 4.7 muestra ejemplos representativos de segmentación correspondientes a los tres casos estudiados. En cada uno de ellos se comparan la máscara manual




Figura 4.7: Ejemplos cualitativos de segmentación de isquemia en distintos escenarios

(GT), y la predicción generada por el modelo.

En el caso de control, el modelo presenta un comportamiento óptimo, con una correspondencia exacta entre la predicción y la ausencia de lesión. Este resultado confirma la capacidad del modelo para no generar falsos positivos en ausencia de patología.

En el caso de isquemia permanente, se obtiene un coeficiente Dice de 0.86 y un IoU de 0.755. A nivel visual, la predicción del modelo muestra una delimitación más homogénea y consistente de la región afectada en comparación con la máscara manual, la cual presenta bordes más irregulares. Este comportamiento sugiere que el modelo no solo reproduce la anotación, sino que puede aportar una segmentación más regular en regiones donde el ground truth es ambiguo.

Por último, en el caso de isquemia transitoria, se obtienen valores inferiores (Dice de 0.751 e IoU de 0.601), lo cual es coherente con la menor definición de la lesión. En este tipo de casos, la baja intensidad de la zona hiperintensa de la isquemia hacen que su selección manual sea compleja, intruduciendo un valor de subjetividad elevado. Sin embargo, el modelo consigue destacar exitosamente la zona más afectada pese a

que el caso puede parecerse mucho a un caso de control.

En conjunto, estos resultados cualitativos refuerzan la interpretación de las métricas cuantitativas, evidenciando que las diferencias observadas en los valores de Dice no responden únicamente al rendimiento del modelo, sino también a la complejidad intrínseca de cada caso y a la variabilidad presente en las anotaciones de referencia.

Se ha observado que, debido a la mayor sensibilidad del modelo, en ocasiones se ha conseguido identificar regiones desapercibidas a criterio manual, así como de segmentar de forma más homogénea ciertas zonas de transición. Estos resultados sugieren que el modelo no solo reproduce el comportamiento humano, sino que, en determinados escenarios, puede ser una herramienta útil para mejorar la consistencia del proceso.

En segundo lugar, en las zonas de transición entre tejido sano y tejido afectado, el modelo muestra una mayor estabilidad en la delimitación de los bordes, proporcionando segmentaciones más suaves y menos fragmentadas. Este aspecto resulta especialmente relevante en el contexto de la isquemia, donde los gradientes de intensidad dificultan la definición de un límite claro.

Por otro lado, también se han identificado casos en los que el modelo presenta una ligera sobreestimación de las regiones afectadas, especialmente en áreas con intensidades intermedias. No obstante, tal y como se ha discutido previamente, este comportamiento puede considerarse aceptable siempre que se mantenga de forma consistente y no introduzca estructuras incompatibles con la morfología esperada de la lesión.

Finalmente, en los casos más complejos, el modelo muestra limitaciones similares a las de la segmentación manual, lo que refuerza la idea de que la dificultad reside en la propia naturaleza de la imagen y no exclusivamente en el enfoque empleado.

En conjunto, el análisis cualitativo respalda los resultados cuantitativos obtenidos, evidenciando que el modelo produce segmentaciones coherentes y clínicamente plausibles, incluso en aquellos casos donde las métricas numéricas no alcanzan valores elevados.

4.3.6. Resultados de explicabilidad en la segmentación de isquemia

Una vez evaluado el rendimiento del modelo de segmentación de isquemia, se analizó la coherencia de sus predicciones mediante técnicas de explicabilidad visual. El objetivo de este análisis no es sustituir la evaluación cuantitativa de segmentación, sino estudiar si las regiones destacadas por los métodos de explicabilidad se corresponden con las zonas que el modelo utiliza para generar la máscara predicha.

El análisis se realizó sobre un subconjunto de 84 cortes pertenecientes a tres casos de prueba. De estos cortes, 22 presentaban lesión en la segmentación manual y 62 no contenían lesión. A nivel de presencia o ausencia de lesión por corte, el modelo obtuvo 21 verdaderos positivos, 60 verdaderos negativos, 2 falsos positivos y 1 falso negativo. Esto supone una sensibilidad del 95,45 %, una especificidad del 96,77 % y una puntuación F1 del 93,33 %. En los cortes con lesión correctamente detectada, el

Dice medio fue de 0,784 y la IoU media de 0,672.

Para la interpretación visual se aplicaron Grad-CAM, Grad-CAM++ e Integrated Gradients utilizando como objetivo la máscara predicha por el propio modelo. Esta decisión permite analizar qué regiones de la imagen contribuyen a la predicción generada, independientemente de si esta coincide o no con la segmentación manual. Por tanto, las explicaciones deben interpretarse como una medida de fidelidad respecto al comportamiento del modelo, y no como una validación clínica directa de la lesión.

Como se muestra en la Figura 4.8, en los cortes correctamente segmentados los mapas de Grad-CAM y Grad-CAM++ presentan activaciones localizadas en la región predicha como isquemia, con una correspondencia visual clara con la máscara de referencia en los casos de mayor solapamiento. Integrated Gradients también resalta la zona de interés, aunque con un patrón más disperso y fragmentado, lo que resulta esperable en métodos basados directamente en gradientes a nivel de píxel. Esta diferencia hace que Grad-CAM y Grad-CAM++ resulten más interpretables desde el punto de vista visual, mientras que Integrated Gradients aporta una explicación más fina, aunque menos compacta.




Figura 4.8: Ejemplo cualitativo de explicabilidad aplicado al modelo de segmentación de isquemia. Se muestran la imagen original, la máscara manual, la máscara predicha y los mapas de relevancia obtenidos mediante Grad-CAM, Grad-CAM++ e Integrated Gradients.

Este comportamiento resulta especialmente relevante en segmentación médica, donde una explicación coherente puede ayudar a identificar si el modelo se apoya en patrones anatómicos plausibles o en regiones ambiguas de la imagen.

La evaluación cuantitativa mediante perturbación, resumida en la Tabla 4.5, refuerza esta interpretación. En los cortes con lesión correctamente detectada, los valores medios de *Deletion AUC* fueron muy bajos para los tres métodos, con valores de 0,025 para Grad-CAM y Grad-CAM++, y 0,026 para Integrated Gradients. Esto indica que, al eliminar en primer lugar las regiones consideradas más relevantes, el score asociado a la predicción cae de forma abrupta. De forma complementaria, las curvas de *Insertion* muestran que al reconstruir la imagen empezando por las regiones más relevantes el modelo recupera progresivamente su activación, especialmente en Grad-CAM++ e Integrated Gradients, con valores medios de 0,840 y 0,879 respectivamente.

Tabla 4.5: Resultados cuantitativos de explicabilidad para los cortes de isquemia correctamente detectados.

Método	Deletion AUC	Insertion AUC	LeRF AUC	AOPC normalizado
Grad-CAM	0,025	0,627	0,867	1,000
Grad-CAM++	0,025	0,840	0,840	1,000
Integrated Gradients	0,026	0,879	0,882	0,999

Además, los valores de *LeRF AUC* se mantienen elevados, lo que indica que al eliminar inicialmente las regiones menos relevantes la predicción se conserva durante una parte importante del proceso de perturbación. Del mismo modo, el *AOPC* normalizado se sitúa en valores cercanos a 1 para los tres métodos, reforzando la idea de que las regiones destacadas por los mapas tienen una influencia significativa en la salida del modelo.

No obstante, el análisis también permite identificar limitaciones. En los falsos positivos, las explicaciones muestran activaciones localizadas en las regiones que han originado la predicción errónea. Esto evidencia que la explicabilidad no garantiza que la predicción sea correcta, sino que permite analizar qué información ha utilizado el modelo para producirla. Por tanto, estos casos resultan especialmente útiles para detectar patrones de error y posibles regiones ambiguas en la imagen.

En conjunto, los resultados de explicabilidad sugieren que el modelo de isquemia basa sus predicciones en regiones espacialmente coherentes con las máscaras generadas. Las técnicas Grad-CAM y Grad-CAM++ proporcionan explicaciones visualmente más compactas, mientras que Integrated Gradients ofrece una atribución más detallada pero menos localizada. La combinación de análisis cualitativo y métricas de perturbación permite aportar una capa adicional de interpretación al modelo, aunque sus resultados deben entenderse como apoyo a la evaluación del sistema y no como validación clínica independiente.

4.3.7. Discusión crítica del modelo de isquemia

Es importante destacar que el sistema desarrollado se concibe como una herramienta supervisada en la que el especialista mantiene el control de los datos finales. La herramienta permite la edición de cada una de las máscaras generada así como los valores volumétricos en cada corte de la resonancia analizada. Este enfoque garantiza que cualquier desviación pueda ser corregida de manera sencilla por el experto, integrando la automatización dentro de un **flujo de trabajo asistido y no sustitutivo**.




Figura 4.9: bland altman




Figura 4.10: bland altman

4.4. Análisis comparativo global

4.5. Relación con el objetivo del TFG

4.6. Limitaciones

4.7. Conclusiones del capítulo




Figura 4.11: bland altman

Capítulo 5

Conclusiones y Trabajo Futuro

Conclusiones del trabajo y líneas de trabajo futuro.

Introduction

Introduction to the subject area. This chapter contains the translation of Chapter 1.

Conclusions and Future Work

Conclusions and future lines of work. This chapter contains the translation of Chapter ??.

Contribuciones Personales

Estudiante 1

Estudiante 2

Bibliografía

*Y así, del mucho leer y del poco dormir, se
le secó el cerebro de manera que vino a
perder el juicio.*
(modificar en Cascaras\bibliografia.tex)

Miguel de Cervantes Saavedra

AKKUS, Z., GALIMZIANOVA, A., HOOGI, A., RUBIN, D. L. y ERICKSON, B. J. Deep learning for brain mri segmentation: State of the art and future directions. *Journal of Digital Imaging*, vol. 30(4), páginas 449–459, 2017.

CHATTOPADHAY, A., SARKAR, A., HOWLADER, P. y BALASUBRAMANIAN, V. N. Grad-cam++: Generalized gradient-based visual explanations for deep convolutional networks. En *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)*, páginas 839–847. IEEE, 2018.

DEVELOPERS, N. Nibabel: Access a multitude of neuroimaging data formats. <https://nipy.org/nibabel/>, 2024.

DOSHI-VELEZ, F. y KIM, B. Towards a rigorous science of interpretable machine learning. 2017.

HARSTON, G. W. J. ET AL. Imaging biomarkers in acute ischemic stroke trials: A systematic review. *Stroke*, vol. 46(4), páginas 1163–1169, 2015.

MEI, X., LIU, Z., ROBSON, P. M., MARINELLI, B., HUANG, M., DOSHI, A., JACOBI, A., CAO, C., LINK, K. E., YANG, B. ET AL. Radimagenet: An open radiologic deep learning research dataset for effective transfer learning. *Radiology: Artificial Intelligence*, vol. 4(5), página e210315, 2022.

MILLETARI, F., NAVAB, N. y AHMADI, S.-A. V-net: Fully convolutional neural networks for volumetric medical image segmentation. En *2016 Fourth International Conference on 3D Vision (3DV)*, páginas 565–571. IEEE, 2016.

NEUROIMAGING INFORMATICS TECHNOLOGY INITIATIVE. Nifti-1 data format specification. <https://nifti.nimh.nih.gov/nifti-1/>, 2003.

- NEUROIMAGING INFORMATICS TECHNOLOGY INITIATIVE. Nifti-1 fields. <https://nifti.nimh.nih.gov/nifti-1/documentation/nifti1fields.html>, 2005.
- NIABEL DEVELOPERS. Working with nifti images. https://nipy.org/nibabel/nifti_images.html, 2026.
- ODENA, A., DUMOULIN, V. y OLAH, C. Deconvolution and checkerboard artifacts. *Distill*, vol. 1(10), página e3, 2016.
- OKTAY, O., SCHLEMPER, J., FOLGOC, L. L., LEE, M., HEINRICH, M., MISAWA, K., MORI, K., McDONAGH, S., HAMMERLA, N. Y., KAINZ, B. ET AL. Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*, 2018.
- DE OLIVEIRA, M. ET AL. Lesion volume quantification using two convolutional neural networks in mr images. *Sensors*, vol. 22(4), página 1661, 2022.
- OSPEL, J. M. ET AL. How do quantitative tissue imaging outcomes in acute ischemic stroke relate to functional outcome? *Stroke*, vol. 55(6), páginas e186–e194, 2024.
- PETSIUK, V., DAS, A. y SAENKO, K. Rise: Randomized input sampling for explanation of black-box models. En *British Machine Vision Conference*. 2018.
- RONNEBERGER, O., FISCHER, P. y BROX, T. U-net: Convolutional networks for biomedical image segmentation. En *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, páginas 234–241. Springer, 2015.
- SAMEK, W., BINDER, A., MONTAVON, G., LAPUSCHKIN, S. y MÜLLER, K.-R. Evaluating the visualization of what a deep neural network has learned. *IEEE Transactions on Neural Networks and Learning Systems*, 2017a.
- SAMEK, W., WIEGAND, T. y MÜLLER, K.-R. Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. 2017b.
- SELVARAJU, R. R., COGSWELL, M., DAS, A., VEDANTAM, R., PARIKH, D. y BATRA, D. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, vol. 128(2), páginas 336–359, 2019. ISSN 1573-1405.
- SUNDARARAJAN, M., TALY, A. y YAN, Q. Axiomatic attribution for deep networks. 2017.
- UNIVERSIDAD COMPLUTENSE DE MADRID. Manual de procesamiento de imágenes de rm con imagej. <https://cai.ucm.es/data/cai/7/Manual-de-procesado-de-imagenes-de-RM-con-IMAGEJ-462.pdf>, s.f.
- ZHOU, Z., SIDDIQUEE, M. M. R., TAJBAKHSI, N. y LIANG, J. Unet++: A nested u-net architecture for medical image segmentation. *arXiv preprint arXiv:1807.10165*, 2018.

Apndice **A**

Título del Apéndice A

Los apéndices son secciones al final del documento en las que se agrega texto con el objetivo de ampliar los contenidos del documento principal.

Apndice	B
---------	----------

Título del Apéndice B

Se pueden añadir los apéndices que se consideren oportunos.

Este texto se puede encontrar en el fichero Cascaras/fin.tex. Si deseas eliminarlo, basta con comentar la línea correspondiente al final del fichero TFGTeXiS.tex.

*–¿Qué te parece desto, Sancho? – Dijo Don Quijote –
Bien podrán los encantadores quitarme la ventura,
pero el esfuerzo y el ánimo, será imposible.*

*Segunda parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

*–Buena está – dijo Sancho –; fírmela vuestra merced.
–No es menester firmarla – dijo Don Quijote–,
sino solamente poner mi rúbrica.*

*Primera parte del Ingenioso Caballero
Don Quijote de la Mancha
Miguel de Cervantes*

